https://hjfy.top/arxiv/2506.21605

MemBench：面向基于 LLM 智能体记忆能力的更全面评估

Haoran Tan[1*‡§], Zeyu Zhang[1*‡§], Chen Ma[1‡§], Xu Chen[1†‡§], Quanyu Dai[2†], Zhenhua Dong[2]

[1]Gaoling School of Artificial, Renmin University of China, Beijing, China,
[2]Huawei Noah's Ark Lab
{tanhaoran1321,zeyuzhang,xu.chen}@ruc.edu.cn, daiquanyu@huawei.com

Abstract

近期研究强调了基于 LLM 的智能体中记忆机制的重要性，这些机制使其能够存储观察到的信息并适应动态环境。 然而，评估其记忆能力仍面临挑战。 以往的评估通常受限于记忆层次和交互场景的多样性，且缺乏全面的指标来从多角度反映记忆能力。 为解决这些问题，本文构建了一个更全面的数据集和基准，用于评估基于 LLM 的智能体的记忆能力。 我们的数据集结合了事实记忆和反思记忆作为不同层次，并提出了参与和观察作为多种交互场景。 基于我们的数据集，我们提出了一个名为 MemBench 的基准，从有效性、效率和容量等多方面评估基于 LLM 的智能体的记忆能力。为惠及研究社区，我们在https://github.com/import-myself/Membench发布了我们的数据集和项目。

1 引言

近年来，大模型（LLMs）在处理自然语言和执行跨领域复杂任务方面展现了显著的能力 (Zhao et al., 2023; Wu et al., 2024b)。然而，传统的大模型通常在静态场景中运行，不与外部环境交互，从而限制了其向通用人工智能(AGI)发展的潜力。为解决这一局限，许多近期研究提出了基于大模型的智能体，这些智能体在基础模型之外配备了额外模块，使其能够通过自主学习和动态适应与环境交互 (Wang et al., 2024a; Xi et al., 2025)。其中，记忆模块作为保存关键信息和积累经验的重要基础，使基于大模型的智能体能够更好地应对动态任务的需求，并在其环境中持续进化 (Zhang et al., 2024a)。

以往的一些研究以主观方式评估基于大模型的智能体的记忆能力，采用人工评估者或大模型对记忆过程进行打分 (Zhong et al., 2024)。其他研究则侧重于间接评估方式 (Packer et al., 2023)，通过测量智能体在不同记忆机制下的任务表现来评估其记忆能力，通常更好的记忆机制会带来更优的表现。最近，一些研究引入了长期对话数据集，可用于客观评估基于大模型的智能体的长期记忆能力 (Wu et al., 2024a)。

然而，先前的研究在评估基于 LLM 的智能体记忆能力方面存在一些局限。首先，多数研究对不同层次记忆能力的评估不够充分，主要集中于事实记忆，而忽视了反思记忆。在此，我们将事实记忆定义为涉及明确提供信息的低级记忆类型，而反思记忆则属于更高级别，虽未明言却可隐晦反映。例如，用户的口味偏好体现的是反思记忆，而他们对特定菜品的喜好则属于事实记忆。其次，多数研究局限于参与场景，即智能体以第一人称视角与用户互动。然而，在智能体的日常使用中，还存在观察场景，即智能体以第三人称视角观察并记录用户

*共同第一作者
†通讯作者。
‡北京大模型与智能治理研究重点实验室
§教育部下一代智能搜索与推荐工程研究中心

信息。此外，多数研究仅关注记忆机制的有效性，未考虑其效率与容量，而这在实际应用中也至关重要。

针对这些局限，我们提出了一个更为全面的数据集和基准，用以评估基于 LLM 的智能体的记忆能力。我们的数据集和基准的主要特征如下：

多场景数据集。为了评估智能体在不同场景下的记忆能力，我们的数据集包含了两种常见使用场景的数据。第一种是参与场景，其中智能体与用户进行交互。第二种是观察场景，假设智能体扮演观察者的角色，需要记录用户提供的信息。

多层次记忆内容。我们的数据集同时关注事实记忆与反思记忆，从而能够全面评估基于 LLM 的智能体的记忆能力。它支持在信息提取、跨会话推理、知识更新、时间推理以及反思总结等任务中对记忆能力进行评估。

多指标评估。基于我们的数据集，我们引入了一个多指标基准来评估基于 LLM 的智能体的记忆能力。为了全面且清晰地评估智能体记忆表现的各个方面，我们提供了四项评估指标，包括准确率、召回率、容量和时间效率。

综上所述，我们推出了一款包含多场景、多层次内容的数据集，其特色显著区别于以往的数据集。同时，我们引入了一个更为全面的基准，采用多指标评估体系。为惠及研究界，我们已在 Github 仓库公开了数据集及项目资源。[*]. 在以下部分中，我们在第 2节中提供了相关工作。我们在第 3节中阐述了数据构建的过程，并在第 4节中展示了基准及其分析。最后，我们在第 5节中总结了本文的结论。

2 相关工作

近年来，基于大语言模型的智能体已被广泛应用于许多领域，如推荐 (Wu et al., 2024b)，金融 (Ding et al., 2024) 和个人助手 (Li et al., 2024)，因为它们在解决复杂任务和交互场景方面具有强大的能力 (Wang et al., 2024a)。在智能体解决问题的各种能力中，记忆是最重要的一种，负责存储观察到的信息并召回相关经验，以支持大语言模型推理 (Zhang et al., 2024a)。对基于大语言模型的智能体的记忆能力进行评估是开发先进记忆的关键问题。

[*]https://github.com/import-myself/Membench

表 1: 不同数据集之间的对比。PS 代表参与情景，OS 代表观察情景，FM 指事实记忆，RM 指反思记忆。

Datasets	Profiles	Scenarios	Levels
PerLTQA	✓	PS	FM
LoCoMo	×	PS	FM
LongMemEval	×	PS	FM
MemBench	✓	PS & OS	FM & RM

之前用于记忆评估的数据集主要来自对话数据集，这些数据集旨在评估聊天助手，重点是评估助手的事实记忆能力。LoCoMo (Maharana et al., 2024) 通过 LLM 扩展的个性化描述和时间事件图构建长期对话，为多个评估任务创建对话。LongMemEval (Wu et al., 2024a) 构建具有属性本体和时间戳历史的用户-助手交互数据集。Xu et al. (2022) 通过翻译和角色扮演适应 PersonaChat (Zhang et al., 2019)，具有注释的个性化使用和部分信息可见性。Bai et al. (2023) 提出一个涵盖 Q&A、摘要和代码完成等综合任务的中英文双语基准。An et al. (2023) 提供一个设计用于评估跨不同领域和输入长度的长上下文语言模型的数据集。PerLTQA (Du et al., 2024) 通过 ChatGPT 和维基百科生成角色资料和事件，在人工验证后创建资料、事件和问答对。

如表 1所示，大多数数据集缺乏多样化的场景，仅关注参与场景（PS），而忽视了智能体的观察场景（OS）。此外，它们仅聚焦于事实记忆（FM），忽略了反思记忆（RM）。一些研究甚至未包含用户档案。以往的研究通常将这些数据集用于与智能体记忆过程不匹配的长上下文评估方法中。而且，这些数据集所采用的评估指标也不够全面。

相较于先前研究，我们的工作首次着重于

反思记忆，提出了观察场景，采用了更契合智能体记忆过程的评估方法，并配备了更为全面的度量指标。

3 数据集构建

3.1 数据生成流水线

受 Memsim (Zhang et al., 2024b) 启发，我们基于此框架扩展了用于记忆评估的数据集。在 Memsim 包含的事实记忆问题类型基础上，我们进一步评估了单次或多次会话中记忆知识更新及从助手响应中提取信息的能力。此外，我们融入了反思记忆生成方法，并将观察场景扩展至参与场景。数据集创建过程如下，如图 1所示。

用户关系图采样。借鉴 Memsim 的方法，我们构建了一个由用户档案及其相关实体（包括个人、事件、地点和物品）组成的关系图。基于 Memsim 对事实记忆相关属性采样的方法，我们提出了一种对反思记忆相关高层属性进行采样的方法。为了更好地拟合现实世界中高层属性的分布，我们利用来自三个推荐数据集（包括 MovieLens (Harper and Konstan, 2015)、Food (Majumder et al., 2019) 和 Goodreads (Wan and McAuley, 2018; Wan et al., 2019)）的用户-物品关系对及相关评分。我们通过识别用户最喜欢或积极评分的物品类别，提取每个用户在每个推荐数据集中的高层偏好。如果没有类别信息，我们则利用 LLMs（GPT-4o-mini）总结这些积极关系物品对应的高层偏好。我们通过随机匹配或基于相同属性的匹配来分配高层偏好属性，最终得到如图 2所示的用户关系图。同时，我们利用 LLMs 或推荐数据集中的物品-类别关系，构建了高层偏好与低层事实属性之间的三个一对多映射。

记忆数据集构建。Memsim 为观察场景提供了数据创建流程。我们通过自我对话方法将其扩展到参与场景。在选择高层偏好属性时，应从映射字典中选择多个低层偏好属性，并利用这些低层偏好属性生成相应的证据对话。例如，用户可能会说："我喜欢电影《星球大战》"。为了确保对话的流畅性，关于低层偏好的具体讨论，如电影内容的讨论，会插入到关键对话之间，形成完整的对话。最后，利用剩余的相关属性生成多轮对话，并将证据对话插入其中，构成完整的会话。我们引入了一种基于时间的会话划分方法，其中会话内的时间戳连续分配给每轮对话，通常间隔较短，如一分钟。不同会话之间的时间戳保持顺序，但相邻会话之间的时间间隔通常较长，如一天。

3.2 多场景记忆

智能体的交互场景可分为两类，包括参与场景与观察场景。在参与场景中，智能体与用户进行互动；而在观察场景中，智能体仅作为观察者，记录用户输入的信息。在参与场景下，智能体的其他模块，如推理模块，会影响到记忆模块。然而，在观察场景中，智能体不执行动作，因此不会对记忆产生影响。这两种场景不可等同视之。鉴于此，我们提供了以下两类数据集：

参与记忆场景。参与记忆场景通过用户与智能体之间的对话来体现，这是智能体的典型使用场景。为了消除智能体其他模块的影响，我们预先定义了智能体对用户表达的响应。在用户与智能体的对话交互中，智能体的记忆不仅需要记住用户表达的信息，还需要存储智能体响应的信息，例如当用户请求推荐时智能体的回复。在我们的数据集中，参与场景数据集的数据由多轮对话组成的会话构成。

观察记忆场景。观察记忆场景由用户向智能体输入消息的流程表示。在此过程中，智能体被动接收用户随时间推移发送的消息流，并不与用户进行交互。该场景侧重于智能体作为观察者的角色，智能体只需记住用户表达的消息而无需采取任何动作。在我们的数据集中，观察场景数据集的数据由多条消息组成的消息列表构成。

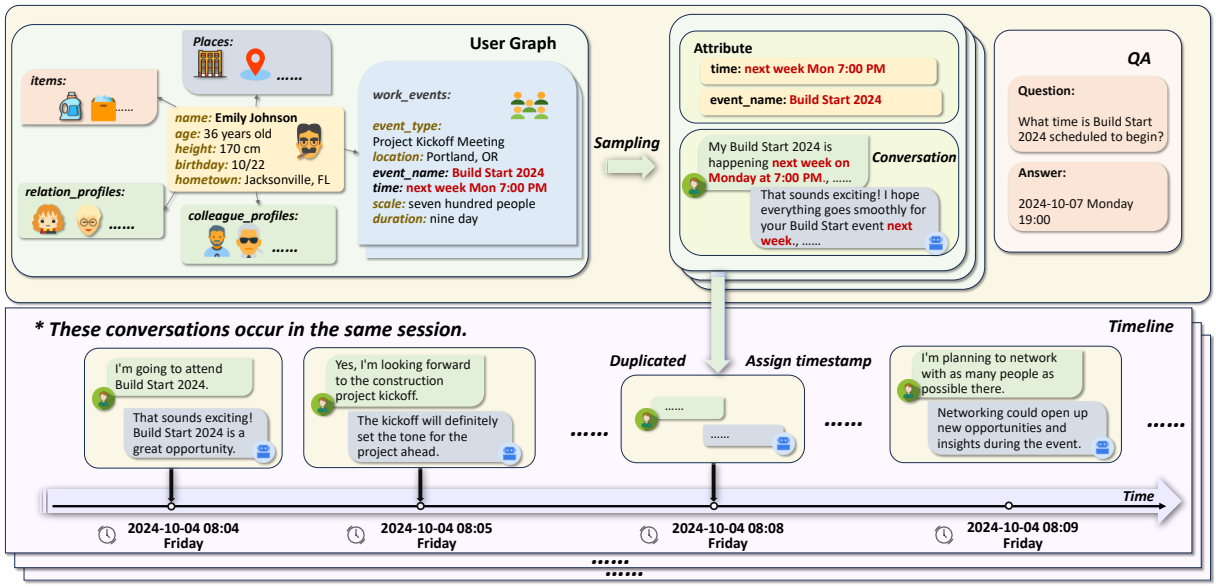

图 1: 一个生成对话数据的示例。首先，提取事件“Build Start 2024”及其时间“下周一晚上 7 点”，随后基于此生成证据对话和问题。该信息与其他属性生成的对话合并，形成完整对话，并依据提供的时间标签“2024 年 10 月 7 日星期一 19:00”生成答案。

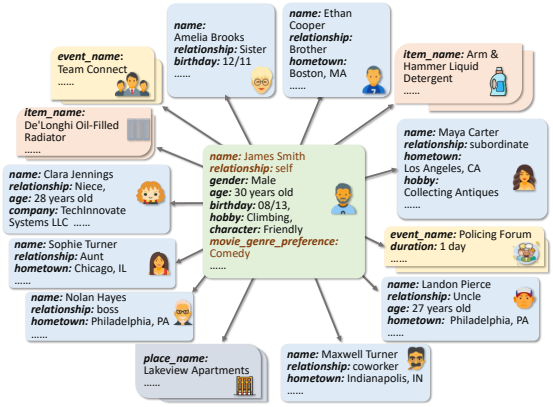

图 2: 用户关系图由用户档案及其关联的实体组成，包括个人、事件、物品和地点。

3.3 多级内存

在基于 LLM 的智能体日常使用中，我们期望其具备事实记忆能力，同时希望其记忆机制能在更高层次上进行总结与推理，生成反思性记忆。反思性记忆使智能体能更全面地理解用户，从而提升后续交互的满意度。基于此视角，我们将数据集中的记忆数据类型及问题划分为两大类：

事实记忆。它指的是用户或与其相关的实体的具体事实属性，例如他们亲属的年龄或职业、事件的时间细节等。这些信息将在用户与智能体之间的日常对话中表达。通过询问这些属性可以测试智能体的各种记忆能力。例如，在对话中，用户可能不会直接表达事件的时间，而是使用间接的引用，如“下周一”，我们可以通过询问智能体事件的确切日期来评估其提取信息并即时转换时间相关信息的能力。此外，我们还可以评估其根据同一属性随时间变化的不同表达来更新知识的能力。更进一步，通过设计需要整合多个实体属性才能回答的问题，我们评估智能体在单次会话和多次会话上下文中的记忆推理能力。这些问题的示例如图 3所示。

反思记忆。反思记忆指的是根据用户对低层次偏好的表达，提取并总结高层次偏好，包括对话中的一些事实属性。例如，从用户对不同菜品的喜好表达中推断其口味偏好。为了增强回答的可信度，我们的记忆内容通过多次表达不同的事实偏好或属性来强化，以加深智能体的理解。我们可以评估智能体记忆机制在不同层次上提取和总结偏好的能力。

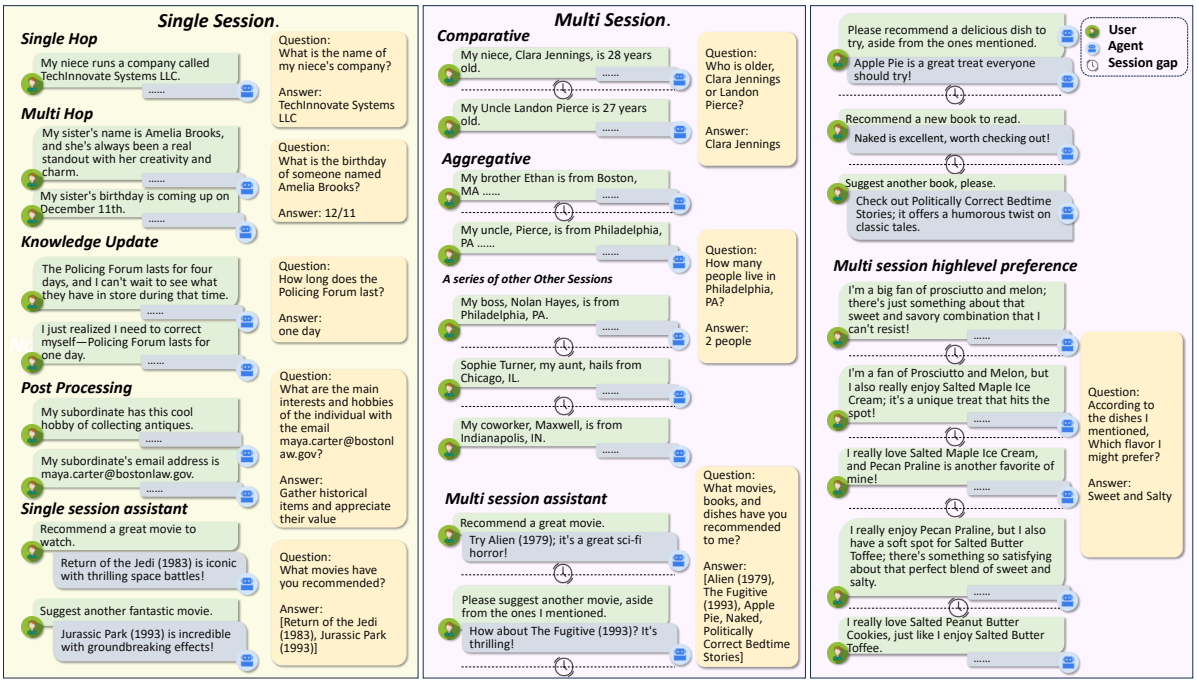

图 3: 用于测试不同能力的数据部分类别概览

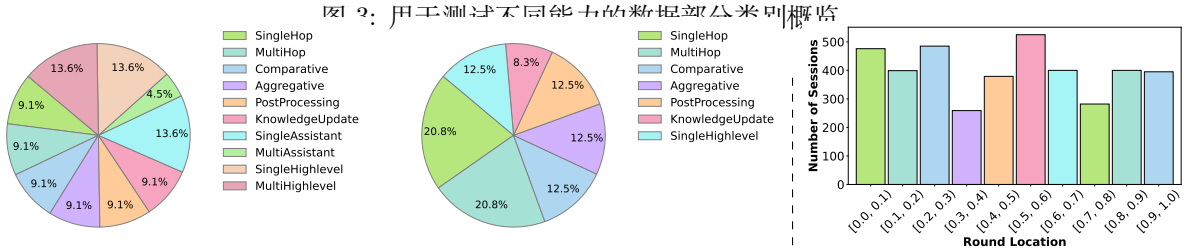

(a) The distribution of different types of questions in the participation dataset.

(b) The distribution of different types of questions in the participation dataset.

(c) The distribution of the number of different round locations of key evidence dialogue turn within a session.

图 4: 数据集中类别分布与答案分布的详细信息。

3.4 多指标评估

为更全面地评估智能体的记忆机制，我们采用了以下四项评价指标。

记忆准确率。为了避免因智能体灵活表达答案而导致的误判，在我们的评估数据集中，所有问题均设置为选择题。在智能体完成记忆过程后，问题和选项将一并提交给智能体。通过比较智能体的选择与真实选择，计算出记忆的准确率得分。

记忆召回。对于基于检索的记忆机制，检索的准确率也是一个需要度量的重要指标。它不仅反映了智能体有效存储和组织记忆内容的能力，还表明了智能体在回答问题时的记忆使用效率。在创建对话的过程中，我们首先生成用于回答问题的关键证据对话，这使得检索准确率的测量成为可能。

记忆容量。我们认为智能体的记忆机制可能存在容量限制，当记忆内容达到一定量时，准确率会急剧下降。这一临界阈值代表了记忆的容量。这种现象可能并不存在，例如，在评估基于检索的记忆机制时，其准确率取决于检索的有效性。

内存效率。在智能体的内存机制设计中，我们不仅需要关注内存的准确率和完整性，还需注重效率。某些内存机制可能导致智能体的处理时间成本过高，这在实际应用中可能是不可接受的。

表 2: 我们数据集的统计量。TPT 表示每条轨迹的平均 token 数量。PS 表示参与场景。OS 表示观察场景。RM 表示反思记忆。FM 表示事实记忆。

Data Type	# Session	# Question	# Trajectory	TPT
PS-RM	3.5k	3.5k	3.5k	2,195
PS-FM	51k	39k	8k	10,285
OS-RM	2k	2k	2k	745
OS-FM	8.5k	8.5k	8.5k	617

3.5 数据集统计量

数据集由两部分组成: (1) 500 个由用户档案和与用户相关的实体档案组成的图，以及 (2) 用户与助手之间的多段对话、多条用户消息及相应的问题。数量如表 2所示。为了更好地模拟现实对话中答案位置的分布，会话中的关键证据轮次几乎均匀分布在每一轮中。如图 4所示，我们可以看到不同类别的数量分布以及会话中关键证据轮次的数量分布。

4 基准

在本节中，我们基于数据集创建了一个基准，用于评估基于 LLM 的个人智能体的记忆能力。为了更好地评估智能体记忆机制能力的上限，我们还利用新闻数据集 (DataGuy and Amoako, 2022) 生成了大量对话和消息，作为与问题无关的噪声记忆内容。我们确保噪声数据的内容不包含与评估数据集中的记忆消息或对话存在事实冲突的情况。此外，通过调整噪声数据的比例，我们可以控制评估的难度。

4.1 实验情景

为了更好地模拟现实场景中智能体的记忆过程，尤其是时间的流动，我们模拟了用户与智能体之间的交互过程，以输入需要记忆的内容。在时间 t，我们输入了用户在第 t 轮中的声明，而前 $t-1$ 轮及更早的内容只能通过记忆召回。在参与记忆场景中，在第 t 轮，智能体不仅需要记住用户的消息，还需要记住它已生成的响应，这是我们预先定义的。同时，在观察场景中，智能体只需记住用户的消息。

为了设定不同的难度级别，我们利用噪声数据集在相邻会话中随机插入一些噪声会话。通过控制比例，我们创建了一个每个单独测试平均长度超过 100k token 的数据集。鉴于我们创建的数据集数量庞大以及智能体记忆机制设计的复杂性，我们对两种不同大小数据集的每个子集进行均匀采样，作为本文的最终测试。在普通大小的数据集中，我们从参与测试数据中提取 120 条反思记忆和 360 条事实记忆数据（每个会话约含 10K token），以及观察测试数据中的 60 条反思记忆和 280 条事实记忆数据（每条消息列表约含 1K token），构成子数据集 1。对于 100k 数据集，我们从参与测试数据中提取 30 条反思记忆和 90 条事实记忆数据（每个会话约含 100K token），以及观察测试数据中的 15 条反思记忆和 84 条事实记忆数据（每条消息列表约含 10K token），标记为子数据集 2。

为了消除其他记忆机制设计对智能体在评估结果中的影响，我们未对智能体的动作模块或其他组件进行任何修改。基于 MemEngine (Zhang et al., 2025)，我们实现了七种记忆机制，使用 Qwen2.5-7B 作为基础模型，应用于我们的基准测试中的智能体应用，包括 FullMemory、RetrievalMemory、RecentMemory、GenerativeAgent (Park et al., 2023)、MemoryBank (Zhong et al., 2024)、MemGPT (Packer et al., 2023) 和自控记忆（SCMemory） (Wang et al., 2023)。在我们的实验中，所有涉及检索的方法均使用 multilingual-e5-small (Wang et al., 2024b) 进行检索。

4.2 事实记忆评估

事实记忆的测试结果如表 3所示。在子数据集 1 上，FullMemory、RetrievalMemory 和 RecentMemory 的表现优于其他记忆机制。然而，在子数据集 2 上，FullMemory 和 RecentMemory 表现出一定程度的下降，因为目标信息可能落在记忆窗口之外。由于 RecentMemory 的窗口大小较小，其下降更为明显。在我们的评估中，其他设计的记忆机制并未显示出

表 3: 不同记忆机制在事实记忆数据集上的表现结果。读取时间（RT）和写入时间（WT）以每次操作的秒数呈现。

Method	Participation-Accuracy		Paticipation-Efficiency		Observation-Accuracy		Observation-Efficiency	
	10k	100k	RT	WT	1k	100k	RT	WT
FullMemory	0.647	0.489	0.001	<0.001	0.786	0.631	<0.001	<0.001
RecentMemory	0.639	0.422	0.001	<0.001	0.8	0.512	<0.001	<0.001
RetrievalMemmory	0.692	0.833	0.041	0.058	0.883	0.933	0.024	0.026
GenerativeAgent	0.478	0.455	0.045	6.116	0.779	0.476	0.031	6.239
MemoryBank	0.442	0.456	0.035	8.047	0.721	0.488	0.037	18.243
MemGPT	0.455	0.411	4.549	0.106	0.789	0.488	1.541	2.480
SCMemory	0.355	0.444	1.531	2.276	0.529	0.429	0.085	0.535

Method	Participation-Recall@10		Observation-Recall@10	
	10k	100k	10k	100k
RetrievalMemmory	0.776	0.749	0.847	0.769

表 4: 不同机制在反射内存数据集上的表现结果。读取时间（RT）与写入时间（WT）以每次操作所需秒数呈现。

Method	Participation-Accuracy		Paticipation-Efficiency		Observation-Accuracy		Observation-Efficiency	
	10k	100k	RT	WT	1k	100k	RT	WT
FullMemory	0.733	0.533	<0.001	<0.001	0.883	0.333	<0.001	<0.001
RecentMemory	0.700	0.333	<0.001	<0.001	0.867	0.400	<0.001	<0.001
RetrievalMemmory	0.692	0.833	0.036	0.057	0.883	0.933	0.026	0.028
GenerativeAgent	0.742	0.333	0.028	6.064	0.883	0.200	0.030	6.019
MemoryBank	0.692	0.400	0.033	15.705	0.900	0.333	0.032	12.827
MemGPT	0.733	0.367	1.042	<0.001	0.883	0.200	0.921	<0.001
SCMemory	0.542	0.267	0.036	0.057	0.783	0.333	0.025	0.028

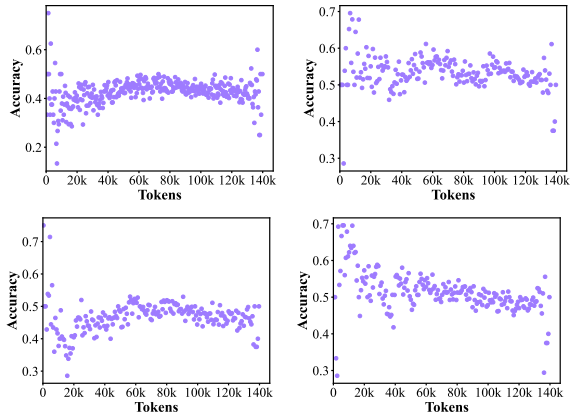

图 5: 随着记忆 token 的增加，SCMemory（左上）、MemGPT（右上）、GenerativeAgent（左下）和 RecentMemory（右下）的准确率变化情况。

显著优越的性能，这可能是由于这些记忆机制存在缺陷。此外，还需注意这些记忆机制在每轮信息读写时消耗的时间，尤其是 MemGPT 在读取信息时耗时较长，而 MemoryBank 在写入信息时耗时较长。

以往的评价工作并未聚焦于智能体记忆机制的设计，仅提供了事实性记忆数据集，因此无法充分探讨智能体在总结反思性记忆方面的能力。接下来，我们将针对反思性记忆进行评估。

4.3 反射内存评估

反射记忆的测试结果如表 4 所示。可以观察到，GenerativeAgent、MemGPT 和 MemoryBank 在子数据集 1 上表现非常出色，但在子数据集 2 上其性能显著下降。只有基于检索的 RetrievalMemory 保持了较好的结果。这可能是由于模型的上下文窗口有限，或者这些记忆系统中引入了遗忘机制，导致重要记忆的丢失。然而，这些发现仍然表明，设计良好的记忆机制能够有效捕捉反射记忆。如何在长时间交互后保持这种能力可能是一个具有挑战性的研究问题。

4.4 记忆容量评估

为了探究智能体记忆机制的容量，我们在子数据集 2（100k）中关键证据开启观察场景后，测试了每轮回答的准确率。为了观察 MemGPT 与自控记忆的准确率随 token 数量增加的变化，我们绘制了图 5。从结果中可以看出，两种记忆机制均表现出急剧下降的趋势，这可能是由于 Qwen2.5-7B-Instruct (Yang et al., 2024; Team, 2024) 中这些记忆机制的记忆性能保留容量上限所致。

4.5 不同推理模型的比较

在实际应用中，针对不同的记忆机制，可能会选择不同的模型。因此，我们评估了几种常见模型在各种记忆机制下的性能。具体而言，我们选择了 Qwen2.5-7B-Instruct、gpt-4o-mini、Meta-Llama-3.1-8B-Instruct 和 glm-4b-chat (GLM et al., 2024) 进行评估。结果如表 5所示。在相同的上下文窗口长度下，基础模型的选择显著影响智能体的表现。在大多数情况下，GPT-4o-mini 相较于其他模型表现最佳。尽管 Meta-Llama-3.1-8B-Instruct 的事实记忆能力明显逊色于其他模型，但其反思记忆能力仍然相对较好。有趣的是，对于 GenerativeAgent，选择 GPT-4o-mini 作为基础模型在我们的实验中会导致时间消耗显著高于其他模型。然而，在大多数情况下，三种模型之间的时间消耗差异并不显著。

5 结论

本文提供了一个更为全面且可扩展的数据集，用于评估基于 LLM 的智能体记忆机制。该数据集涵盖多场景（包括参与与观察）及多层次记忆内容，如反思记忆与事实记忆。依托此数据集，我们构建了一个时间感知的评估框架，模拟用户与智能体间的日常互动，并采用多指标（如准确率、召回率、容量及时效性）进行衡量。我们在基准测试中评估了七种常见智能体记忆机制的表现。

局限性

本文提出的数据集由用户及相关实体档案构成的图谱组成，旨在深入探索智能体的记忆机制。我们的评估方法受限于对结构化数据记

表 5: 不同大模型在我们子数据集 1 上的记忆机制结果。读取时间（RT）和写入时间（WT）以每次操作秒数呈现。对于反射记忆，P-准确率表示参与者场景下的准确率，O-准确率则指观察场景下的准确率。

Method	Factual-Participation			Factual-Observation			Reflective Memory	
	Accuracy	RT	WT	Accuracy	RT	WT	P-Accuracy	O-Accuracy
Qwen2.5-7B-Instruct								
FullMemory	0.647	0.001	<0.001	0.786	<0.001	<0.001	0.733	0.883
RecentMemory	0.639	0.001	<0.001	0.800	<0.001	<0.001	0.700	0.867
RetrievalMemmory	0.692	0.041	0.058	0.883	0.024	0.026	0.692	0.883
GenerativeAgent	0.478	0.045	6.116	0.779	0.031	6.239	0.742	0.883
GPT-4o-mini								
FullMemory	0.736	0.001	<0.001	0.864	<0.001	<0.001	0.783	0.883
RecentMemory	0.697	0.001	<0.001	0.864	<0.001	<0.001	0.758	0.900
RetrievalMemmory	0.633	0.003	0.031	0.857	0.023	0.023	0.767	0.900
GenerativeAgent	0.592	0.107	0.970	0.846	0.030	0.998	0.758	0.900
Meta-Llama-3.1-8B-Instruct								
FullMemory	0.519	0.001	<0.001	0.779	<0.001	<0.001	0.708	0.817
RecentMemory	0.461	0.001	<0.001	0.779	<0.001	<0.001	0.683	0.850
RetrievalMemmory	0.500	0.050	0.062	0.700	0.044	0.049	0.733	0.833
GenerativeAgent	0.430	0.036	6.551	0.725	0.065	12.322	0.725	0.850
glm-4-9b-chat								
FullMemory	0.475	0.001	<0.001	0.775	<0.001	<0.001	0.658	0.850
RecentMemory	0.539	0.001	<0.001	0.746	<0.001	<0.001	0.708	0.850
RetrievalMemmory	0.483	0.032	0.037	0.739	0.025	0.025	0.742	0.800
GenerativeAgent	0.439	0.050	0.165	0.718	0.030	0.111	0.675	0.900

忆的评估。然而，通过比较用户与智能体交互过程中相关实体档案的构建或特定属性信息的捕捉，我们可以研究智能体结构化记忆的能力。此外，在反思性记忆方面，如用户的情感记忆，仍有诸多领域有待探索。

伦理声明

本文构建数据集所采用的数据，均来源于公开且经授权的数据集。所有公开数据均依据各自许可协议，用于研究目的。由大语言模型生成的内容可能带来风险，包括无意中的偏见或有害输出。尽管我们已采取措施降低此类风险，但仍鼓励用户负责任地使用该数据集，以规避伦理 Risk。

致谢

本研究部分得到国家自然科学基金（编号 62422215 和 62472427）的资助，同时获得中国人民大学“双一流”建设重大创新与规划交叉平台、中国人民大学公共计算云以及中国人民大学世界一流大学（学科）建设基金的支持。此外，本研究还受到华为创新研究计划的资助。我们衷心感谢 Mindspore 提供的支持。[†]，本研究采用了 CANN（神经网络计算架构）与🅕腾 AI 处理器。

References

Chenxin An, Shansan Gong, Ming Zhong, Mukai Li, Jun Zhang, Lingpeng Kong, and Xipeng Qiu. 2023. L-eval: Instituting standardized evaluation for long context language models. *arXiv preprint arXiv:2307.11088*.

Yushi Bai, Xin Lv, Jiajie Zhang, Hongchang Lyu, Jiankai Tang, Zhidian Huang, Zhengxiao Du, Xiao Liu, Aohan Zeng, Lei Hou, et al. 2023. Longbench: A bilingual, multitask benchmark for long context understanding. *arXiv preprint arXiv:2308.14508*.

DataGuy and Gordon Amoako. 2022. twitter-news.

Han Ding, Yinheng Li, Junhao Wang, and Hang Chen. 2024. Large language model agent in financial trading: A survey. *arXiv preprint arXiv:2408.06361*.

Yiming Du, Hongru Wang, Zhengyi Zhao, Bin Liang, Baojun Wang, Wanjun Zhong, Zezhong Wang, and Kam-Fai Wong. 2024. Perltqa: A personal long-term memory dataset for memory classification, retrieval, and synthesis in question answering. *arXiv preprint arXiv:2402.16288*.

Team GLM, Aohan Zeng, Bin Xu, Bowen Wang, Chenhui Zhang, Da Yin, Diego Rojas, Guanyu Feng, Hanlin Zhao, Hanyu Lai, Hao Yu, Hongning Wang, Jiadai Sun, Jiajie Zhang, Jiale Cheng, Jiayi Gui, Jie Tang, Jing Zhang, Juanzi Li, Lei Zhao, Lindong Wu, Lucen Zhong, Mingdao Liu, Minlie Huang, Peng Zhang, Qinkai Zheng, Rui Lu, Shuaiqi Duan, Shudan Zhang, Shulin Cao, Shuxun Yang, Weng Lam Tam, Wenyi Zhao, Xiao Liu, Xiao Xia, Xiaohan Zhang, Xiaotao Gu, Xin Lv, Xinghan Liu, Xinyi Liu, Xinyue Yang, Xixuan Song, Xunkai Zhang, Yifan An, Yifan Xu, Yilin Niu, Yuantao Yang, Yueyan Li, Yushi Bai, Yuxiao Dong, Zehan Qi, Zhaoyu Wang, Zhen Yang, Zhengxiao Du, Zhenyu Hou, and Zihan Wang. 2024. Chatglm: A family of large language models from glm-130b to glm-4 all tools. *Preprint*, arXiv:2406.12793.

F Maxwell Harper and Joseph A Konstan. 2015. The movielens datasets: History and context. *Acm transactions on interactive intelligent systems (tiis)*, 5(4):1–19.

Yuanchun Li, Hao Wen, Weijun Wang, Xiangyu Li, Yizhen Yuan, Guohong Liu, Jiacheng Liu, Wenxing Xu, Xiang Wang, Yi Sun, et al. 2024. Personal llm agents: Insights and survey about the capability, efficiency and security. *arXiv preprint arXiv:2401.05459*.

Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. 2024. Evaluating very long-term conversational memory of llm agents. *arXiv preprint arXiv:2402.17753*.

Bodhisattwa Prasad Majumder, Shuyang Li, Jianmo Ni, and Julian McAuley. 2019. Generating personalized recipes from historical user preferences. *arXiv preprint arXiv:1909.00105*.

Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G Patil, Ion Stoica, and Joseph E Gonzalez. 2023. Memgpt: Towards llms as operating systems. *arXiv preprint arXiv:2310.08560*.

Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S Bernstein. 2023. Generative agents: Interactive simulacra of human behavior. In

[†] https://www.mindspore.cn

Proceedings of the 36th annual acm symposium on user interface software and technology, pages 1–22.

Qwen Team. 2024. Qwen2.5: A party of foundation models.

Mengting Wan and Julian J. McAuley. 2018. Item recommendation on monotonic behavior chains. In *Proceedings of the 12th ACM Conference on Recommender Systems, RecSys 2018, Vancouver, BC, Canada, October 2-7, 2018*, pages 86–94. ACM.

Mengting Wan, Rishabh Misra, Ndapa Nakashole, and Julian J. McAuley. 2019. Fine-grained spoiler detection from large-scale review corpora. In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28- August 2, 2019, Volume 1: Long Papers*, pages 2605–2610. Association for Computational Linguistics.

Bing Wang, Xinnian Liang, Jian Yang, Hui Huang, Shuangzhi Wu, Peihao Wu, Lu Lu, Zejun Ma, and Zhoujun Li. 2023. Enhancing large language model with self-controlled memory framework. *arXiv preprint arXiv:2304.13343*.

Lei Wang, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhiyuan Chen, Jiakai Tang, Xu Chen, Yankai Lin, et al. 2024a. A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6):186345.

Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024b. Multilingual e5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.

Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. 2024a. Longmemeval: Benchmarking chat assistants on long-term interactive memory. *arXiv preprint arXiv:2410.10813*.

Likang Wu, Zhi Zheng, Zhaopeng Qiu, Hao Wang, Hongchao Gu, Tingjia Shen, Chuan Qin, Chen Zhu, Hengshu Zhu, Qi Liu, et al. 2024b. A survey on large language models for recommendation. *World Wide Web*, 27(5):60.

Zhiheng Xi, Wenxiang Chen, Xin Guo, Wei He, Yiwen Ding, Boyang Hong, Ming Zhang, Junzhe Wang, Senjie Jin, Enyu Zhou, et al. 2025. The rise and potential of large language model based agents: A survey. *Science China Information Sciences*, 68(2):121101.

Xinchao Xu, Zhibin Gou, Wenquan Wu, Zheng-Yu Niu, Hua Wu, Haifeng Wang, and Shihang Wang. 2022. Long time no see! open-domain conversation with long-term persona memory. *arXiv preprint arXiv:2203.05797*.

An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, Guanting Dong, Haoran Wei, Huan Lin, Jialong Tang, Jialin Wang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Ma, Jin Xu, Jingren Zhou, Jinze Bai, Jinzheng He, Junyang Lin, Kai Dang, Keming Lu, Keqin Chen, Kexin Yang, Mei Li, Mingfeng Xue, Na Ni, Pei Zhang, Peng Wang, Ru Peng, Rui Men, Ruize Gao, Runji Lin, Shijie Wang, Shuai Bai, Sinan Tan, Tianhang Zhu, Tianhao Li, Tianyu Liu, Wenbin Ge, Xiaodong Deng, Xiaohuan Zhou, Xingzhang Ren, Xinyu Zhang, Xipin Wei, Xuancheng Ren, Yang Fan, Yang Yao, Yichang Zhang, Yu Wan, Yunfei Chu, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, and Zhihao Fan. 2024. Qwen2 technical report. *arXiv preprint arXiv:2407.10671*.

Wei-Nan Zhang, Qingfu Zhu, Yifa Wang, Yanyan Zhao, and Ting Liu. 2019. Neural personalized response generation as domain adaptation. *World Wide Web*, 22:1427–1446.

Zeyu Zhang, Xiaohe Bo, Chen Ma, Rui Li, Xu Chen, Quanyu Dai, Jieming Zhu, Zhenhua Dong, and Ji-Rong Wen. 2024a. A survey on the memory mechanism of large language model based agents. *arXiv preprint arXiv:2404.13501*.

Zeyu Zhang, Quanyu Dai, Luyu Chen, Zeren Jiang, Rui Li, Jieming Zhu, Xu Chen, Yi Xie, Zhenhua Dong, and Ji-Rong Wen. 2024b. Memsim: A bayesian simulator for evaluating memory of llm-based personal assistants. *arXiv preprint arXiv:2409.20163*.

Zeyu Zhang, Quanyu Dai, Xu Chen, Rui Li, Zhongyang Li, and Zhenhua Dong. 2025. Memengine: A unified and modular library for developing advanced memory of llm-based agents. In *Companion Proceedings of the ACM on Web Conference 2025*, pages 821–824.

Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. 2023. A survey of large language models. *arXiv preprint arXiv:2303.18223*.

Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. 2024. Memorybank: Enhancing large language models with long-term memory. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 38, pages 19724–19731.

A 案例研究

A.1 用户关系图示例

在本节中，我们将展示数据集中各组成部分的实例，包括用户关系图及测试案例。针对用户关系图，我们呈现了用户自身、相关人物、事件、物品及地点的档案示例。

用户档案: ” 性别”: ” 男”, ” 关系”: ” 本人”, ” 姓名”: ” 詹姆斯 · 史密斯”, ” 年龄”: ”30 岁”, ” 身高”: ”164 厘米”, ” 生日”: ”08.13”, ” 家乡”: ” 加利福尼亚州旧金山”, ” 工作地点”: ” 马萨诸塞州波士顿”, ” 教育程度”: ” 副学士学位”, ” 职业”: ” 警察”, ” 职位”: ” 社区警务官”, ” 公司名称”: ” 波士顿执法机构”, ” 爱好”: ” 攀岩”, ” 性格”: ” 友好”, ” 联系电话”: ”4150430511”, ” 电子邮件地址”: ”james.smith@bostonlawenforcement.gov”, ” 社会保障号”: ”914610199408130162”, ” 护照号码”: ”PUP4822676”, ” 银行账户”: ”6222022865544246”, ” 驾驶证”: ”914EAPRDV5F”, ” 高级偏好”: [” 电影类型偏好”: (” 喜剧”, ” 爱情”, ” 动作”, ” 剧情”, ” 惊悚”), ” 口味偏好”: ” 鲜味和甜味”, ” 书籍偏好”: ” 幽默”].

RelativeRoleProfile.” 性别”:” 男”, ” 关系”:” 兄弟”,” 姓名”: ” 伊森 · 库珀”,” 年龄”: ”28 岁”,” 身高”: ”165cm”,” 生日”: ”01/20”,” 家乡”: ” 马萨诸塞州波士顿”, ” 工作地点”: ” 加利福尼亚州洛杉矶”, ” 学历”: ” 副学士学位”, ” 职业”: ” 电工”, ” 职位”: ” 电气维护技术员”, ” 公司名称”: ”SparkLight 电气服务”, ” 爱好”: ” 跑步”, ” 性格”: ” 体贴”, ” 联系电话”: ”20103787263”,” 电子邮件地址”: ”ethan.cooper@sparklightelectric.com”

同事角色档案。” 性别”: ” 男”, ” 关系”: ” 上司”, ” 姓名”: ” 诺兰 · 海耶斯”, ” 年龄”: ”39 岁”, ” 身高”: ”170 厘米”, ” 生日”: ”03/24”, ” 家乡”: ” 费城, 宾夕法尼亚州”, ” 工作地点”: ” 波士顿, 马萨诸塞州”, ” 教育程度”: ” 副学士学位”, ” 职业”: ” 警察”, ” 职位”: ” 警长”, ” 公司名称”: ” 波士顿执法机构”, ” 爱好”: ” 参加音乐会”, ” 性格”: ” 富有同情心”, ” 联系电话”: ”30503926075”, ” 电子邮件地址”: ”nolan.hayes@bostonlawagency.gov”

工作活动档案。” 活动类型”: ” 公司团队建设”, ” 主要内容”: ” 团队凝聚力的社区参与研讨会”, ” 地点”: ” 加利福尼亚州洛杉矶”, ” 时间”: ” 下下周六上午 9:00”, ” 活动名称”: ” 团队连接”, ” 规模”: ” 一百人”, ” 持续时间”: ” 八天”

RestEventProfile.” 活动类型”: ” 社区集市”, ” 主要内容”: ” 加入我们的社区集市，体验攀岩挑战、装备演示和安全工作坊！与同好交流，探索本地攀岩地点，并聆听资深攀岩者的鼓舞演讲。适合所有技能水平和攀岩爱好者！”, ” 地点”: ” 佛罗里达州迈阿密”, ” 时间”: ”2024-10-12 19:00”, ” 活动名称”: ” 攀岩节”, ” 规模”: ” 九百人”, ” 持续时间”: ” 三天”

物品简介: ” 关系”: ” 拥有”, ” 物品类型”: ” 洗衣液”, ” 物品名称”: ”Arm & Hammer 液体洗衣液”, ” 物品评价”: ” 作为一名警察，我总是在外奔波，需要能够跟上我忙碌生活节奏的产品。我使用 Arm & Hammer 液体洗衣液已有一段时间，不得不说，它彻底改变了我的洗衣体验。不仅能轻松应对制服和装备上的顽固污渍，还让衣物保持清新洁净。添加的小苏打有效中和异味，这对于在不同环境中工作的我来说至关重要。此外，我很欣赏它提供环保选择，让我在照顾衣物的同时也能关爱地球。对于寻求高效可靠洗衣液的人来说，这无疑是一个坚实的选择！”

地点简介。地点示例：“关系”：” 曾到访“,” 地点类型“:” 购物中心“,” 地点名称“:” The Grove“,” 地点评价“:” 我最近访问了 The Grove，不得不说，这是一次非常令人耳目一新的体验。那里的氛围非常友好和热情，就像我作为一名警察努力服务的社区一样。商店和餐厅种类繁多，我特别喜欢在当地的一家餐馆用餐。布局易于导航，是放松和享受新鲜空气的完美场所。作为一个热爱攀爬的人，我欣

赏那里的绿地，可以在那里放松身心，享受大自然。这是一个与家人或朋友共度时光的绝佳地点。我发现的唯一缺点是高峰时段会有点拥挤，但在这样一个受欢迎的地方这是可以预料的。总的来说，我强烈推荐 The Grove 给任何寻找有趣且友好外出活动的人！“

A.2 FM-RM 词典示例

在建立事实记忆属性与反思记忆属性之间的对应关系时，我们同步创建了一个映射两者的字典。以下，我们分别从反思记忆的各个类别中提供示例。

电影。 ” 动作”: [” 星球大战 (1977)”,” 教父 (1972)”,” 夺宝奇兵 (1981)”,” 泰坦尼克号 (1997)”,” 帝国反击战 (1980)”,” 潜艇风暴 (1981)”,” 教父 2 (1974)”,” 非洲女王号 (1951)”,” 公主新娘 (1987)”,” 勇敢的心 (1995)”, ” 光荣战役 (1989)”, ” 亡命天涯 (1993)”,” 异形 (1979)”,” 绝地归来 (1983)”,” 终结者 2:审判日 (1991)”, ” 虎豹小霸王 (1969)”,” 异形 2 (1986)”,” 豪勇七蛟龙 (1954)”,” 终结者 (1984)”,” 阿波罗 13 号 (1995)”,” 夺宝奇兵 3: 圣战奇兵 (1989)”,” 虎胆龙威 (1988)”,” 猎杀红色十月 (1990)”,” 黄金三镖客 (1966)”,” 福禄双霸天 (1980)”,” 宾虚 (1959)”, ” 大鼻子情圣 (1990)”, ” 星际迷航 2: 可汗怒吼 (1982)”,” 火线狙击 (1993)”, ” 罗宾汉历险记 (1938)”,” 大白鲨 (1975)”,” 变脸 (1997)”,” 黑衣人 (1997)”,” 歌剧红伶 (1981)”,” 侏罗纪公园 (1993)”,” 勇闯夺命岛 (1996)”,” 全金属外壳 (1987)”, ” 完美世界 (1993)”,” 星际迷航: 第一次接触 (1996)”,” 生死时速 (1994)”,” 空军一号 (1997)”, ” 哭泣游戏 (1992)”, ” 真实罗曼史 (1993)”,” 深渊 (1989)”,” 燃眉追击 (1994)”,” 盗火线 (1995)”,” 真实的谎言 (1994)”,” 矮子当道 (1995)”,” 最后的莫希干人 (1992)”,” 超级警察 (1992)”]

食物。“甜味”: [” 糖果”, ” 蜂蜜”, ” 水果”, ” 枫糖浆煎饼”, ” 巴克拉瓦”, ” 巧克力蛋糕”, ” 蛋奶沙司”, ” 果冻”, ” 山核桃派”, ” 苹果派”, ” 布朗尼”, ” 香蕉面包”, ” 甜甜圈”, ” 米花糖”]

书籍. “健康与健身”: [《怀孕圣经（修订版)》,《建立联系: 十步迈向更佳体魄与更美好生活》,《南滩饮食: 美味、医生设计、简单易行的快速健康减重计划》,《阿特金斯博士的新饮食革命》,《阿特金斯博士的新饮食革命》,《营养治疗处方: 使用维生素、矿物质、草药及食品补充剂的无药疗法实用 A-Z 指南》,《八周达到最佳健康状态》,《生命之体: 十二周实现心理与身体力量的提升》,《你的孕期: 每周指南（你的孕期系列)》,《肥胖之地: 美国人如何成为世界上最胖的人群》]

A.3 问题描述

在表 6中，我们提供了对每种事实记忆问题的解释。在表 7中，我们提供了对每种反思记忆问题的解释。

A.4 参与示例

在本节中，我们从数据集的参与场景中提供了更为详尽的示例。为使展示更加清晰，我们仅列出了回答问题所需的关键证据对话轮次，并省略了任何不必要的信息。

具体示例如下:

单跳

我的侄女经营着一家名为“科技创新系统有限责任公司”的企业。

助手: ...

我侄女的公司叫什么名字?

答案: TechInnovate 系统有限责任公司

多跳

我妹妹名叫艾米莉亚 · 布鲁克斯，她向来以其创造力和魅力而格外引人注目。

助手: ...

我妹妹的生日是 12 月 11 日，快到了。

助手: ...

阿米莉亚 · 布鲁克斯的生日是什么时候?

答案: 12/11

知识更新

表 6: 事实记忆题概览。

Types	Descriptions
Single-hop	Rely on one message to answer the question directly.
Multi-hop	Require multiple messages to answer the question jointly.
Comparative	Compare two entities on a shared attribute with multiple messages.
Aggregative	Aggregate messages about more than two entities on a common attribute.
Post-processing	Involve extra reasoning steps to answer with multiple messages.
Knoewledge-updating	The basis for answering questions will be updated over time with different messages.
Single-session-assistant	Rely on a single message from the assistant to directly answer the question.
Multi-session-assistant	Require Multiple messages from the assistant to collectively answer the question.

表 7: 反射内存问题概述。

Types	Descriptions
Preference	Rely on multiple messages to actively express the user's lower-level preferences.
Emotion	Rely on multiple consecutive messages within a specific time to express the user's emotional state.

警务论坛将持续四天，我迫不及待想看看他们在这期间准备了哪些内容。

用户：我刚意识到需要更正一下——警务论坛仅持续一天。助手：...

警务论坛持续多长时间?

答案：有一天

后处理

我的下属有个很酷的爱好，就是收藏古董。

助手：...

我下属的电子邮件地址是 maya.carter@bostonlaw.gov。

助手：...

邮箱地址为 maya.carter@bostonlaw.gov 的个人的主要兴趣和爱好是什么?

收集历史文物，品味其价值

单次会话助手

我正在寻找一部好电影来看，除了我之前提到的那几部之外。

我完全沉迷于《绝地归来》；这部电影太经典了，那些激动人心的太空战斗和令人难忘的角色，使它成为必看之作!

我在寻找一部精彩的电影来看，除了我之前提到的那几部之外。

我推荐 1993 年的《侏罗纪公园》；这部电影以其突破性的特效和扣人心弦的冒险情节，牢牢抓住了我的注意力，堪称经典!

我之前给你推荐过哪些电影?

《绝地归来》(1983 年)、《侏罗纪公园》(1993 年)

比较的

用户：我的侄女，克拉拉 · 詹宁斯，今年 28 岁。

助理：...

我的叔叔兰登 · 皮尔斯今年 27 岁。

助理：...

克拉拉 · 詹宁斯和兰登 · 皮尔斯，谁更年长?

克拉拉 · 詹宁斯

聚合性

我的兄弟伊桑 · 库珀来自马萨诸塞州波士顿。

助手：...

我的妹妹，艾米莉亚 · 布鲁克斯，来自华盛顿特区。

助手：...

我的侄女克拉拉 · 詹宁斯来自佛罗里达州的杰克逊维尔。

助手：...

我的叔叔兰登 · 皮尔斯来自宾夕法尼亚州费城。

助手：...

用户：我的姑姑索菲 · 特纳来自伊利诺伊州芝加哥。

助手：...

我的老板诺兰 · 海斯来自宾夕法尼亚州费城。

助手：...

用户：在我手下工作的玛雅 · 卡特来自加利福尼亚州洛杉矶。

助手：...

我的同事麦克斯韦 · 特纳来自印第安纳州印第安纳波利斯。

助手：...

费城，宾夕法尼亚州的人口有多少?

答：2 人

多会话助手

用户：我在找一部好电影来看，之前提到过的那些除外。

助手：我坚信《异形》(1979) 绝对不容错过；它巧妙融合了科幻与恐怖元素，紧张刺激，让人全程屏息凝神！

用户：我在找一部好电影来看，除了我之前提到的那几部之外。

“我超爱 1993 年的《亡命天涯》，那真是一场惊心动魄的旅程，让人全程紧张不已！”

用户：我想尝试一道美味的菜肴，除了之前提到的那几道之外。

助手：我超爱苹果派；它真是一道令人愉悦的美味，大家绝对应该尝一尝！

用户：我在找一本好书来读，之前提到过的那些除外。

助手：我真的觉得《赤裸》是一本非常棒的书，绝对值得一读！

用户：我在找一本好书来读，除了之前提到的那几本之外。

助手：我真心推荐大家阅读《政治正确的睡前故事：当代生活与时代的现代寓言》，它以诙谐的方式重新诠释经典故事，巧妙映射出当今社会的诸多议题。

我向你推荐过哪些电影、书籍和菜肴?

答案：[” 异形 (1979)”,” 逃亡者 (1993)”,” 苹果派”,” 赤裸”,” 政治正确的睡前故事：现代故事讲述我们的生活和时代”]

多会话高级偏好

用户：我是火腿蜜瓜的超级粉丝，那种甜咸交织的味道真是让人无法抗拒！

助手：...

我是意大利火腿配蜜瓜的忠实粉丝，但同样钟情于咸枫糖冰淇淋；这道独特的美味总能恰到好处地满足我的味蕾！

助理：...

我真的很喜欢盐枫冰淇淋，而山核桃糖也是我的另一大最爱！

助理：...

我确实非常喜欢山核桃糖，但咸味黄油太妃糖也让我难以抗拒；那种甜与咸的完美融合，实在令人满足。

助理：...

用户：我真的很喜欢咸味花生酱曲奇，就像我享受咸味黄油太妃糖一样。

助手：...

根据我提到的菜肴，我可能偏爱哪种口味?

答案：甜与咸

A.5 观察示例

参与数据与此处数据的唯一区别在于缺少“助手”的回应，因此此处未提供具体示例。

B 详细数据统计

在表 8中，我们提供了参与数据集的详细统计量。在表 9中，我们提供了观测数据集的详细统计量。

C 数据生成提示

C.1 个人简介提示

风味记忆属性请根据用户喜欢的菜品从 [口味] 中选择其偏好。[菜品]:{菜品} [口味]: [” 甜”, ” 酸”, ” 辣”, ” 咸”, ” 鲜”, ” 苦”, ” 甜咸”, ” 酸甜”, ” 咸鲜”, ” 酸辣”, ” 甜咸辣”, ” 酸咸”, ” 酸香甜”, ” 咸鲜辣”, ” 麻辣”, ” 奶油甜”, ” 鲜

表 8: 我们参与数据集的详细统计量。RM 代表反思记忆，FM 代表事实记忆。类型包括 ssh（单跳）、mh（多跳）、comp（比较性）、agg（聚合性）、pp（后处理）、ku（知识更新）、ssa（单会话助手）、msa（多会话助手）。

Data Type	# Session	# Question	# Trajectory
RM-Pr	3.0k	3.0k	3.0k
RM-Em	0.5k	0.5k	0.5k
FM-sh	8k	8k	1k
FM-mh	8k	8k	1k
FM-comp	8k	4k	1k
FM-agg	8k	1k	1k
FM-ku	8k	8k	1k
FM-pp	8k	8k	1k
FM-ssa	1.5k	1.5k	1.5k
FM-msa	1.5k	0.5k	0.5k

表 9: 我们参与数据集的详细统计量。RM 代表反思记忆，FM 代表事实记忆。所包含的类型有 sh（单跳）、mh（多跳）、comp（比较性）、agg（聚合性）、pp（后处理）、ku（知识更新）。

Data Type	# Session	# Question	# Trajectory
RM-Pr	1.5k	1.5k	1.5k
RM-Em	0.5k	0.5k	0.5k
FM-sh	1.5k	1.5k	1.5k
FM-mh	1.5k	1.5k	1.5k
FM-comp	1.5k	1.5k	1.5k
FM-agg	1.5k	1.5k	1.5k
FM-pp	1.5k	1.5k	1.5k
FM-ku	1k	1k	1k

甜”，” 苦甜”，” 涩”，” 麻”，” 浓郁肥美”，” 清凉”，” 温热辣”] 示例输出:{{’ 口味’: ’ 甜’}}

C.2 自我对话提示

角色对话生成提示。请生成一段 {round_length} 轮的交互对话，总共有 {sentence_length} 句话。对话的主要内容应基于用户 {entity} 的给定信息。确保对话中不引入超出提供范围的信息。** 请注意，用户不能向助手询问信息，因为助手并不知道这些信息。** 请注意，助手是用户的个人助手，因此它只能被动回应用户的对话，但可以回复多样化的内容。请以示例中所示的 JSON 列表格式返回对话，确保结果可以直接被 json.loads 解析。** 每个 json 必须包含用户和助手的对话内容！每个 json 的格式为 {{”user”: 用户的话，”assistant”: 助手的话}}** #[信息]: {information}

#example: [{{”user”: ”I wanted to talk to you about my cousin, Ethan Parker. He’s 39 years old.”, ”assistant”: ”Certainly! Ethan is 39. Is there something specific you’d like to discuss about him?”}}, {{”user”: ”Well, he’s actually pretty short for a guy, only 162 cm. He always jokes about it, though.”, ”assistant”: ”It sounds like Ethan has a good sense of humor about his height. That’s always a great quality!”}}, {{”user”: ”Yes, he really does. It’s one of the things that makes him so fun to be around.”, ”assistant”: ”I can imagine! Having a cousin with a lighthearted attitude must make family gatherings enjoyable.”}}, {{”user”: ”Definitely. And since we’ re so close in age, it feels like he’ s more of a friend than just family.”, ”assistant”: ”That sounds wonderful. It must be special to have that kind of bond with your cousin.”}} {{”user”: ”It really is. We’ ve shared a lot of memories growing up together.”, ”assistant”: ”Those shared memories must make your relationship even stronger. It sounds like Ethan has been a big part of your life.”}}]

事件对话生成提示。请生成一段 {round_length} 轮的交互对话，包含 {sentence_length} 句话。对话的主要内容应基于提供的 {event_name} 相关信息。确保对话中不引入超出所提供信息的内容。请注意，助手是用户的个人助理，因此应仅被动回应用户的对话，但可以以多样化的内容进行回复。注意，用户不能向助手询问信息，因为助手并不了解这些信息。你可以从用户说“我要参加 {event_name}”开始。请以 JSON 列表格式返回对话，确保结果可以直接被 json.loads 解析。#[信息]: {information}

#example: [{{"user": "I wanted to talk to you about my cousin, Ethan Parker. He's 39 years old.", "assistant": "Certainly! Ethan is 39. Is there something specific you'd like to discuss about him?"}}, {{"user": "Well, he's actually pretty short for a guy, only 162 cm. He always jokes about it, though.", "assistant": "It sounds like Ethan has a good sense of humor about his height. That's always a great quality!"}}, {{"user": "Yes, he really does. It's one of the things that makes him so fun to be around.", "assistant": "I can imagine! Having a cousin with a lighthearted attitude must make family gatherings enjoyable."}}, {{"user": "Definitely. And since we' re so close in age, it feels like he' s more of a friend than just family.", "assistant": "That sounds wonderful. It must be special to have that kind of bond with your cousin."}} {{"user": "It really is. We' ve shared a lot of memories growing up together.", "assistant": "Those shared memories must make your relationship even stronger. It sounds like Ethan has been a big part of your life."}}]

C.3 观察提示

角色消息提示。[用户消息]: {message} 请将上述用户消息改写为口语化的陈述句。确保其流畅且无语法错误，不改变原始信息。仅输出改写后的用户消息，不包括原始消息。不要输出任何其他描述。输出示例：我的老板卢卡斯 · 格兰特拥有硕士学位。

事件消息提示。我收到了一条消息：{message}

D 结果详情

D.1 反思成果

在表 10中，我们展示了 10k-Reflective 内存数据集的详细结果。

D.2 实际结果

在表 11中，我们展示了 10k 事实参与记忆数据集的详细结果。在表 12中，我们展示了 10k 事实观察记忆数据集的详细结果。

表 10: 不同机制在我们 10k-反射记忆数据集上的各类别表现结果。

Method	Participation-Accuracy		Observation-Accuracy	
	preference	emotion	preference	emotion
FullMemory	0.733	0.593	0.883	0.630
RecentMemory	0.700	0.481	0.867	0.556
RetrievalMemmory	0.692	0.556	0.883	0.593
GenerativeAgent	0.742	0.412	0.883	0.676
MemoryBank	0.692	0.296	0.900	0.481
MemGPT	0.733	0.471	0.883	0.556
SCMemory	0.542	0.294	0.783	0.333

表 11: 不同机制在我们 10k-Factual-Participation 数据集上的表现结果，涵盖 sh（单跳）、mh（多跳）、comp（比较）、agg（聚合）、pp（后处理）、ku（知识更新）、ssa（单会话助手）、msa（多会话助手）。

Method	Participation-Accuracy							
	sh	mh	comp	agg	pp	ku	ssa	msa
FullMemory	0.825	0.8	0.55	0.275	0.625	0.75	0.7	0.55
RecentMemory	0.85	0.75	0.425	0.45	0.65	0.725	0.717	0.5
RetrievalMemmory	0.875	0.775	0.55	0.275	0.475	0.675	0.4	0.3
GenerativeAgent	0.75	0.675	0.3	0.35	0.525	0.525	0.267	0.55
MemoryBank	0.575	0.7	0.25	0.25	0.475	0.55	0.417	0.4
MemGPT	0.625	0.625	0.275	0.225	0.45	0.625	0.367	0.45
SCMemory	0.575	0.475	0.05	0.275	0.525	0.475	0.217	0.1

表 12: 不同机制在我们 10k-Factual-Observation 记忆数据集上的表现结果，涵盖 sh（单跳）、mh（多跳）、comp（对比）、agg（聚合）、pp（后处理）、ku（知识更新）等类型。

Method	Observation-Accuracy					
	sh	mh	comp	agg	pp	ku
FullMemory	0.92	0.92	0.667	0.233	0.82	0.6
RecentMemory	0.92	0.92	0.667	0.367	0.82	0.65
RetrievalMemmory	0.92	0.92	0.633	0.367	0.78	0.45
GenerativeAgent	0.88	0.94	0.7	0.3	0.82	0.4
MemoryBank	0.8	0.78	0.633	0.233	0.800	0.6
MemGPT	0.94	0.92	0.667	0.233	0.82	0.600
SCMemory	0.46	0.68	0.133	0.133	0.78	0.65