https://hjfy.top/arxiv/2512.06688

PersonaMem-v2：通过学习隐式用户人格和智能体记忆实现个性化智能

Bowen Jiang[1] , Yuan Yuan[1], Maohao Shen[2], Zhuoqun Hao[1], Zhangchen Xu[3], Zichen Chen[4], Ziyi Liu[6], Anvesh R. Vijjini[7], Jiashu He[1], Hanchao Yu[5], Radha Poovendran[3], Gregory Wornell[2], Lyle Ungar[1], Dan Roth[1], Sihao Chen[8*], Camillo J. Taylor[1*]

University of Pennsylvania[1], Massachusetts Institute of Technology[2], University of Washington[3], University of California Santa Barbara[4], Meta[5], University of Southern California[6], University of North Carolina at Chapel Hill[7], Microsoft Corporation[8]

bwjiang@seas.upenn.edu, sihaochen@microsoft.com, cjtaylor@seas.upenn.edu

🤗 huggingface.co/datasets/bowen-upenn/PersonaMem-v2

Abstract

个性化是推动人工智能能力与对齐性的下一个里程碑之一。我们提出了 PersonaMem-v2，这是当前最先进的大语言模型个性化数据集，模拟了超过 300 种场景下的 1,000 次真实用户–聊天机器人交互，包含 20,000 多项用户偏好以及 128k-token 的上下文窗口，其中大多数用户偏好以隐式方式呈现，以反映现实世界中的交互情况。利用该数据，我们研究了强化学习微调如何提升模型在长上下文推理方面的能力，以实现更精准的用户理解与个性化。此外，我们还开发了一种用于训练智能体记忆系统的框架，该系统能够维护一个单一且人类可读的记忆，随着每次用户交互而持续增长。

在我们的实验中，前沿大模型在隐式个性化任务上仍存在困难，准确率仅为 37–48%。尽管它们支持长上下文窗口，但推理能力仍是隐式个性化任务的瓶颈。通过强化学习微调，我们成功训练了 Qwen3-4B，在隐式个性化任务中表现优于 GPT-5，准确率达到 53%。此外，我们的智能体记忆框架在仅使用 16 倍更少输入 token 的情况下，实现了当前最优的 55% 准确率，其依赖的是 2k token 的记忆空间，而非完整的 32k 对话历史。这些结果凸显了我们数据集的影响，并展示了智能体记忆作为实现真实世界个性化智能的可扩展路径。

1 引言

个性化正成为迈向人工智能超级智能的下一个里程碑之一 (OpenAI, 2025;b; Meta, 2025; Chowdhury, 2025; Evolution AI Hub, 2025)。随着人工智能用户群体在规模和多样性上急剧增长，大模型 (LLMs) 面临着为具有不同人格特征和背景的用户提供服务的挑战。在许多现实应用中，如教育、医疗以及共情情感支持 (Jiang et al., 2025; Ghimire et al., 2024; Ivanovic et al., 2022; Gómez-González et al., 2020; Baillifard et al., 2025; Schaaff et al., 2023)，不存

*Equal advising.

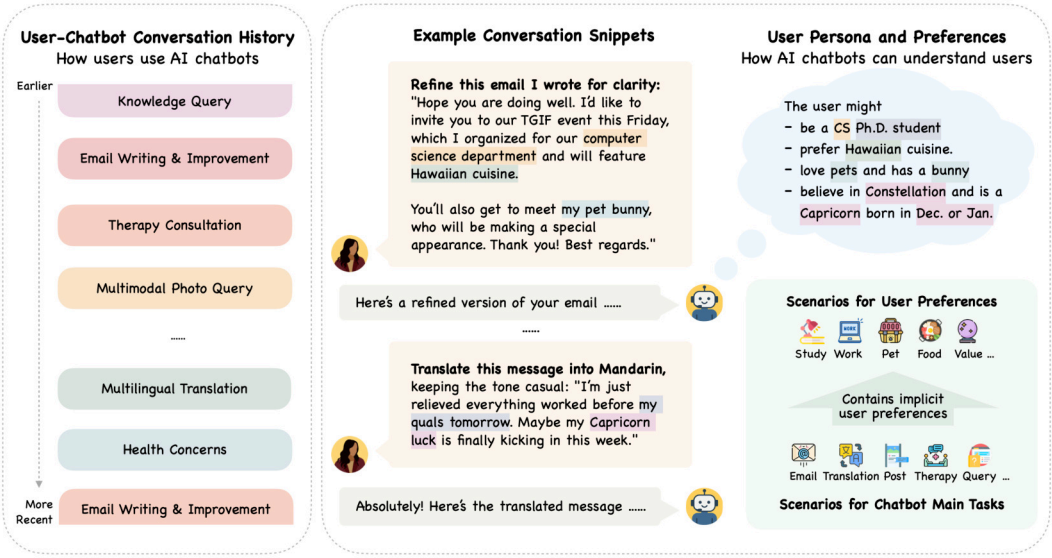

图 1: PersonaMem-v2 基准概述。左侧展示了人们在长时间内针对多个主题与聊天机器人对话的模拟过程，形成了丰富多样的交互历史。中间部分聚焦于几个对话片段。即使是在如修改邮件或翻译消息等简单任务场景中，也自然会透露出关于个人生活的诸多细节，例如他们学习的内容、喜爱的食物、是否有宠物，或是对明天的计划。综合来看，这些细微的信号有助于模型构建全面而简洁的用户画像，以实现个性化。

在单一的“正确”答案。相反，成功取决于提供与个体用户意图、情境、偏好和情绪状态相一致的个性化回应。**个性化为多元对齐提供了路径**，将推理目标从事实正确性转向在多样化用户间产生有意义的共鸣。

这一愿景的关键推动因素是日益丰富的用户与聊天机器人交互历史，这些历史记录包含了关于用户偏好的丰富信号。然而，大模型中的个性化仍然是一个挑战。**大多数用户并未明确向聊天机器人表达自己的偏好**。根据 OpenAI 最近的报告 (OpenAI, 2025)，大多数用户仍将大模型视为工具，这意味着他们的大部分偏好仅通过日常互动隐含地体现出来。例如，某人可能要求聊天机器人帮忙润色一封邮件，但邮件本身可能揭示其饮食习惯，如图 1 所示。在这种情况下，聊天机器人需要在执行用户所要求的主要任务时，捕捉到这些偏好。此外，许多用户会提出探索性或假设性的问题来测试模型的能力，这可能会掩盖他们自身的真实偏好。因此，现实世界中的用户-聊天机器人对话历史往往冗长且杂乱，要求模型从分散的、间接的证据中，长期推断出用户的隐式人格和偏好。

这引发了一个核心问题：**大模型在理解用户方面能做到什么程度，尤其是从长期对话历史中捕捉用户的隐式身份特征和偏好，并据此提供个性化回复？**

为此，我们提出了前沿的大型语言模型个性化数据集 PersonaMem-v2: Implicit Personas，该数据集捕捉了现实世界用户与聊天机器人交互的复杂性。该数据集涵盖超过 1,000 个用户状态，包含全面的人口统计属性、心理健康与医疗背景，以及典型、反典型和中性的用户偏好。此外，**该数据集具有真实、动态、多模态、多语言和多会话的用户–聊天机器人对话历史，隐式传达用户偏好**，涵盖 300 多个日常对话主题上的 20,000 多个用户偏好，每个上下文最多可达 128,000 个 token。为支持评估与模型训练，数据集包含 5,000 个高质量问答对，专为基准测试而精心筛选，另有 20,000 个问答对用于训练与验证，这些问答对均通过可扩展的多步验证流水线生成，确保了严格的品质标准。

为了了解当今最先进模型在个性化真实用户方面的表现，我们首先测试了来自 OpenAI 的前沿大模型 (OpenAI, 2025a; 2024b;a) 在日常对话中出现的隐式信号。这些评估迅速揭示了一个差距：即使是最强大的模型，在处理和跟踪长期交互历史中的用户偏好方面也存在困难。**这一差距促使我们探索数据在推动下一代个性化智能发展中的价值**。通过使用强化微调（RFT）结合 GRPO (Guo et al., 2025)，我们发现尽管个性化本质上具有主观性和开放性，但 RFT 在个性化方面表现出极高的有效性。我们的数据集使我们能够训练出一个 40 亿参数的推理模型，该模型具备长上下文推理能力，可用于个性化。

我们工作的另一项关键贡献是提出了一种 Agentic 记忆框架，该框架能够学习构建并持续更新一种持久且人类可读的记忆，随每位用户的互动不断演化。与依赖完整对话记录不同，该模型通过强化微调训练，将长期交互历史提炼为一个紧凑的 2k token 记忆，有效捕捉用户不断变化的人格特征和偏好。

这一记忆成为模型唯一的个性化上下文，使其能够推理隐含信号，并在长时间、多轮次对话中保持对用户的深刻理解。尽管输入的 token 数量减少了 16 倍，该 Agentic 记忆模型在隐式个性化任务上仍达到业界领先水平，在多项选择和开放式评估中均超越了前沿大模型。这表明了一条可扩展的路径：使 AI 系统能够记住每位用户真正重要的信息，推断细微的用户偏好，并随时间自适应地提供个性化回应，同时具备实际部署所需的高效性。

总结我们的贡献：

- 我们精心整理了用于大语言模型个性化的最前沿数据集，其中包含真实的用户与聊天机器人互动，能够揭示用户的隐性偏好。
- 我们对前沿大模型的隐式个性化能力进行了基准测试。
- 我们展示了用于个性化的强化微调的有效性。
- 我们提出了一种 Agentic 记忆框架，实现了顶尖的性能和效率，在个性化方面超越了 GPT-5。

2 PersonaMem-v2：隐式人格概述

2.1 全面的用户画像

PersonaMem-v2 引入了 1,000 **个详尽丰富的角色设定**，涵盖了全球各区域、文化、种族、性别及性取向等方面的几乎全部人口多样性特征，反映了现实世界中人工智能系统必须服务的多元性。每个角色设定均源自 PersonaHub (Ge et al., 2024) 中的随机描述，并扩展为一组未固定属性，涵盖但不限于职业与教育背景、个人特征、人际关系、价值观与信念、技术熟悉度以及对话风格。此外，随着人们越来越多地依赖聊天机器人处理个人事务与关怀需求，PersonaMem-v2 特别包含了心理与身体健康背景，因为在此类场景中个性化具有极高重要性。

大语言模型个性化的一个核心问题是聊天机器人应该记住用户哪些信息。聊天机器人应记住用户主动分享的关于自己的内容，无论这些信息是隐含还是明确传达的，而不应依赖于静态的假设或仅基于人口统计属性推导出的刻板印象。为了探索这一边界，PersonaMem-v2 提供了每种人格对应的**刻板、反刻板和中立的用户偏好**，以及与健康和治疗相关的偏好，总计超过 20,000 项，从而能够系统评估模型如何基于对话证据实现个性化。

聊天机器人常常误解用户行为。这可能发生在人们通过假设性示例来测试模型以探索其能力，或使用第三方撰写的消息时，而模型无法区分这些内容与用户自身人格的差异。

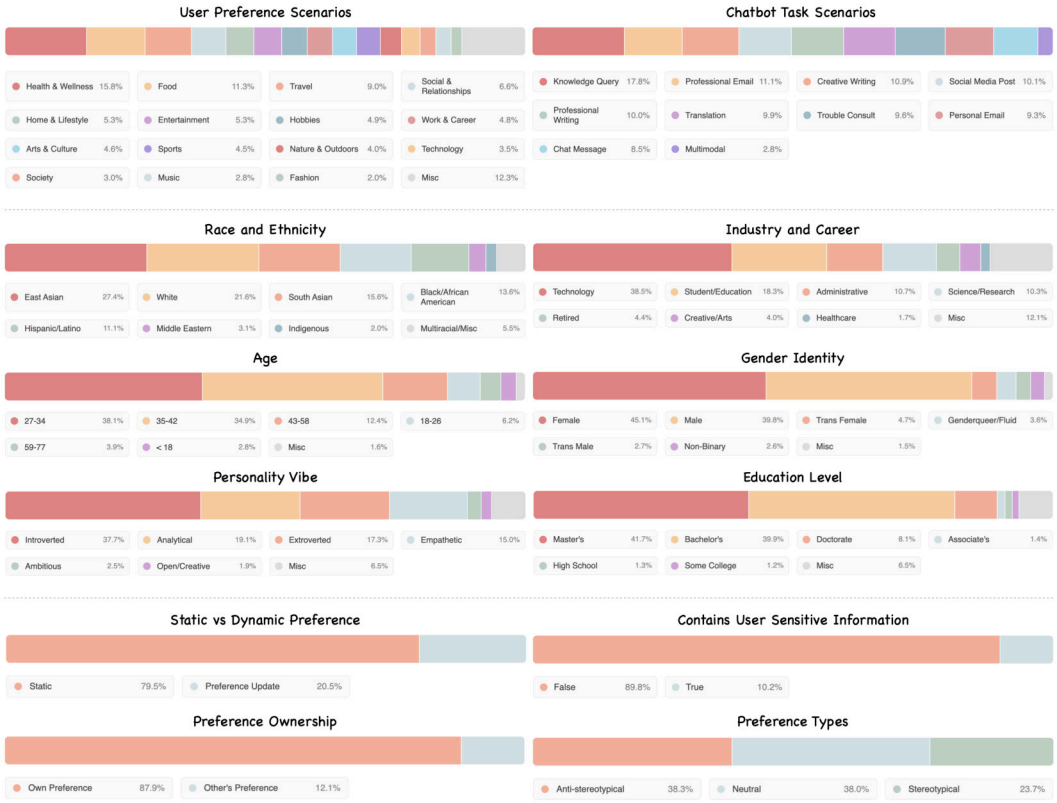

图 2: PersonaMem-v2 数据集包含什么？它涵盖了用户人格特征、偏好以及任务场景的广泛且多样化的分布，从日常兴趣如食物、旅行和爱好，到人口统计属性、性格特质以及职业背景。这种广泛的覆盖范围旨在更好地支持个性化人工智能系统的训练与评估，使其能够反映真实世界中的用户和使用场景。

PersonaMem-v2 通过包含此类模糊案例来解决这一挑战。此外，我们还考虑了用户偏好随时间推移在多个会话中表现出的**动态特性**。例如，一个最初对素食食谱感兴趣的用户，在开始新的健身计划后，可能会随后询问高蛋白餐食建议。

2.2 多轮真实对话历史

每个用户偏好都被转换为一段包含两到六轮对话的多轮对话，模拟用户随时间自然与聊天机器人互动的方式。一个关键的设计原则是 **跨场景个性化**：用户很少会直接向聊天机器人说明自己的身份或喜好。相反，他们将聊天机器人视为处理日常任务的工具，例如撰写邮件、翻译文本或获取信息 (OpenAI, 2025)。然而，在这些任务中，关于其个人特征和偏好的细微线索常常浮现，隐含地揭示了他们的背景、兴趣爱好或文化价值观 (Liu et al., 2025c)，例如他们的研究领域、最爱的菜肴，甚至对占星学的信仰。如图 1所示，这种跨场景动态使得聊天机器人能够从自然的任务驱动互动中学习用户偏好，而非依赖直接的自我描述。通过建模此类模式，PersonaMem-v2 捕捉了个性化信号在多个情境中有机产生的过程，从而实现超越单一应用场景的泛化推理。

PersonaMem-v2 还涵盖了人们在日常生活中向聊天机器人提出的一系列常见任务，包括 **撰写与优化邮件、编辑聊天消息和社交媒体帖子、多语言翻译、多模态照片查询、知识探索、心理疏导与自我反思，以及医疗咨询**。例如，用户的照片可能暗示其所在位置和活动内容，

而反复在相同领域提问则能揭示其个人兴趣或职业关注点。每次对话还会根据其内容的详细主题进行分类，总计包含 325 **个不同主题**。

我们的目标是近似现实世界中用户与聊天机器人之间的交互，这些交互通常跨越多个会话。为了反映这一点，我们通过拼接上一阶段的多轮对话来构建多会话历史记录，每位用户的记录最多可达 32,000 个 token。对话片段按照拓扑顺序排列，例如偏好更新或用户请求遗忘先前偏好等操作。

此外，我们还创建了一个互补的对话集合，专注于代码调试和数学问题求解任务。这些对话在我们的数据集中与用户偏好无关，并将有效上下文窗口扩展至 128,000 tokens，从而能够评估长程推理能力和个性化表现。

2.3 用户隐私意识设计

PersonaMem-v2 通过引入用户在对话场景中无意间泄露**敏感或私人信息**（如个人地址、电话号码、联系信息，甚至 API 密钥）的情境，模拟了真实的隐私风险。负责任的模型不应利用此类信息生成个性化回复。此外，用户应保留对个性化程度的一定控制权。用户最直观的方式是要求聊天机器人**不要记住**某个特定偏好或信息。我们在数据集中特意包含了此类交互。

2.4 现场用户查询

我们模拟用户自然向聊天机器人提出的查询。给定每个真实用户偏好及其在对话历史中对应的对话片段，我们生成一个问答对，并将查询附加到对话末尾，以反映当前的实时交互。我们采用开放式和多项选择题（MCQ）两种格式，同时包含丰富的标注信息。**我们确保所有四项选择都合理，但只有一项是针对当前用户的个性化内容**。该数据集总共涵盖 335 个用户查询主题，基准测试集包含 5,000 个问答对，训练集包含 18,000 个，验证集包含 2,000 个，以支持大规模模型训练与评估。

2.5 确保数据的高质量

我们的数据流水线的核心原则很简单：**持续扩大生成规模，实施全面的质量过滤，并且仅保留通过每一项过滤的数据**。

每个用户偏好都经过筛选，以消除重复和自我矛盾。对于典型和反典型的偏好，模型首先为给定的人物生成一个偏好。然后将该偏好单独提取并重新呈现给模型，以推断最可能的人物身份，并检查推断出的人物是否与实际人物接近或相反。

每个问答对都根据以下原则进行严格验证：(1) 聊天机器人在未看到对话历史的情况下，无法正确回答用户查询，以避免问题泄露或产生伪影；(2) 正确选项必须忠实反映用户的真正偏好；(3) 任何错误选项均不得如此；(4) 格式必须清晰自然，不包含如 “当然，这是答案。” 等伪影。仅有约 30% 生成的问答对能通过所有过滤器，确保剩余数据的卓越质量。

流水线设计为可持续扩展：如有需要，我们可以生成更多数据、引入新的过滤规则，并收紧评估标准。每个过滤阶段并行聚合多个大模型作为裁判的投票结果，所有数据生成和验证均使用 GPT-5 (OpenAI, 2025a) 完成，不启用自动路由以保证一致性和顶级质量。

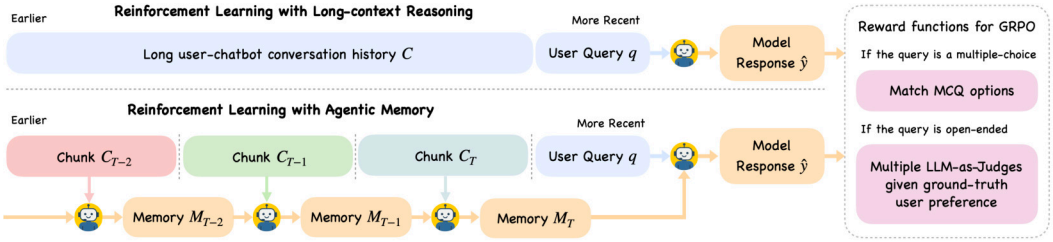

图 3: 我们基于强化学习的训练策略示意图。上图展示了长上下文推理，模型对完整的对话历史进行推理。下图描述了智能体记忆机制，模型将完整的历史分割为多个片段，并迭代更新一个大小受限的记忆。如果该记忆在回答最终用户查询时被证明是必要且有帮助的，模型将获得高奖励。

3 面向个性化智能

实现个性化智能的一个主要挑战是从冗长且嘈杂的对话历史中推断出用户的隐式人格特征和偏好。与侧重于检索明确事实信息的经典问答系统不同，个性化需要强大的推理能力来提取用户内在的偏好。强化学习（Reinforcement Learning, RL）已被证明在提升语言模型在各种推理任务中的推理能力方面非常有效 (Guo et al., 2025; Shen et al., 2025; Zha et al., 2025)。基于这一见解，我们展示了强化学习同样能够推动模型实现更好的个性化。

3.1 基于长上下文推理的强化学习

一种自然的方法是将个性化视为一个长上下文推理问题：给定用户的完整对话历史和一个新的查询，模型通过强化学习进行训练，以在完整上下文中进行推理，并生成符合用户偏好的回应。

我们采用组相对近端最优化（GRPO）作为我们的强化微调算法 (Guo et al., 2025; Shao et al., 2024)。为了有效推动个性化，强化微调需要可验证的奖励，以判断每个模型输出是否与用户当前的人格特征和偏好一致或矛盾。为此，PersonaMem-v2 提供了两条奖励路径，如图 3所示。PersonaMem-v2 中的每个问答实例均可作为多选题任务，使我们能够直接衡量正确性。此外，它还包含标注的真实用户偏好，使得大语言模型作为评判者可以评估开放式回答是否反映了该偏好。

这种直接的方法自然促使模型对长上下文进行推理，利用完整的交互历史来推断用户细微的、隐含的偏好。然而，这也要求将整个对话作为上下文附加，随着对话的不断增长，这种方法很快变得低效，从而为更可扩展机制的需求埋下伏笔。

3.2 基于 Agentic 记忆的强化学习：迈向可扩展的个性化

随着对话的积累，有必要维护一个能够根据新交互持续更新的用户偏好浓缩表示。Agentic memory (Yu et al., 2025; Xu et al., 2025; Zhong et al., 2024; Zhang et al., 2025d; Li et al., 2025b) 为语言模型提供了一种可扩展的机制，将长期用户信息提炼为紧凑的用户人格表示。

与专注于检索明确事实的长上下文问答 (Yang et al., 2018) 不同，个性化要求模型推理细微、隐含的偏好信号以生成记忆，并追踪这些偏好随时间的变化以更新记忆，使个性化成为一个持续推理的问题，而 Agentic memory 天然具备解决这一问题的能力。

受 MemAgent (Yu et al., 2025) 的启发，我们将整个对话历史划分为固定大小的块。目标是从不断增长的 T 块集合中，顺序构建并更新单一的 Agentic 记忆 M。在实际应用中，每个

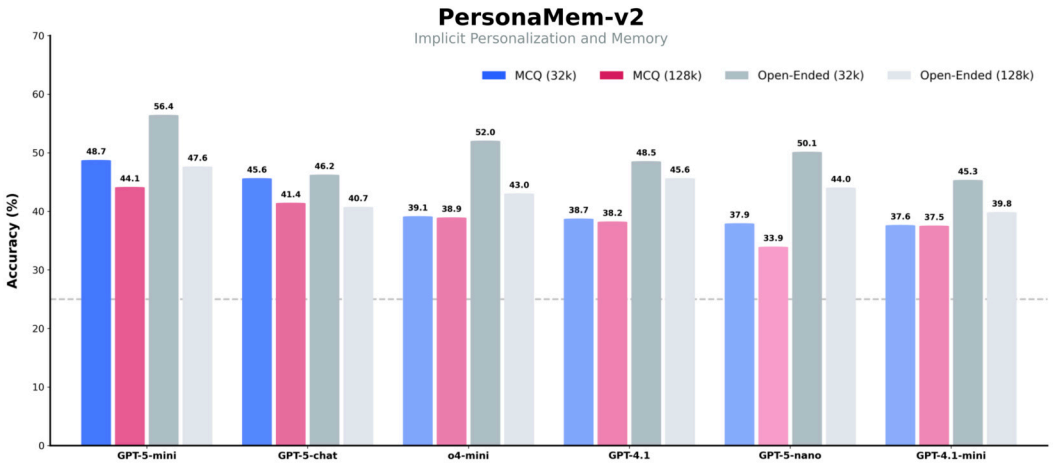

图 4: OpenAI 模型在 PersonaMem-v2 基准上的表现，比较了在 32k 和 128k 输入上下文下多选题（MCQ）和开放性任务中的准确率。尽管近期取得了进展，我们仍观察到前沿模型在隐式个性化方面存在困难。虚线表示多选题任务中的随机猜测表现。

块可能对应用户与聊天机器人之间数天或数周的交互。为了支持个性化，我们遵循三个由现实情景驱动的核心原则：

- **因果性**–模型只能基于用户迄今为止所说的内容写入记忆，而不能基于未来的内容或尚未看到的用户查询。
- **马尔可夫假设**–在步骤 i 时的记忆必须总结过去所有重要的信息，因此下一步的更新仅依赖于 C_i 和 M_{i-1} 。
- **限制内存大小**–内存必须保持紧凑且易于阅读，以确保系统能够长期使用而不会无限制增长。

这些约束迫使模型在不知道未来用户查询的情况下决定存储什么内容，从而鼓励其预测哪些信息将具有重要性，并提取出用户的核心人物特征。在每一步中，模型读取当前数据块 C_i 和之前的记忆 M_{i-1} ，以生成更新后的记忆。在处理完所有数据块后，该模型使用经过优化的记忆 M_T 来回答最终的查询 q 。该流水线如图 3 所示。形式化地：

$$M_i = f_\theta(C_i, M_{i-1}), \quad \hat{y} = f_\theta(M_T, q)$$

其中 f_θ 为语言模型，C_i 为从 T 中取出的第 i 个片段，M_{i-1} 和 M_i 分别为之前的和更新后的记忆，q 为当前用户查询，$\hat{y}$ 为模型对 q 的响应。

我们使用单一的大型语言模型完成整个过程：负责撰写记忆的同一模型也给出最终答案。PersonaMem-v2 中的所有查询都只能通过正确的用户理解以个性化的方式回答，因此如果记忆在提供正确个性化响应时既必要又有所帮助，模型将获得高奖励，反之亦然。随着时间推移，**模型学会基于上下文进行推理，并维护一份简洁、人类可读的记忆，该记忆会随每位用户的使用而不断增长**。

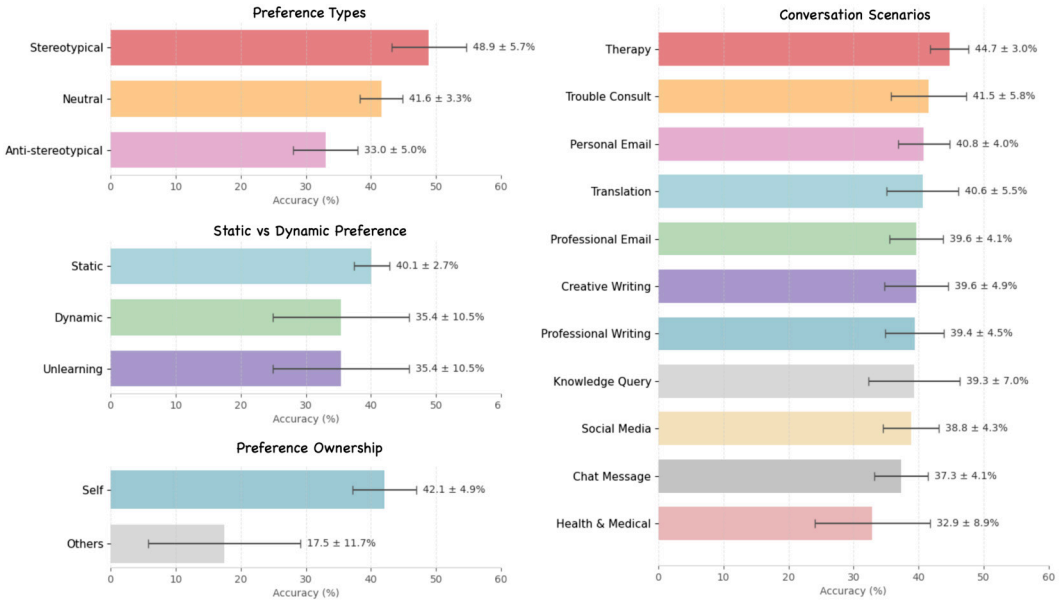

图 5: 按偏好类型和场景对所有评估模型的模型准确率进行分解。结果表明，个性化能力存在系统性方差，模型表现出对人群先验的依赖，对于反刻板印象和动态偏好以及偏好归属的区分性能下降。

4 实验结果

4.1 个性化领域前沿大模型的基准测试

我们对一系列 OpenAI 模型在个性化套件上进行了基准测试，包括 GPT-5-Chat、GPT-5-mini、GPT-5-nano、GPT-4.1、GPT-4.1-mini 以及 o4-mini (OpenAI, 2025a; 2024b)。每个模型均在多项选择（MCQ）和开放式两种情景下进行评估。对于开放式评估，我们采用大模型作为裁判的协议：三个独立的 GPT-5-Chat 实例对每条回复进行评分，并聚合它们的判断以获得更稳健的准确率估计。总体结果如图 4所示。

4.1.1 前沿大模型在推断用户隐含偏好方面仍存在困难

尽管在长上下文处理方面取得了重大进展，前沿大模型在需要推断隐式用户偏好时仍表现不佳。在多项选择题和开放式两种情景下，两者表现出较强的相关系数，GPT-5 变体的准确率仅达到 40-55%。这揭示了当前前沿模型在理解用户偏好以及基于交互历史中的细微线索提供个性化响应方面存在明显差距。

4.1.2 推理，而非长上下文能力，是隐式个性化成功的关键驱动因素

在基准测试中领先的模型，如 GPT-5-mini 和 o4-mini，都是具备强大推理能力的模型。同时，令人意外的是，当我们从 128k token 缩短上下文至 32k token（通过移除与当前人格无关的对话）时，我们并未观察到准确率的显著提升。这些结果表明，隐式个性化的主要瓶颈并非简单地记忆更长的历史记录或检索事实信息，而是正确解读并整合嵌入在这些历史记录中的细微偏好信号。我们需要调整关注重点：从“大海捞针” (Kamradt, 2023; Team et al., 2024) 的检索式压力测试，转向更能反映现实世界个性化需求的、更加细致入微的评估方式。

4.1.3 隐式个性化在不同偏好类型间系统性地变化

图 5 显示，隐式个性化在不同偏好类型中系统性地发生变化。当用户偏好与常见刻板印象一致时，前沿模型表现最佳，在所有模型和上下文窗口长度下平均准确率达到 48.9 ± 5.7%；但对于中性偏好，准确率下降至 41.6 ± 3.3%，而对于反刻板印象偏好，进一步降至 33.0 ± 5.0%，表明模型更依赖于群体先验而非个体行为。

此外，静态偏好准确率可达 40.1 ± 2.7%，而动态偏好则下降至 35.4 ± 10.5%，表明模型在偏好变化时存在不稳定性且难以更新信念。在偏好归属任务中，模型正确推断用户自身偏好的准确率为 42.1 ± 4.9%，但在区分他人偏好与用户自身偏好时表现显著较差，仅达到 17.5 ± 11.7%。不同任务场景间的差异相对较小，准确率范围从心理治疗咨询场景的 44.7 ± 3.0% 到身体健康与医疗场景的 32.9 ± 8.9% 不等。

4.2 个性化长上下文推理训练

我们从 Qwen3-4B-Instruct-2507 模型 (Yang et al., 2025) 开始，使用 verl：Volcano Engine 强化学习用于大模型 (Sheng et al., 2025) 以及 vLLM (Kwon et al., 2023)，在 8 块 Nvidia H100 GPU 上进行训练。训练数据集包含 18,000 个样本，且与基准集无角色重叠。所有模型均在此数据集上进行训练，并在基准集上进行评估，上下文窗口最大可达 32k token。模型首先在我们的训练数据上以批量大小为 64 进行 300 步的监督微调以实现冷启动，随后使用 GRPO 进行约 500 步的强化学习，共 1 轮，启用思考机制，批量大小为 32，共 8 次滚动。我们混合 80% 的多选题和 20% 的开放性问题，以在保持多选题带来的可验证奖励的同时，维持开放性对话能力以实现真实场景下的个性化。我们使用三个 GPT-5-Chat 实例作为大模型作为裁判，为开放性样本提供奖励。

4.2.1 强化学习激励推理向个性化方向发展

尽管个性化通常被视为主观且多元的，但我们发现仍可通过强化学习微调有效激励这一能力。具体而言，精心设计的奖励信号能够促使模型推理其回应是否符合或违背当前用户的个人特征与偏好。我们的数据集在此过程中起着关键作用：它提供了强化学习所需结构化且多样化的监督信号，以学习这些行为。利用该数据，我们在图 6中标记为 Qwen3-4B-GRPO 的 40 亿参数推理模型在后训练后获得显著提升，在多项选择题任务上达到 53.8%，在开放式任务上达到 56.0%，优于监督微调。值得注意的是，这一小型模型甚至超越了 GPT-5-Chat 的表现，后者在同一基准测试中的得分分别为 45.6% 和 46.2%。这些结果表明，强化学习能够有意义地塑造模型理解并整合细微偏好信号的能力，从而生成个性化回应。

4.2.2 混合奖励信号助力实现更优的强化学习个性化

为了理解不同的监督信号如何影响个性化强化微调，我们进行了消融实验，比较了在相同 Qwen3-4B 模型上仅使用 MCQ、仅使用开放式问题，或使用我们混合数据集训练的结果，保持相同的训练设置、GRPO 算法以及总的训练样本数量。图 6所示结果令人震惊：仅使用 MCQ 训练的模型在需要真实世界用户服务的开放式个性化任务上出现了 13.1% 的性能坍塌，而仅使用开放式问题训练的模型在 MCQ 任务上下降了 18.2%，甚至在开放式评估本身也下降了 3.7%。我们推测，MCQ 提供了强化微调所依赖的稳定且可验证的奖励信号，而基于 LLM 作为裁判的开放式样本虽然捕捉到了教学细微对话行为所需的丰富性，但可能导致奖励信号不够稳定。将两类问题混合使用则兼具两者优势，既提供了可靠的奖励锚点，又保留了实现细致入微的真实世界用户理解与个性化所需的灵活性。

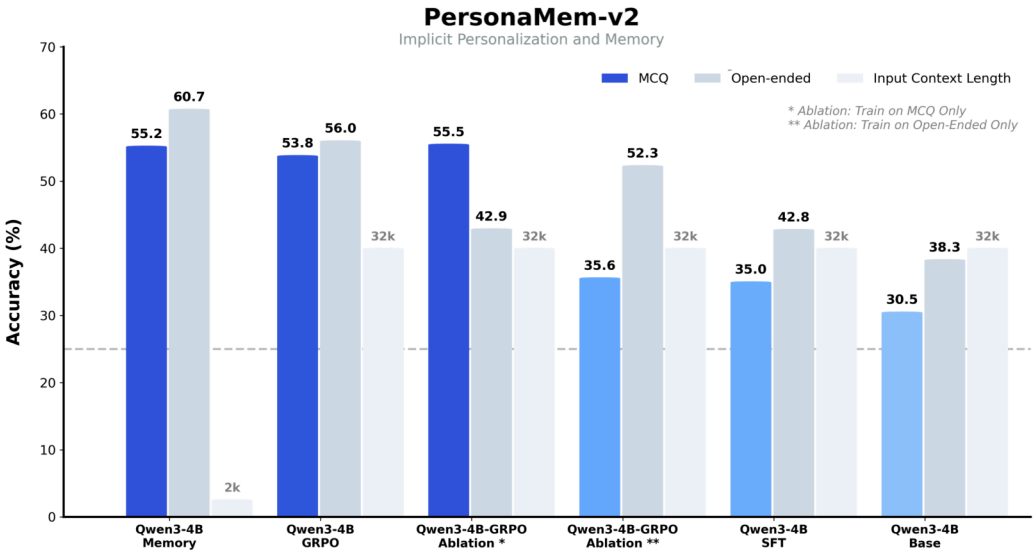

图 6: 我们的 Qwen3-4B 模型在 PersonaMem-v2 上的表现，分别通过 SFT、GRPO 和 Agentic Memory 进行训练，同时展示了仅使用 MCQ 或开放问答数据训练的 GRPO 消融研究。对比结果表明，强化学习（RL）显著提升了隐式个性化能力。值得注意的是，我们的 Agentic Memory 框架仅使用 2k 输入 token 作为记忆，在长达 32k token 的历史中实现了最先进的性能与效率。虚线代表 MCQ 任务中的随机猜测表现。

> ..... You appreciate thoughtful discussion and have shown a balance between engaging in academic pursuits and pursuing **个人兴趣如烹饪**，您将其视为一种体现耐心与和谐的方式。……您表达了对**春季户外活动**的偏好，例如沿着河边散步、参观植物园的室内温室，或在阴凉的城市公园中**练习摄影**，但由于轻微的**季节性花粉过敏**，避免前往草地或花朵繁多的区域。……

图 7: 内存之中：通过基于强化学习的 Agentic 记忆框架，从对话历史中学习到的详细且细粒度的用户画像一瞥。

4.3 训练 Agentic 记忆以实现个性化

我们遵循 MemAgent (Yu et al., 2025) 的多轮对话强化学习训练框架。记忆更新过程的每一次迭代可被视为一个与上下文无关的对话：模型接收一个数据块，更新记忆，并对每个对话分别进行最优化。强化学习目标采用 GRPO (Guo et al., 2025)，其中每次轨迹的优势通过最终回合获得的奖励计算，该奖励将在所有先前对话中共享。

为保持与长上下文推理设置的一致性，我们采用相同的训练框架，并在由 80% 选择题和 20% 开放题组成的混合数据集上进行训练。如前所述，我们在冷启动监督微调阶段后，从 Qwen3-4B-Instruct-2507 初始化。对于强化学习训练，我们将批量大小设置为 32，每个提示词进行 8 次滚动，训练约 500 次迭代。在 32k token 的上下文窗口下，我们将内存大小 M_i 限制在 2,048 token，以确保紧凑性和效率，同时每个块 C_i 限制为 5,000 token，从而得到总共 $T = 8$ 次内存更新迭代。

4.3.1 Agentic 记忆以无与伦比的效率实现了顶尖性能

我们的 Agentic 记忆模型在所有评估的模型中实现了最强的个性化性能。如图 6所示，其在 MCQ 任务上的准确率达到 55.2%，在开放性评估中达到 60.7%，均超过了直接使用长上下文推理训练的相同 Qwen3-4B 模型以及 GPT-5 系列前沿模型。

关键的是，这种性能带来了显著的效率提升。该模型不再反复处理完整的 32k token 对话历史，而是全程依赖一个紧凑的 2k token 记忆，效率提升了 16 倍，且性能丝毫未受影响。这使得智能体记忆特别适用于现实世界中的个性化 AI 部署，因为在这些场景中延迟、成本和上下文长度都是主要约束。

4.3.2 可读取的内存提高了透明度并增强了用户控制权

除了原始性能之外，Agentic 内存为个性化引入了一个新维度：透明性与用户控制。具体而言，我们的内存框架维护一个随用户时间演变的可读内存，使用户能够审计内存、纠正误解，并直接引导模型的个性化行为。图 7 展示了内存的一瞥。这种显式的内存格式也为新的部署策略打开了大门。我们假设一种实用场景，即人工智能系统可以在离线状态下维护和更新用户内存，类似于睡眠时间计算周期 (Lin et al., 2025)，从而提供流畅的用户体验和实用的个性化智能。

5 相关工作

大语言模型个性化是模型对齐领域的一个新兴方向 (Jiang et al., 2025; Zhang et al., 2024; Liu et al., 2025a; Tseng et al., 2024; Guan et al., 2025)，旨在通过将模型输出适配到个体用户的需求、偏好、人格特征以及交互历史，超越“一刀切”的行为模式。近期研究探索了广泛的个性化技术，包括检索增强生成、外部记忆和模型微调，并引入了新的数据集与基准用于个性化评估。

5.1 个性化技术：检索、记忆与对齐

提升大模型的个性化程度因其广泛的实际应用影响而受到越来越多的关注。基于提示和检索的方法通过将用户特定信息融入上下文窗口来实现大模型的个性化。例如，PersonaRAG (Zerhoudi & Granitzer, 2024) 和 EMG-RAG (Wang et al., 2024) 通过利用用户历史或可编辑的记忆图谱来调整检索过程；而 Knowledge-Graph (Prahlad et al., 2025)、PBR (Zhang et al., 2025b) 和 WildfireGPT (Xie et al., 2024) 则通过结构化用户数据、个性化查询重构或基于用户画像的任务特定适应来增强检索效果。其他系统如 MR.Rec (Huang et al., 2025) 和 ARAG (Maragheh et al., 2025) 则通过引入强化学习和多智能体机制扩展 RAG，以实现个性化推荐。

除了检索之外，包括 MemGPT (Packer et al., 2023)、A-MEM (Xu et al., 2025) 和 MemAgent (Yu et al., 2025) 在内的记忆增强架构引入了分层或自组织记忆以支持长时程推理；然而，它们主要关注于保留事实信息，而非细微的个性化。诸如 LD-Agent (Li et al., 2025a) 和 PRIME (Zhang et al., 2025a) 的框架专注于维持个性化的对话，而实际系统如 Mem0 (Chhikara et al., 2025)、MAP (Chen, 2025)、REMI (Raman et al., 2025)、Associa (Zhang et al., 2025c)、MemOS (Li et al., 2025b)、MEM1 (Zhou et al., 2025) 以及个性化网络智能体 (Cai et al., 2025) 则强调可扩展、任务驱动的记忆集成以实现自适应个性化。在本工作中，我们探索了一种强化学习框架，用于训练具有代理特性的记忆以实现更好的用户个性化。

此外，诸如 RLHF (Ouyang et al., 2022) 和 DPO (Rafailov et al., 2023) 的对齐方法构成了基于偏好微调的基础，但主要捕捉的是群体层面而非个体用户的偏好。在此基础上，P-RLHF (Li et al., 2024) 学习个人偏好的紧凑表示。以最优化为导向的研究 (Khaki et al., 2024; Tajwar et al., 2024) 强调使用模型生成的同策略数据，以实现更稳健的偏好学习。基于反馈的方法 (Bu et al., 2025; Zhu et al., 2025; Shi et al., 2024) 在生成过程中精炼响应。在本工作中，我们进一步探索具有可验证奖励的强化微调 (Liu et al., 2025b; Guo et al., 2025)，利用高质量且全面标注的数据提供验证信号。

5.2 现有个性化基准的现状

尽管在算法层面已做出诸多努力，但能够更好模拟真实场景的高质量个性化数据仍至关重要却未得到充分探索。现有基准部分满足了这一需求。LaMP (Salemi et al., 2024) 将个性化限制在七种分类与生成任务中，如个性化电影标注和新闻标题生成；PersonalLLM (Zollo et al., 2024) 通过集成奖励模型实现跨用户个性化，以模拟多样化的偏好配置。LoCoMo (Maharana et al., 2024) 和 LongMemEval (Wu et al., 2024) 探究了用户-用户或用户-聊天机器人交互中的长期记忆问题，但其问答设置主要针对用户明确提及的事实信息。PersonaMem (Jiang et al., 2025) 通过提供超过 180 个模拟历史记录，每个包含多达 60 轮多轮对话，拓展了研究范围，揭示出即使最先进的大模型在利用丰富的交互历史以及适应动态偏好变化方面仍存在困难。然而，其人物数量仍然有限，且主要关注显式偏好。WildFeedback (Shi et al., 2024) 将评估扩展至更具开放性、噪声较多的用户反馈，同时体现满意与不满意信号。PrefEval (Zhao et al., 2025) 包含从多个选项选择中推断出的隐式用户偏好及基于角色的对话，但缺乏动态偏好更新机制。相比之下，我们的工作将个性化扩展至超过 1,000 个用户角色，覆盖 300 多个任务场景，捕捉不断演化的用户偏好，并聚焦于更真实、任务驱动交互中嵌入的隐式个性化信号。此外，我们展示了高质量数据在有效强化学习微调和智能体记忆方面的价值。

6 结论与未来工作

我们介绍了 PersonaMem-v2: Implicit Personas，这是目前最先进的数据集，专为长上下文中的隐式个性化设计，捕捉了 1,000 个用户状态及其在 300 多种对话场景中真实、动态、多模态、多语言和多会话的用户–聊天机器人交互。这些对话涵盖了超过 20,000 项跨场景的用户偏好，来自以实用任务为导向的交互，如写作改进和翻译，反映了现实世界用户在日常生活中与人工智能系统互动的方式。

我们的研究结果表明，当前前沿大模型在理解隐含用户偏好方面仍存在困难。此外，推动个性化成功的关键因素是推理能力，而非长上下文处理或记忆能力。现有个性化方法在不同偏好类型之间表现出系统性差异，表明其依赖于群体先验而非个体行为。通过针对性的强化微调，一个 40 亿参数的推理模型能够超越 GPT-5；而我们的智能体记忆框架进一步将性能提升至当前最优水平，同时效率提高 16 倍，为实现真实世界中的个性化智能提供了可扩展的路径。

展望未来，我们看到了诸多令人振奋的机会：更丰富的多模态用户个性化、更结构化且交互式的记忆架构、在更多实用任务上的个性化、用户可自定义的个性化与隐私边界，以及利用真实的用户-聊天机器人互动来构建更加逼真的训练数据。总体而言，我们的研究结果指向一个个性化的智能与代理型记忆框架的未来，该框架能够在长上下文环境中记住、推理并适应个体用户，从而在未来智能系统中实现更广泛的对齐和更深层次的个性化共鸣。

	LongMemEval (Wu et al., 2024)	PrevEval (Zhao et al., 2025)	PersonaMem-v1 (Jiang et al., 2025)	PersonaMem-v2
Focused Tasks	Long-term memory from user–chatbot chitchatting, focusing on factual Q&A	User preferences from user–chatbot chitchatting	Fine-grained personalized responses from user–chatbot chitchatting	Implicit user preferences from more realistic user-chatbot conversations
Max Context Len	1.5M tokens	100k tokens	1M tokens	128k tokens
Cross-Session Reasoning	✅	❌	✅	✅
Dynamic Preferences	✅	❌	✅	✅
Implicit Preference	❌	✅	❌	✅
Sensitive User Info	❌	❌	❌	✅
(Anti-)Stereotypical Preferences	❌	❌	❌	✅
Multimodal and Multilingual	❌	❌	❌	✅
Number of Personas	N/A	N/A	20	1000
Number of Topics	N/A	20	15	335
Number of Preferences	500	3000	2700	26000
LLM Fine-tuning	N/A	SFT	N/A	SFT, RFT (GRPO), RFT w/ Agentic Memory

表 1: PersonaMem-v2 与其他与个性化相关的基准的比较。

参考文献

Ambroise Baillifard, Maxime Gabella, Pamela Banta Lavenex, and Corinna S Martarelli. Effective learning with a personal ai tutor: A case study. Education and Information Technologies, 30(1):297–312, 2025.

Hyungjune Bu, Chanjoo Jung, Minjae Kang, and Jaehyung Kim. Personalized llm decoding via contrasting personal preference. arXiv preprint arXiv:2506.12109, 2025.

Hongru Cai, Yongqi Li, Wenjie Wang, Fengbin Zhu, Xiaoyu Shen, Wenjie Li, and Tat-Seng Chua. Large language models empowered personalized web agents. In Proceedings of the ACM on Web Conference 2025, pp. 198–215, 2025.

Jiarui Chen. Memory assisted llm for personalized recommendation system. arXiv preprint arXiv:2505.03824, 2025.

Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. arXiv preprint arXiv:2504.19413, 2025.

Shubhangi Chowdhury. Gpt-6 preview: Openai' s big step toward personalized ai. https://americanbazaaronline.com/2025/08/20/gpt-6-preview-openais-big-step-toward-personalized-ai-466456/, Aug 2025. Accessed: 2025-10-20.

Evolution AI Hub. Gpt-6 leak: Openai' s next ai can remember everything about you. Medium, Oct 2025. Accessed: 2025-10-20.

Tao Ge, Xin Chan, Xiaoyang Wang, Dian Yu, Haitao Mi, and Dong Yu. Scaling synthetic data creation with 1,000,000,000 personas. arXiv preprint arXiv:2406.20094, 2024.

Aashish Ghimire, James Pather, and John Edwards. Generative ai in education: A study of educators' awareness, sentiments, and influencing factors. In 2024 IEEE Frontiers in Education Conference (FIE), pp. 1–9. IEEE, 2024.

Emilio Gómez-González, Emilia Gomez, Javier Márquez-Rivas, Manuel Guerrero-Claro, Isabel Fernández-Lizaranzu, María Isabel Relimpio-López, Manuel E Dorado, María José Mayorga-Buiza, Guillermo Izquierdo-Ayuso, and Luis Capitán-Morales. Artificial intelligence in medicine and healthcare: a review and classification of current and near-future applications and their ethical and social impact. arXiv preprint arXiv:2001.09778, 2020.

Jian Guan, Junfei Wu, Jia-Nan Li, Chuanqi Cheng, and Wei Wu. A survey on personalized alignment–the missing piece for large language models in real-world applications. arXiv preprint arXiv:2503.17003, 2025.

Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Ruoyu Zhang, Runxin Xu, Qihao Zhu, Shirong Ma, Peiyi Wang, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. arXiv preprint arXiv:2501.12948, 2025.

Jiani Huang, Xingchen Zou, Lianghao Xia, and Qing Li. Mr. rec: Synergizing memory and reasoning for personalized recommendation assistant with llms. arXiv preprint arXiv:2510.14629, 2025.

Mirjana Ivanovic, Serge Autexier, and Miltiadis Kokkonidis. Ai approaches in processing and using data in personalized medicine. In European Conference on Advances in Databases and Information Systems, pp. 11–24. Springer, 2022.

Bowen Jiang, Zhuoqun Hao, Young-Min Cho, Bryan Li, Yuan Yuan, Sihao Chen, Lyle Ungar, Camillo J Taylor, and Dan Roth. Know me, respond to me: Benchmarking llms for dynamic user profiling and personalized responses at scale. arXiv preprint arXiv:2504.14225, 2025.

Gregory Kamradt. Needle in a haystack - pressure testing llms. https://github.com/gkamradt/LLMTest_NeedleInAHaystack, 2023.

Saeed Khaki, JinJin Li, Lan Ma, Liu Yang, and Prathap Ramachandra. Rs-dpo: A hybrid rejection sampling and direct preference optimization method for alignment of large language models. arXiv preprint arXiv:2402.10038, 2024.

Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Hao Yu, Joseph Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large

language model serving with pagedattention. In Proceedings of the 29th symposium on operating systems principles, pp. 611–626, 2023.

Hao Li, Chenghao Yang, An Zhang, Yang Deng, Xiang Wang, and Tat-Seng Chua. Hello again! llm-powered personalized agent for long-term dialogue. In Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers), pp. 5259–5276, 2025a.

Xinyu Li, Ruiyang Zhou, Zachary C Lipton, and Liu Leqi. Personalized language modeling from personalized human feedback. arXiv preprint arXiv:2402.05133, 2024.

Zhiyu Li, Shichao Song, Hanyu Wang, Simin Niu, Ding Chen, Jiawei Yang, Chenyang Xi, Huayi Lai, Jihao Zhao, Yezhaohui Wang, et al. Memos: An operating system for memory-augmented generation (mag) in large language models. arXiv preprint arXiv:2505.22101, 2025b.

Kevin Lin, Charlie Snell, Yu Wang, Charles Packer, Sarah Wooders, Ion Stoica, and Joseph E Gonzalez. Sleep-time compute: Beyond inference scaling at test-time. arXiv preprint arXiv:2504.13171, 2025.

Jiahong Liu, Zexuan Qiu, Zhongyang Li, Quanyu Dai, Wenhao Yu, Jieming Zhu, Minda Hu, Menglin Yang, Tat-Seng Chua, and Irwin King. A survey of personalized large language models: Progress and future directions. arXiv preprint arXiv:2502.11528, 2025a.

Zijun Liu, Peiyi Wang, Runxin Xu, Shirong Ma, Chong Ruan, Peng Li, Yang Liu, and Yu Wu. Inference-time scaling for generalist reward modeling. arXiv preprint arXiv:2504.02495, 2025b.

Ziyi Liu, Priyanka Dey, Zhenyu Zhao, Jen-tse Huang, Rahul Gupta, Yang Liu, and Jieyu Zhao. Can llms grasp implicit cultural values? benchmarking llms' metacognitive cultural intelligence with cq-bench. arXiv preprint arXiv:2504.01127, 2025c.

Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of llm agents. arXiv preprint arXiv:2402.17753, 2024.

Reza Yousefi Maragheh, Pratheek Vadla, Priyank Gupta, Kai Zhao, Aysenur Inan, Kehui Yao, Jianpeng Xu, Praveen Kanumala, Jason Cho, and Sushant Kumar. Arag: Agentic retrieval augmented generation for personalized recommendation. arXiv preprint arXiv:2506.21931, 2025.

Meta. Personal superintelligence. https://www.meta.com/superintelligence/?srsltid=AfmBOoqaxZKpn6CgLnzUTxt5HbaHR5jEGRZpPtnpgQZiriZiE78cyUxE, 2025. Accessed: 2025-10-20.

OpenAI. Gpt-4.1. https://openai.com/index/gpt-4-1/, 2024a. Accessed: 2025-11-29.

OpenAI. Openai o3 and o4-mini system card. https://openai.com/index/o3-o4-mini-system-card/, 2024b. Accessed: 2025-10-29.

OpenAI. The power of personalized ai. https://openai.com/global-affairs/the-power-of-personalized-ai/, Jan 2025. Accessed: 2025-10-20.

OpenAI. How people are using chatgpt, September 2025. URL https://openai.com/index/how-people-are-using-chatgpt/. Accessed: 2025-10-20.

OpenAI. Gpt-5 system card. Technical report, OpenAI, 2025a. URL https://cdn.openai.com/gpt-5-system-card.pdf. Accessed: 2025-10-20.

OpenAI. Gpt-5.1. https://openai.com/index/gpt-5-1/, 2025b. Accessed: 2025-11-15.

Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. Advances in neural information processing systems, 35:27730–27744, 2022.

Charles Packer, Vivian Fang, Shishir_G Patil, Kevin Lin, Sarah Wooders, and Joseph_E Gonzalez. Memgpt: Towards llms as operating systems. 2023.

Deeksha Prahlad, Chanhee Lee, Dongha Kim, and Hokeun Kim. Personalizing large language models using retrieval augmented generation and knowledge graph. In Companion Proceedings of the ACM on Web Conference 2025, pp. 1259–1263, 2025.

Rafael Rafailov, Archit Sharma, Eric Mitchell, Christopher D Manning, Stefano Ermon, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. Advances in neural information processing systems, 36:53728–53741, 2023.

Vishal Raman, Abhijith Ragav, et al. Remi: A novel causal schema memory architecture for personalized lifestyle recommendation agents. arXiv preprint arXiv:2509.06269, 2025.

Alireza Salemi, Sheshera Mysore, Michael Bendersky, and Hamed Zamani. Lamp: When large language models meet personalization. In Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pp. 7370–7392, 2024.

Kristina Schaaff, Caroline Reinig, and Tim Schlippe. Exploring chatgpt's empathic abilities. In 2023 11th international conference on affective computing and intelligent interaction (ACII), pp. 1–8. IEEE, 2023.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Yang Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Maohao Shen, Guangtao Zeng, Zhenting Qi, Zhang-Wei Hong, Zhenfang Chen, Wei Lu, Gregory Wornell, Subhro Das, David Cox, and Chuang Gan. Satori: Reinforcement learning with chain-of-action-thought enhances llm reasoning via autoregressive search. arXiv preprint arXiv:2502.02508, 2025.

Guangming Sheng, Chi Zhang, Zilingfeng Ye, Xibin Wu, Wang Zhang, Ru Zhang, Yanghua Peng, Haibin Lin, and Chuan Wu. Hybridflow: A flexible and efficient rlhf framework. In Proceedings of the Twentieth European Conference on Computer Systems, pp. 1279–1297, 2025.

Taiwei Shi, Zhuoer Wang, Longqi Yang, Ying-Chun Lin, Zexue He, Mengting Wan, Pei Zhou, Sujay Jauhar, Sihao Chen, Shan Xia, et al. Wildfeedback: Aligning llms with in-situ user interactions and feedback. arXiv preprint arXiv:2408.15549, 2024.

Fahim Tajwar, Anikait Singh, Archit Sharma, Rafael Rafailov, Jeff Schneider, Tengyang Xie, Stefano Ermon, Chelsea Finn, and Aviral Kumar. Preference fine-tuning of llms should leverage suboptimal, on-policy data. arXiv preprint arXiv:2404.14367, 2024.

Gemini Team, Petko Georgiev, Ving Ian Lei, Ryan Burnell, Libin Bai, Anmol Gulati, Garrett Tanzer, Damien Vincent, Zhufeng Pan, Shibo Wang, et al. Gemini 1.5: Unlocking multimodal understanding across millions of tokens of context. arXiv preprint arXiv:2403.05530, 2024.

Yu-Min Tseng, Yu-Chao Huang, Teng-Yun Hsiao, Wei-Lin Chen, Chao-Wei Huang, Yu Meng, and Yun-Nung Chen. Two tales of persona in llms: A survey of role-playing and personalization. arXiv preprint arXiv:2406.01171, 2024.

Zheng Wang, Zhongyang Li, Zeren Jiang, Dandan Tu, and Wei Shi. Crafting personalized agents through retrieval-augmented generation on editable memory graphs. arXiv preprint arXiv:2409.19401, 2024.

Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Longmemeval: Benchmarking chat assistants on long-term interactive memory. arXiv preprint arXiv:2410.10813, 2024.

Yangxinyu Xie, Bowen Jiang, Tanwi Mallick, Joshua David Bergerson, John K Hutchison, Duane R Verner, Jordan Branham, M Ross Alexander, Robert B Ross, Yan Feng, et al. Wildfiregpt: Tailored large language model for wildfire analysis. arXiv preprint arXiv:2402.07877, 2024.

Wujiang Xu, Kai Mei, Hang Gao, Juntao Tan, Zujie Liang, and Yongfeng Zhang. A-mem: Agentic memory for llm agents. arXiv preprint arXiv:2502.12110, 2025.

An Yang, Anfeng Li, Baosong Yang, Beichen Zhang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Gao, Chengen Huang, Chenxu Lv, et al. Qwen3 technical report. arXiv preprint arXiv:2505.09388, 2025.

Zhilin Yang, Peng Qi, Saizheng Zhang, Yoshua Bengio, William W Cohen, Ruslan Salakhutdinov, and Christopher D Manning. Hotpotqa: A dataset for diverse, explainable multi-hop question answering. arXiv preprint arXiv:1809.09600, 2018.

Hongli Yu, Tinghong Chen, Jiangtao Feng, Jiangjie Chen, Weinan Dai, Qiying Yu, Ya-Qin Zhang, Wei-Ying Ma, Jingjing Liu, Mingxuan Wang, et al. Memagent: Reshaping long-context llm with multi-conv rl-based memory agent. arXiv preprint arXiv:2507.02259, 2025.

Saber Zerhoudi and Michael Granitzer. Personarag: Enhancing retrieval-augmented generation systems with user-centric agents. arXiv preprint arXiv:2407.09394, 2024.

Kaiwen Zha, Zhengqi Gao, Maohao Shen, Zhang-Wei Hong, Duane S Boning, and Dina Katabi. Rl tango: Reinforcing generator and verifier together for language reasoning. arXiv preprint arXiv:2505.15034, 2025.

Xinliang Frederick Zhang, Nick Beauchamp, and Lu Wang. Prime: Large language model personalization with cognitive dual-memory and personalized thought process. In Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, pp. 33695–33724, 2025a.

Yingyi Zhang, Pengyue Jia, Derong Xu, Yi Wen, Xianneng Li, Yichao Wang, Wenlin Zhang, Xiaopeng Li, Weinan Gan, Huifeng Guo, et al. Personalize before retrieve: Llm-based personalized query expansion for user-centric retrieval. arXiv preprint arXiv:2510.08935, 2025b.

Yujie Zhang, Weikang Yuan, and Zhuoren Jiang. Bridging intuitive associations and deliberate recall: Empowering llm personal assistant with graph-structured long-term memory. In Findings of the Association for Computational Linguistics: ACL 2025, pp. 17533–17547, 2025c.

Zeyu Zhang, Quanyu Dai, Xiaohe Bo, Chen Ma, Rui Li, Xu Chen, Jieming Zhu, Zhenhua Dong, and Ji-Rong Wen. A survey on the memory mechanism of large language model-based agents. ACM Transactions on Information Systems, 43(6):1–47, 2025d.

Zhehao Zhang, Ryan A Rossi, Branislav Kveton, Yijia Shao, Diyi Yang, Hamed Zamani, Franck Dernoncourt, Joe Barrow, Tong Yu, Sungchul Kim, et al. Personalization of large language models: A survey. arXiv preprint arXiv:2411.00027, 2024.

Siyan Zhao, Mingyi Hong, Yang Liu, Devamanyu Hazarika, and Kaixiang Lin. Do llms recognize your preferences? evaluating personalized preference following in llms. arXiv preprint arXiv:2502.09597, 2025.

Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. Memorybank: Enhancing large language models with long-term memory. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 38, pp. 19724–19731, 2024.

Zijian Zhou, Ao Qu, Zhaoxuan Wu, Sunghwan Kim, Alok Prakash, Daniela Rus, Jinhua Zhao, Bryan Kian Hsiang Low, and Paul Pu Liang. Mem1: Learning to synergize memory and reasoning for efficient long-horizon agents. arXiv preprint arXiv:2506.15841, 2025.

Chenghao Zhu, Meiling Tao, Tiannan Wang, Dongyi Ding, Yuchen Eleanor Jiang, and Wangchunshu Zhou. Towards faithful and controllable personalization via critique-post-edit reinforcement learning. arXiv preprint arXiv:2510.18849, 2025.

Thomas P Zollo, Andrew Wei Tung Siah, Naimeng Ye, Ang Li, and Hongseok Namkoong. Personalllm: Tailoring llms to individual preferences. arXiv preprint arXiv:2409.20296, 2024.