https://hjfy.top/arxiv/2404.13501

基于大型语言模型的智能体记忆机制调查

Zeyu Zhang[1], Xiaohe Bo[1], Chen Ma[1], Rui Li[1], Xu Chen[1], Quanyu Dai[2], Jieming Zhu[2], Zhenhua Dong[2], Ji-Rong Wen[1]
[1]Gaoling School of Artificial Intelligence, Renmin University of China, Beijing, China
[2]Huawei Noah’s Ark Lab, China
zeyuzhang@ruc.edu.cn, xu.chen@ruc.edu.cn

Abstract

基于大型语言模型（LLM）的智能体最近吸引了学术界和工业界的极大关注。与原始 LLM 相比，基于 LLM 的智能体以其自我演进的能力为特点，这是解决需要长期复杂智能体-环境交互的实际问题的基础。支持智能体-环境交互的关键组件是智能体的记忆。虽然先前的研究提出了许多有前景的记忆机制，但这些研究分散在不同的论文中，缺乏一个系统的综述从整体视角总结和比较这些工作，未能抽象出通用且有效的设计模式以启发未来的研究。为弥合这一差距，本文提出了一篇关于基于 LLM 的智能体记忆机制的综合调查。具体而言，我们首先讨论“什么是”以及“为什么需要”基于 LLM 的智能体中的记忆。然后，我们系统地回顾了先前关于如何设计和评估记忆模块的研究。此外，我们还介绍了许多智能体应用，其中记忆模块发挥了重要作用。最后，我们分析了现有工作的局限性并展示了重要的未来方向。为了跟上该领域的最新进展，我们在https://github.com/nuster1128/LLM_Agent_Memory_Survey创建了一个存储库。

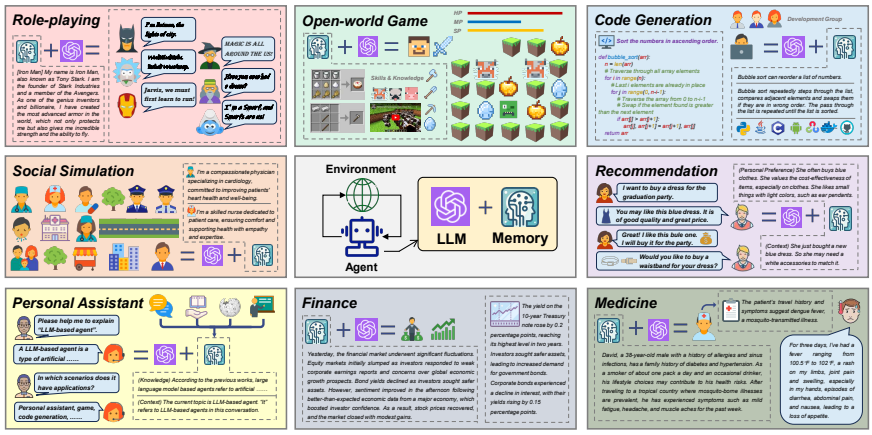

图 1: 基于 LLM 的智能体中内存模块的重要性。

Preprint. Under review.

目录

1 **引言** 3

2 **相关调查** 4

2.1 大型语言模型调查 4

2.2 基于大型语言模型的智能体调查 6

3 **基于 LLM 的智能体的记忆是什么** 6

3.1 基础知识 6

3.2 智能体记忆的狭义定义 8

3.3 智能体记忆的广义定义 8

3.4 基于记忆的智能体-环境交互 8

4 **为什么我们需要在基于 LLM 的智能体中加入记忆** 9

4.1 认知心理学的观点 9

4.2 自我演化的视角 9

4.3 智能体应用的视角 10

5 **基于 LLM 的智能体记忆的实现方法** 10

5.1 记忆来源 10

5.1.1 试验内信息 12

5.1.2 跨试验信息 12

5.1.3 外源知识 12

5.2 记忆形成 13

5.2.1 文本形式的记忆 13

5.2.2 参数形式的记忆 16

5.2.3 文本记忆和参数记忆的优势与劣势 17

5.3 记忆操作 17

5.3.1 记忆书写 17

5.3.2 内存管理 19

5.3.3 记忆阅读 19

6 **如何评估基于 LLM 的智能体的记忆能力** 19

6.1 直接评估 20

6.1.1 主观评价 20

6.1.2 目标评估 20
6.2 间接评估 21
6.2.1 对话 21
6.2.2 多源问答 22
6.2.3 长上下文应用 22
6.2.4 其他任务 22
6.3 讨论 22

7 增强记忆的智能体应用 23
7.1 角色扮演和社会仿真 23
7.2 个人助手 24
7.3 开放世界游戏 24
7.4 代码生成 25
7.5 推荐 25
7.6 特定领域的专家系统 25
7.7 其他应用 26

8 局限性 & 未来方向 26
8.1 参数记忆的更多进展 26
8.2 基于 LLM 的多智能体应用中的记忆 27
8.3 基于记忆的终身学习 27
8.4 人形智能体的记忆 27

9 结论 27

1 引言

”没有记忆就没有文化。没有记忆就没有文明、没有社会、也没有未来。”

Elie Wiesel, 1928-2016

最近，大型语言模型（LLMs）在从人工智能到软件工程、教育和社会科学等多个领域都取得了显著的成功 [1–3]。通常，原始的 LLMs 在完成不同任务时不需要与环境进行交互。然而，为了实现通用人工智能（AGI）的最终目标，智能机器应该能够通过自主探索和从现实世界中学习来提升自身能力。例如，如果一个行程规划代理打算预订机票，它应该向票务网站发送订单请求，并观察响应后再采取下一步行动。个人助理代理应根据用户的反馈调整其行为，提供个性化响应以提高用户满意度。为了进一步推动 LLMs 向 AGI 迈进，近年来见证了大量基于 LLM 的代理研究 [3, 4]，在这些研究中，关键是为 LLMs 配备额外的模块，以增强其在真实环境中自我进化的能力。

在所有添加的模块中，记忆是区分智能体与原始大语言模型的关键组件，使一个智能体真正成为一个智能体（见图 1）。它在决定智能体如何积累知识、处理历史经验、检索支持其动作的信息等方面起着极其重要的作用。围绕记忆模块，人们投入了大量精力来设计其信息来源、存储形式和操作机制。例如，Shinn et al. [5] 结合试验内和跨试验信息以构建记忆模块，从而增强智能体的推理能力。Zhong et al. [6] 以自然语言的形式存储记忆信息，这种形式对用户来说是可解释且友好的。Modarressi et al. [7] 设计了记忆读写操作，以与环境交互解决任务。

尽管已有研究设计了许多有前景的记忆模块，但仍缺乏从整体视角对记忆模块进行系统性研究。为填补这一空白，本文全面回顾了以往的研究，提出了清晰的分类和设计与评估记忆模块的关键原则。具体而言，我们讨论了三个关键问题：（1）基于大型语言模型（LLM）的智能体的记忆是什么？（2）为什么基于 LLM 的智能体需要记忆？（3）如何在基于 LLM 的智能体中实现和评估记忆？首先，我们详细阐述了基于 LLM 的智能体中的记忆概念，提供了狭义和广义的定义。然后，我们分析了 LLM 智能体中记忆的必要性，从认知心理学、自我演化和智能体应用三个方面展示了其重要性。基于“是什么”和“为什么”的问题，我们介绍了设计和评估记忆模块的常用策略。对于记忆设计，我们从三个维度讨论了先前的工作，即记忆来源、记忆形式和记忆操作。对于记忆评估，我们介绍了两种广泛使用的方法，包括直接评估和通过特定智能体任务间接评估。接下来，我们讨论了智能体的应用，包括角色扮演、社会仿真、个人助手、开放世界游戏、代码生成、推荐和专家系统，以展示记忆模块在实际场景中的重要性。最后，我们分析了现有工作的局限性，并强调了重要的未来方向。

本文的主要贡献可总结如下：(1) 我们正式定义了记忆模块，并全面分析了其对基于 LLM 的智能体的必要性。(2) 我们系统地总结了现有研究中关于设计和评估基于 LLM 的智能体的记忆模块的工作，提供了清晰的分类法和直观的见解。(3) 我们展示了典型的智能体应用，以展示记忆模块在不同场景中的重要性。(4) 我们分析了现有记忆模块的关键限制，并展示了激发未来研究的潜在解决方案。据我们所知，这是第一篇关于基于 LLM 的智能体记忆机制的综述。

本文其余部分的组织结构如下。首先，我们在**第2节**为 LLMs 和基于 LLMs 的智能体领域提供了一个系统的元调查，对不同的调查进行了分类并总结了它们的关键贡献。然后，在**第3节至6节**中，我们讨论了基于 LLMs 的智能体中“什么是”、“为什么需要”以及“如何实现和评估”记忆模块的问题。接下来，我们在**第7节**展示增强记忆的智能体的应用。最后，我们在**第8节**和**第9节**讨论现有工作的局限性和未来方向。

2 相关调查

在过去两年中，LLM 吸引了学术界和工业界的许多注意力。为了系统地总结该领域的研究，研究人员撰写了许多综述论文。在本节中，我们简要回顾这些综述（详见**图** 2概览），突出它们的主要关注点和贡献，以便更好地定位我们的研究。

2.1 大型语言模型调查

在 LLM 领域， Zhao et al. [70] 提出了第一个全面的综述，总结了 LLM 的背景、演化路径、模型架构、训练方法以及评估策略。 Hadi et al. [71] 和 Min et al. [72] 也从整体视角对 LLM 进行了综述，然而，它们提供了不同的分类和理解。在这些综述之后，人们深入研究了 LLM 的具体方面，并回顾了相应的里程碑研究和关键技术。这些方面可以分为四大类，包括 LLM 的基本问题、评估、应用和挑战。

基础问题. 本类别的综述旨在总结可以用来解决大型语言模型（LLMs）基本问题的技术。具体来说，Zhang et al. [8] 提供了关于监督微调方法的全面综述，这是更好地训练 LLMs 的关键技术。Shen et al. [9], Wang et al. [10] 和 Liu et al. [11] 呈现了关于 LLMs 对齐的综述，这对确保 LLMs 产生的输出与人类价值观一致是关键需求。Gao et al. [12] 提出了关于 LLMs 检索增强生成（RAG）能力的综述，这对于为 LLMs 提供事实和最新的知识并消除幻觉至关重要。Qin et al. [18] 总结了使 LLMs 能够利用外部工具的最新方法，这对扩展 LLMs 在需要专门知识领域的功能至关重要。Wang et al. [13], Yao et al. [14], Wang et al. [15], Feng et al. [16] 和 Zhang et al. [17] 呈现了关于 LLMs 知识编辑方向的综述，这对定制 LLMs 以满足特定需求非常重要。Huang et al. [19], Wang et al. [20] 和 Pawar et al. [21] 关注 LLMs 的长上下文能力，这对 LLMs 每次处理更多信息和增强其应用场景至关重要。Wu et al. [22], Song et al. [23], Caffagni et al. [24] 和 Yin et al. [25] 总结了多模态 LLMs，这扩展了 LLMs 从文本到视觉和其他模态的能力。上述综述主要关注 LLMs 的有效性。LLMs 的另一个重要方面是它们的训练和推理效率。为了总结这方面的研究， Zhu et al. [30], Xu and McAuley [31], Wang et al. [32] 和 Park et al. [33] 系统地回顾了模型压缩的技术。Ding et al. [81] 和 Xu et al. [29] 分析并总结了关于参数高效微调的研究。 Bai et al. [26], Wan et al. [27], Miao et al. [28] 和 Ding et al. [81] 更多地关注通用资源利用率的效率。

评估. 本类别的调查主要关注如何评估大型语言模型（LLMs）的能力。具体来说，Chang et al. [34] 从总体角度全面总结了评估方法。它涵盖了不同的评估任务、方法和基准，这些是评估 LLMs 性能的关键部分。Guo et al. [35] 更关注评估目标，并描述了如何评估 LLMs 的知识、对齐性和安全性控制能力，这补充了超出性能的评估指标。

应用. 本类别中的综述旨在总结利用大型语言模型（LLMs）改进不同应用的模型。更具体地说，Zhu et al. [37] 关注信息检索（IR）领域，并总结了基于 LLM 的查询处理研究。Xu et al. [38] 更关注信息提取（IE），并为该领域的基于 LLM 的模型提供了全面的分类。Li et al. [50], Lin et al. [51] 和 Wang et al. [52] 讨论了 LLM 在推荐系统领域的应用，其中它们利用智能体生成数据并提供推荐。Fan et al. [39], Wang et al. [40] 和 Zheng et al. [41] 集中讨论 LLM 如何在软件工程（SE）方面促进软件设计、开发和测试。Zeng et al. [42] 总结了机器人领域的基于 LLM 的方法。Cui et al. [43] 和 Yang et al. [44] 关注自动驾驶的应用，从不同的角度总结了该领域的基于 LLM 的模型。除了上述的人工智能领域外，LLM 还被用于自然科学和社会科学。He et al. [45], Zhou et al. [46] 和 Wang et al. [47] 总结了 LLM 在医学中的应用。Li et al. [48] 关注 LLM 在金融领域的应用。He et al. [49] 回顾了利用 LLM 改善心理学发展的模型。

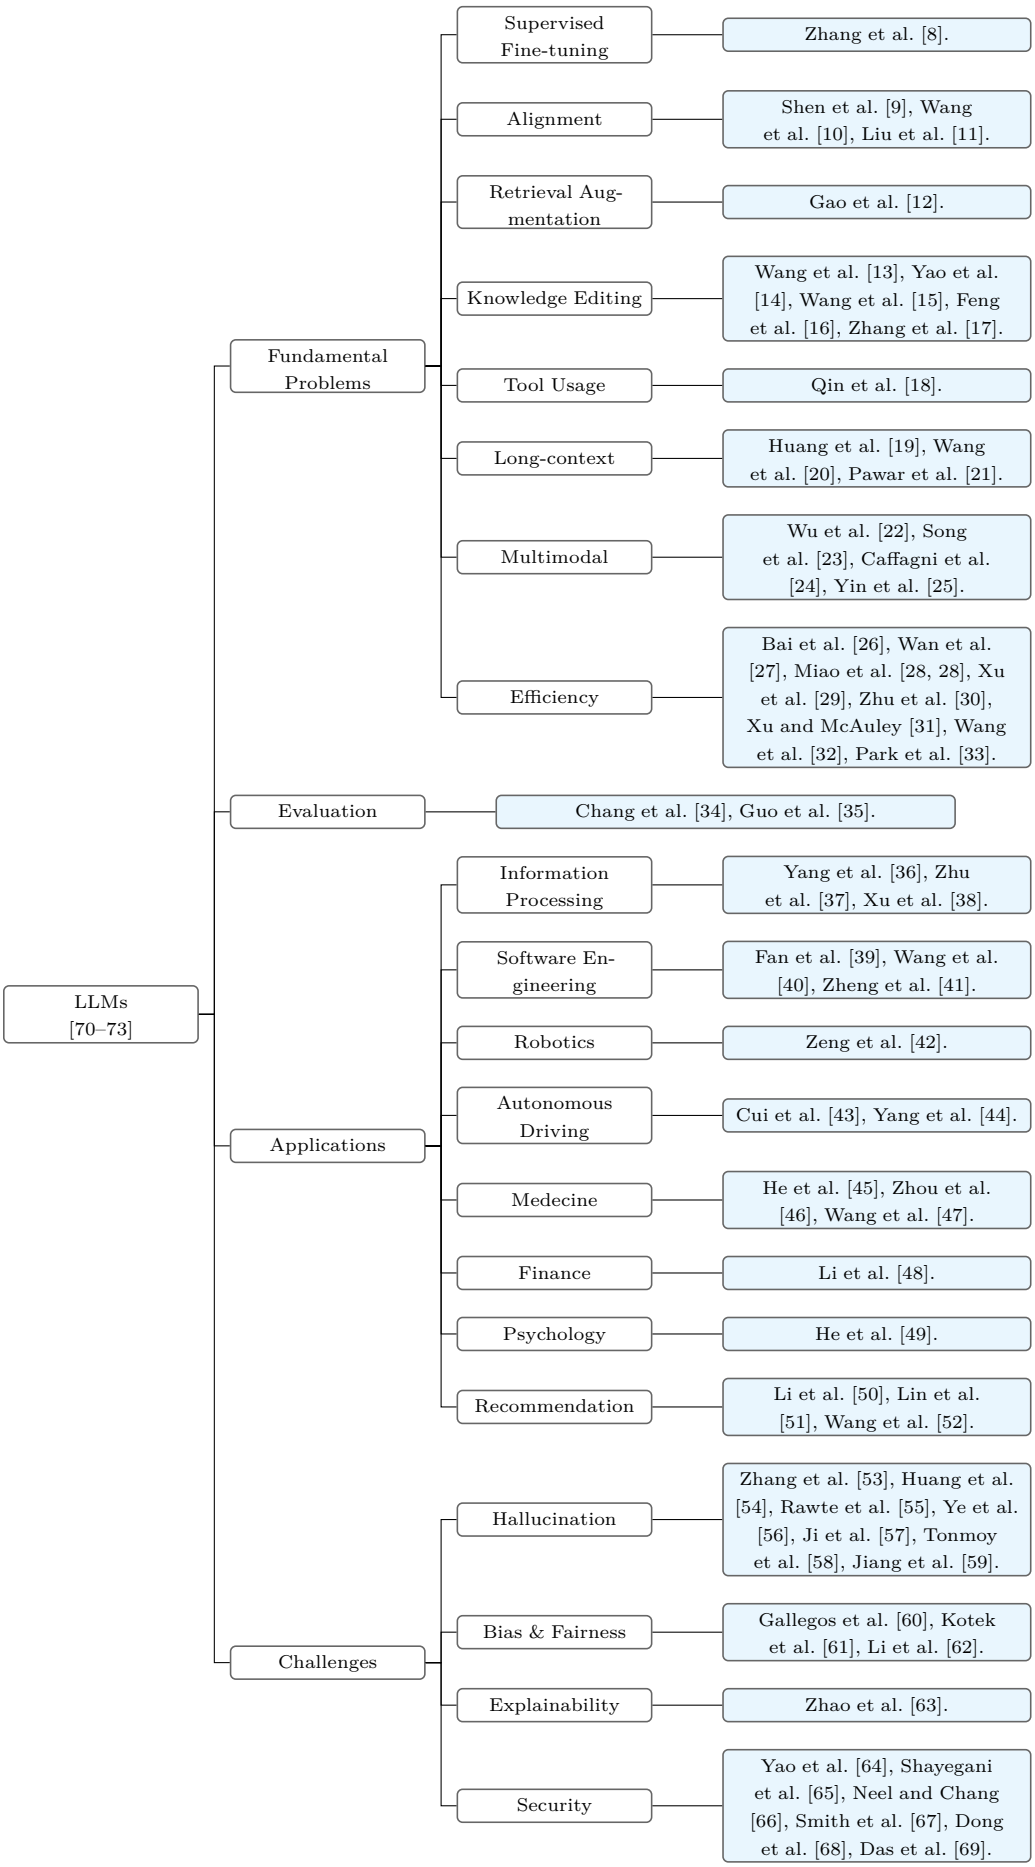
LLMs [70–73]
Fundamental Problems
Supervised Fine-tuning
Zhang et al. [8].
Alignment
Shen et al. [9], Wang et al. [10], Liu et al. [11].
Retrieval Augmentation
Gao et al. [12].
Knowledge Editing
Wang et al. [13], Yao et al. [14], Wang et al. [15], Feng et al. [16], Zhang et al. [17].
Tool Usage
Qin et al. [18].
Long-context
Huang et al. [19], Wang et al. [20], Pawar et al. [21].
Multimodal
Wu et al. [22], Song et al. [23], Caffagni et al. [24], Yin et al. [25].
Efficiency
Bai et al. [26], Wan et al. [27], Miao et al. [28, 28], Xu et al. [29], Zhu et al. [30], Xu and McAuley [31], Wang et al. [32], Park et al. [33].
Evaluation
Chang et al. [34], Guo et al. [35].
Applications
Information Processing
Yang et al. [36], Zhu et al. [37], Xu et al. [38].
Software Engineering
Fan et al. [39], Wang et al. [40], Zheng et al. [41].
Robotics
Zeng et al. [42].
Autonomous Driving
Cui et al. [43], Yang et al. [44].
Medecine
He et al. [45], Zhou et al. [46], Wang et al. [47].
Finance
Li et al. [48].
Psychology
He et al. [49].
Recommendation
Li et al. [50], Lin et al. [51], Wang et al. [52].
Challenges
Hallucination
Zhang et al. [53], Huang et al. [54], Rawte et al. [55], Ye et al. [56], Ji et al. [57], Tonmoy et al. [58], Jiang et al. [59].
Bias & Fairness
Gallegos et al. [60], Kotek et al. [61], Li et al. [62].
Explainability
Zhao et al. [63].
Security
Yao et al. [64], Shayegani et al. [65], Neel and Chang [66], Smith et al. [67], Dong et al. [68], Das et al. [69].
Fundamental Problems
Planning
Huang et al. [74].
Memory
Our Survey.
Multi-agents
Guo et al. [75].

挑战. 本类别中的调查主要集中于 LLM 的信任 worthiness，如幻觉、偏差、不公平性、可解释性、安全性和隐私性。LLMs 中的幻觉问题是指 LLMs 可能会生成误解或捏造的内容，影响其下游应用的可靠性。Zhang et al. [53], Huang et al. [54], Rawte et al. [55], Ye et al. [56], Ji et al. [57], Tonmoy et al. [58] 和 Jiang et al. [59] 总结了缓解 LLMs 中幻觉问题的主要模型。偏差和不公平性问题是指 LLMs 可能对不同的人类或目标不平等待遇的现象，这可能导致社会刻板印象和歧视的传播。Gallegos et al. [60], Kotek et al. [61] 和 Li et al. [62] 全面讨论了这些挑战并总结了现有的缓解方法。可解释性的问题意味着 LLMs 的内部工作机制仍然不清楚。Zhao et al. [63] 系统地讨论了这个问题，并总结了提高 LLMs 可解释性的先前努力。安全性和隐私性也是具有挑战性的问题，已在 Yao et al. [64], Shayegani et al. [65], Neel and Chang [66], Smith et al. [67], Dong et al. [68] 和 Das et al. [69] 中进行了全面调查。

2.2 基于大型语言模型的智能体调查

基于大语言模型的能力，人们开展了大量构建基于大语言模型的智能体的研究，这些智能体能够自主感知环境、采取动作、积累知识并演化自身。在这一领域， Wang et al. [3] 发表了第一篇系统总结基于大语言模型的智能体的综述论文，从智能体构建、智能体应用和智能体评估的角度进行了梳理。 Xi et al. [4], Zhao et al. [77], Cheng et al. [78] 和 Ge et al. [80] 也从总体视角对基于大语言模型的智能体研究进行了总结，但它们各有不同的侧重点和分类方法，为该领域提供了更加多样化的理解。除了这些总体综述外，还出现了一些专门回顾基于大语言模型的智能体特定方面的论文。对于基础问题，Durante et al. [79] 总结了关于多模态智能体的研究；Huang et al. [74] 关注基于大语言模型的智能体的规划能力；Guo et al. [75] 更关注多智能体交互场景。对于应用方面，Li et al. [76] 对被用作个人助理的基于大语言模型的智能体进行了总结。

本文工作位置. 我们的综述总结了基于 LLM 的智能体的一个基础问题的研究，即智能体的记忆机制。据我们所知，这是该方向的第一篇综述。我们希望它不仅能启发未来更先进的记忆架构，还能为新入门者提供全面的基础材料。

3 基于 LLM 的智能体的记忆是什么

与环境进行交互和学习是基于大型语言模型（LLM）的智能体的基本要求。在智能体与环境的交互过程中，有三个关键阶段，即：（1）智能体感知环境中的信息，并将其存储到内存中；（2）智能体处理存储的信息以使其更具可用性；（3）智能体根据处理后的内存信息采取下一步动作。在所有这些阶段中，内存都起着极其重要的作用。接下来，我们首先从狭义和广义两个角度定义智能体的内存，然后详细说明基于内存模块的上述三个阶段的执行过程。

3.1 基础知识

为清楚起见，我们首先介绍几个重要的背景知识如下：

Definition 1 (Task). 任务是智能体需要完成的最终目标，例如，为 Alice 预订机票、为 Bob 推荐餐厅等。正式地，我们用 $\mathcal{T}$ 表示一个任务，并在以下内容中通过下标标注不同的任务。

Definition 2 (Environment). 在狭义上，环境是智能体完成任务需要交互的对象。对于定义 1中的例子，环境是 Alice 和 Bob，他们对智能体的动作提供反馈。更广泛地说，环境可以是影响智能体决策的任何情境因子，例如预订机票时的天气、推荐餐厅时的时间和地点等。

Definition 3 (Trial and Step). 要完成一项任务，智能体需要与环境进行交互。通常情况下，智能体首先采取一个动作，然后环境对该动作作出响应。最后，智能体根据响应采取下一个

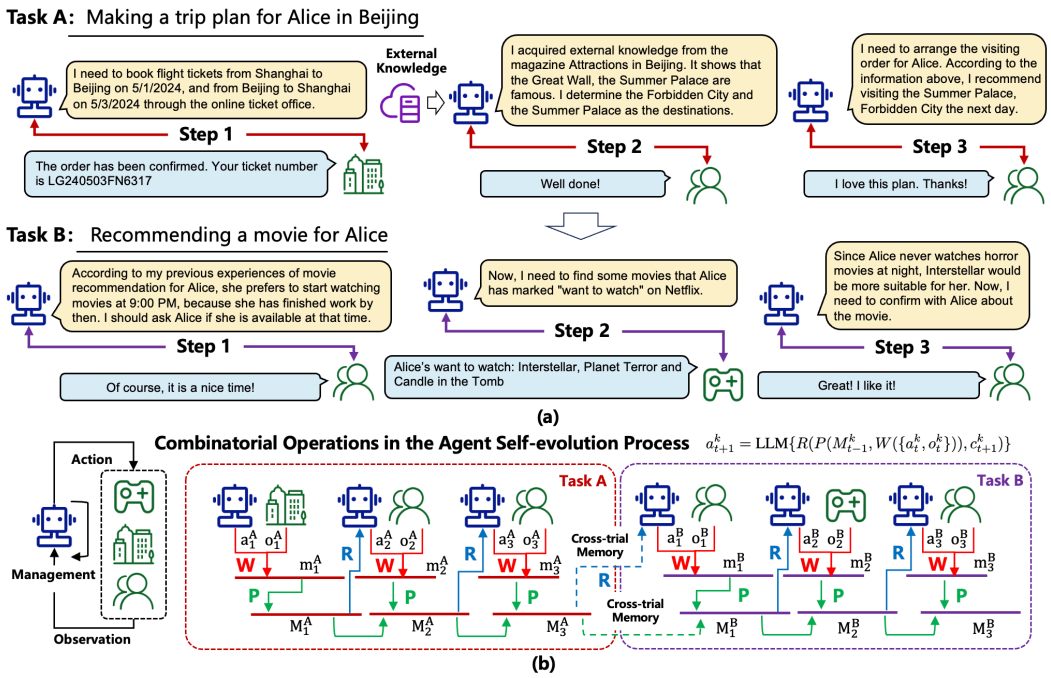

图 3: (a) 智能体-环境交互过程中潜在试验的示例。(b) 记忆读取、写入和管理过程的图示，其中虚线表示跨试验信息可以纳入记忆模块。

动作。此过程迭代直至任务完成。完整的智能体-环境交互过程称为一个 **试验**，每次交互轮次称为一个 **步骤**。对于每次试验，智能体可以采取多个步骤来形成潜在的解决方案。对于每个任务，智能体可以通过探索多个试验来完成任务 [5]。形式上，在第 t 步时，我们用 a_t 表示智能体的动作，用 o_t 表示观察到的环境响应。那么，一个长度为 T 的试验可以表示为 $\xi_T = \{a_1, o_1, a_2, o_2, ..., o_T, a_T\}$ 。

在上述定义中，任务和环境是最粗粒度的概念，而步骤是最细粒度的概念。它们共同描述了完整的智能体-环境交互过程。

一个玩具示例. 基于上述定义，我们展示一个玩具示例，并在本文中贯穿始终以提供更多的直觉。在这个示例中，智能体有两个任务：(A) **为** Alice **制定** 2024 **年** 5 **月** 1 **日至** 2024 **年** 5 **月** 3 **日在北京的旅行计划**，其中智能体必须 (i) 购买往返机票，(ii) 根据 Alice 的偏好确定几个景点，以及 (iii) 安排这些景点的参观顺序。(B) **为** Alice **推荐** 2024 **年** 5 **月** 10 **日观看的电影**，其中智能体必须 (i) 确定 Alice 有空观看电影的时间，以及 (ii) 根据 Alice 的观影偏好选择一部电影。对于每个任务，我们在下面给出一个潜在的试验（同样在**图** 3(a) 中展示）。对于任务 (A)，试验是：

[Step 1] **智能体**：我需要通过在线票务处预订 2024 年 5 月 1 日从上海到北京的航班以及 2024 年 5 月 3 日从北京到上海的航班。**环境（在线票务处）**：订单已确认。出发航班起飞时间为上午 9:00，您的票号为 EK240501SX9021。返程航班起飞时间为下午 4:30，您的票号为 LG240503FN6317。请按时到达机场办理登机手续。

[Step 2] **智能体**: 我从杂志《北京 attractions》获取了外部知识。它显示《长城》、《紫禁城》和《颐和园》很有名。根据爱丽丝的偏好，我认为她更喜欢古代建筑，所以我确定《紫禁城》和《颐和园》为目的地。**环境（爱丽丝）**：干得好！

[步骤 3] **智能体**: 现在，我需要为 Alice 安排参观顺序。根据上述信息，我建议她到达北京后先去参观颐和园，因为它适合花整个下午在那里观看日落。然后，第二天她可以去故宫，这会给她足够的时间。最后，第三天她可以返回上海并休息。**环境（Alice）**：我很喜欢这个计划。谢谢！

对于任务（B），试验是：

[步骤 1] **智能体**: 根据我之前为 Alice 推荐电影的经验，她喜欢在晚上 9:00 开始看电影，因为她那时已经下班了。我应该问 Alice 那时是否有空。**环境** (Alice): 当然，那是个不错的时间！

[步骤 2] **智能体**: 现在，我需要找到 Alice 在 Netflix 上标记为 "想看" 的电影。**环境 (**Netflix**)**: Alice 的想看列表：星际穿越, 死亡飞车和 烛光里的坟墓。

[步骤 3] **智能体**: 由于爱丽丝晚上从不看恐怖电影，星际穿越对她来说会更合适。现在，我需要和爱丽丝确认这部电影。**环境（爱丽丝）**：太好了！我喜欢！

3.2 智能体记忆的狭义定义

在狭义上，智能体的记忆仅与同一试验的历史信息相关。形式上，对于给定的任务，试验在第 t 步之前的历史信息为 $\xi_t = \{a_1, o_1, a_2, o_2, ..., a_{t-1}, o_{t-1}\}$ ，然后根据 ξ_t 得到记忆。在上述玩具示例中，对于任务 (A)，[第 3 步] 智能体需要安排 Alice 的参观顺序；此时，它的记忆包含 [第 1 步] 和 [第 2 步] 中选定的景点和到达时间的信息。对于任务 (B)，智能体在 [第 3 步] 需要为 Alice 选择一部电影；此时，它的记忆包含安排好的观影时间。

3.3 智能体记忆的广义定义

在一个广义的范围内，智能体的记忆可以来自更广泛的来源，例如，不同试验之间的信息以及智能体-环境交互之外的外部知识。正式地讲，给定一系列顺序任务 $\{\mathcal{T}_1, \mathcal{T}_2, ..., \mathcal{T}_K\}$ ，对于任务 $\mathcal{T}_k$ ，在步骤 t 的记忆信息来自三个来源：（1）同一试验中的历史信息，即 $\xi_t^k = \{a_1^k, o_1^k, ..., a_{t-1}^k, o_{t-1}^k\}$ ，我们在其中添加上标 k 来标记任务索引。(2）不同试验之间的历史信息，即 $\Xi^k = \{\xi^1, \xi^2, ..., \xi^{k-1}, \xi^{k'}\}$ ，其中 ξ^j （$j \in \{1, ..., k-1\}$）表示任务 j 的试验。[1]，和 $\xi^{k'}$ 表示先前针对任务 $\mathcal{T}_k$ 探索的试验。(3）外部知识，由 D_t^k 表示。智能体的记忆基于 (ξ_t^k, Ξ^k, D_t^k) 派生。在上述玩具示例中，对于任务 (A)，如果有几个失败的试验，即 Alice 的反馈为负面，那么这些试验可以纳入智能体的记忆中，以避免未来类似的错误（对应于 $\xi^{k'}$）。此外，对于任务 (B)，智能体可能会推荐与 Alice 在任务 (A) 中访问的景点相关的电影，以捕捉她最近的偏好（对应于 $\{\xi^1, \xi^2, ..., \xi^{k-1}\}$）。在智能体的决策过程中，它还参考了杂志《北京景点》，用于制定旅行计划，这是当前任务 $\mathcal{T}_k$ 的外部知识（对应于 D_t^k）。

3.4 基于记忆的智能体-环境交互

如**第 3 节**开头所述，智能体-环境交互过程中有三个关键阶段。智能体记忆模块通过包括记忆写入、记忆管理和记忆读取在内的三种操作来实现这些阶段。

记忆写入. 该操作旨在将原始观测值投射到实际存储在内存中的内容，这些内容更具信息量 [7] 且简洁 [6]。它对应于智能体-环境交互过程的第一阶段。给定一个任务 $\mathcal{T}_k$ ，如果智能体在步骤 t 执行动作 a_t^k ，并且环境提供观测值 o_t^k ，那么记忆写入操作可以形式化地表示为：

$$m_t^k = W(\{a_t^k, o_t^k\}),$$

[1]对于每个任务，可以有多次试验来探索最终解决方案，所有这些都可以纳入记忆中。

其中 W 是一个投影函数。m_t^k 是最终存储的记忆内容，可以是自然语言或参数化表示。在上述玩具示例中，对于任务 (A)，智能体应在 [步骤 2] 后记住航班安排和景点决策。对于任务 (B)，智能体应在 [步骤 1] 后记住 Alice 希望在晚上 9:00 看电影的事实。

记忆管理. 该操作旨在处理存储的记忆信息，使其更加高效，例如，总结高层次概念以使智能体更具泛化能力 [6]，合并相似信息以减少冗余 [7]，并遗忘不重要或无关的信息以消除其负面影响。该操作对应于智能体-环境交互过程的第二阶段。设 M_{t-1}^k 为任务 k 在第 t 步之前的记忆内容，假设 m_t^k 是基于上述内存写入操作在第 t 步存储的信息，则记忆管理操作可以表示为：

$$M_t^k = P(M_{t-1}^k, m_t^k),$$

其中 P 是一个函数，它迭代地处理存储的内存信息。对于狭义的内存定义，并行迭代仅在同一个试验内发生，当试验结束时，内存会被清空。对于广义的内存定义，并行迭代发生在不同的试验甚至任务之间，并且集成了外部知识。在上述玩具示例的任务（B）中，智能体可以得出结论：Alice 喜欢在晚上观看科幻电影，这可以用作默认规则，为 Alice 将来提供建议。

记忆读取. 此操作旨在从记忆中获取重要信息，以支持智能体的下一步动作。它对应于智能体 - 环境交互过程的第三阶段。假设 M_t^k 是任务 k 在步骤 t 时的记忆内容，c_t^k 是下一步动作的上下文，那么记忆读取操作可以表示为：

$$\hat{M}_t^k = R(M_t^k, c_{t+1}^k),$$

其中 R 通常通过计算 M_t^k 和 c_{t+1}^k 的相似度来实现 [82]。$\hat{M}_t^k$ 用作最终提示的一部分，以驱动智能体的下一个动作。对于上述玩具示例中的任务 (B)，当智能体在 [步骤 3] 中决定最终推荐的电影时，它应关注 [步骤 2] 中的“想看”列表，并从中选择一部。

基于上述操作，我们可以推导出一个统一的函数来描述从 $\{a_t^k, o_t^k\}$ 到 a_{t+1}^k 的演化过程，即：

$$a_{t+1}^k = \mathrm{LLM}\{R(P(M_{t-1}^k, W(\{a_t^k, o_t^k\})), c_{t+1}^k)\},$$

其中 LLM 是大型语言模型。通过迭代展开此函数即可轻松获得完整的智能体-环境交互过程（有关直观说明，请参见 **图** 3(b)）。

Remark. 这个函数提供了一个智能体记忆过程的通用公式。先前的工作可能使用不同的规格。例如，在 [5] 中，R 和 P 被设置为相同的函数，并且 P 仅在一次试验结束时生效。在 Park et al. [83] 中，R 是基于三个标准（相似度、时间间隔和重要性）实现的，并且 P 是通过反射过程来获得更抽象的思想。在本节中，我们关注智能体记忆操作的整体框架。更详细的 W、P 和 R 的实现推迟到 **第5 节**。

4 为什么我们需要在基于 LLM 的智能体中加入记忆

上文我们介绍了基于 LLM 的智能体的记忆是什么。在全面介绍其实现方法之前，本节简要说明为什么记忆对于构建基于 LLM 的智能体是必要的，并从认知心理学、自我演化和智能体应用三个角度展开讨论。

4.1 认知心理学的观点

认知心理学是人类 mental processes 的科学研究，如注意力、语言使用、记忆、感知、问题解决、创造力和推理等。[2]. 在这些过程中，记忆被广泛认为是一个极其重要的过程 [84]。它是人类通过积累重要信息并抽象出高级概念来学习知识的基础 [85]，是通过记住文化价值和

[2]https://en.wikipedia.org/wiki/Cognitive_psychology

个人经历来形成社会规范 [86]，是通过想象潜在的积极和消极后果来采取合理行为 [87]，等等。

基于大型语言模型（LLM）的智能体的一个主要目标是取代人类完成不同的任务。为了使智能体的行为像人类一样，遵循人类的工作机制来设计智能体是一种自然且必要的选择 [88]。由于记忆对人类很重要，为智能体设计记忆模块也具有重要意义。此外，认知心理学已经被研究了很长时间，因此积累了许多有效的人类记忆理论和架构，这些可以支持智能体更高级的能力 [89]。

4.2 自我演化的视角

为了完成不同的实际任务，智能体必须在动态环境中自我演化 [90]。在智能体-环境交互过程中，记忆对于以下几个方面至关重要：(1) **经验积累**。记忆的一个重要功能是记住过去的错误规划、不适当的行为或失败的经验，以便使智能体在未来处理类似任务时更加有效 [91]。这对提高智能体在自我演化过程中的学习效率极为重要。(2) **环境探索**。为了在环境中自主演化，智能体必须探索不同的动作并从反馈中学习 [92]。通过记住历史信息，记忆可以帮助更好地决定何时以及如何进行探索，例如，更多地关注之前失败的试验或探索频率较低的动作 [93]。(3) **知识抽象**。记忆的另一个重要功能是从原始观测中总结和抽象高层次的信息，这是智能体对未见过的环境更具适应性和可泛化性的基础 [82]。总之，自我演化是基于 LLM 的智能体的基本特征，而记忆对自我演化至关重要。

4.3 智能体应用的视角

在许多应用中，内存是智能体不可或缺的组成部分。例如，在一个会话智能体中，内存存储关于历史对话的信息，这对于智能体生成下一个回复是必要的。没有内存，智能体不知道上下文，无法继续对话 [94]。在仿真智能体中，内存对于使智能体始终遵循角色配置文件非常重要。如果没有内存，智能体在仿真过程中可能会轻易偏离角色 [95]。上述两个例子表明，内存不是可选组件，而是智能体完成给定任务所必需的。

在上述三种视角中，第一个揭示了记忆构建了智能体的认知基础，后两种表明记忆对智能体的演化原则与应用是必要的，为设计具有记忆机制的智能体提供了启示。

5 基于 LLM 的智能体记忆的实现方法

在本节中，我们将从三个角度讨论记忆模块的实现方法：记忆源、记忆形式和记忆操作。记忆源指的是记忆内容的来源。记忆形式侧重于如何表示记忆内容。记忆操作旨在处理记忆内容。这三个视角为记忆实现方法提供了全面的回顾，这对未来的研究很有帮助。为了更好地展示，我们在图 4 中给出了实现方法的概述。

5.1 记忆来源

在之前的工作中，记忆内容可能来自不同的来源。基于我们在**第 3节**中的表述，这些来源可以分为三类，即试验内的信息、不同试验之间的信息以及外部知识。前两者是在智能体-环境交互过程中动态生成的（例如，任务内部信息），而后者是循环外部的静态信息（例如，任务外部信息）。我们在**表** 1中总结了关于记忆来源的先前工作。

5.1.1 试验内信息

在智能体-环境交互过程中，试验内的历史步骤通常是支持智能体未来动作的相关且有用的信息信号。几乎所有之前的工作都将这些信息作为记忆来源的一部分。

表 1: 记忆来源的总结。我们使用✓ 和 × 来标记相应的来源是否被采用在模型中。

Models	Inside-trial Information	Cross-trial Information	External Knowledge
MemoryBank [6]	✓	×	×
RET-LLM [7]	✓	×	✓
ChatDB [96]	✓	×	✓
TiM [97]	✓	×	×
SCM [98]	✓	×	×
Voyager [99]	✓	×	×
MemGPT [100]	✓	×	×
MemoChat [94]	✓	×	×
MPC [101]	✓	×	×
Generative Agents [83]	✓	×	×
RecMind [102]	✓	×	✓
Retroformer [103]	✓	✓	✓
ExpeL [82]	✓	✓	✓
Synapse [91]	✓	✓	×
GITM [93]	✓	✓	✓
ReAct [104]	✓	×	✓
Reflexion [5]	✓	✓	✓
RecAgent [95]	✓	×	×
Character-LLM [105]	✓	×	✓
MAC [106]	✓	×	×
Huatuo [107]	✓	×	✓
ChatDev [1]	✓	×	×
InteRecAgent [108]	✓	×	✓
MetaAgents [109]	✓	×	×
TPTU [110, 111]	✓	×	✓
MetaGPT [112]	✓	✓	×
S^3 [2]	✓	×	×
InvestLM [113]	✓	×	✓

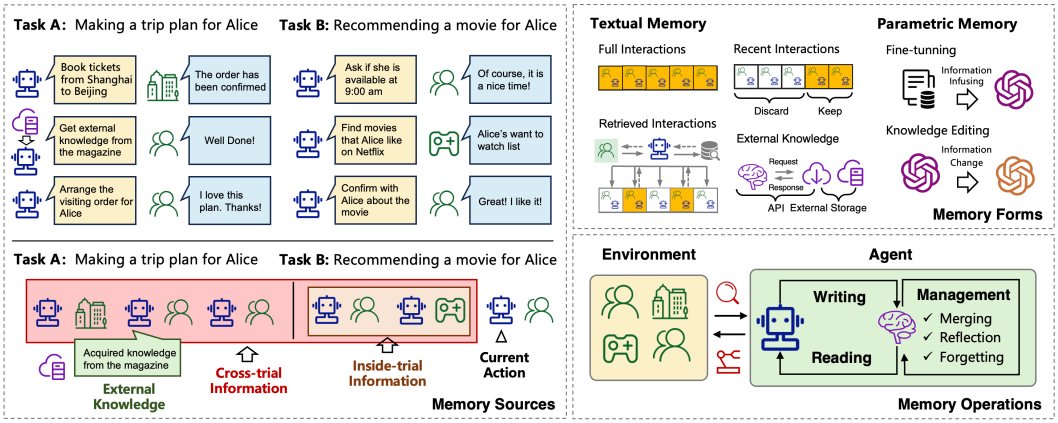

图 4: 基于大型语言模型（LLM）的智能体中记忆的来源、形式和操作概述。

代表性研究。生成性智能体 [83] 旨在通过基于大型语言模型的智能体模拟人类的日常行为。智能体的记忆来源于历史行为以实现目标，例如，在研究特定主题时收集相关论文。MemoChat [94] 旨在与人类聊天，智能体的记忆基于对话会话的历史记录来推导。TiM [97] 旨在通过在完成任务后自动生成多个想法来增强智能体的推理能力，这些想法用作记忆，提供更可泛化的信息。Voyager [99] 专注于基于 Minecraft 构建游戏智能体，其中记忆包含初步和基本操作的可执行代码以完成任务。需要注意的是，内部试验信息不仅包括智能体-环境交互，还包括交互上下文，如时间、地点信息。

讨论. 由于试验内的信息与智能体当前必须完成的任务高度相关，因此它是构建智能体记忆最明显且直观的来源。然而，仅依赖试验内信息可能会阻碍智能体从各种任务中积累宝贵知识并学习更具泛化性的信息。因此，许多研究还探讨了如何有效地利用跨不同任务的信息来构建记忆模块，详见以下章节。

5.1.2 跨试验信息

对于基于 LLM 的智能体，环境中多次试验积累的信息也是记忆的关键部分，通常包括成功和失败的动作及其见解，如失败原因、成功的常见动作模式等。

代表性研究. 最突出的研究之一是 Reflexion [5]，它提出了基于 LLM 的智能体的口语强化学习方法。它以口语形式从过去的试验中推导经验，并在随后的试验中应用这些经验以提高任务性能。此外，Retroformer [103] 对反射模型进行微调，使智能体能够更有效地从过去的试验中提取跨试验信息。在 Synapse [91] 中，智能体专注于解决计算机控制任务。它们的记忆可以通过成功的示例记录跨试验信息，这些示例将作为类似试验的参考。在 ExpeL [82] 中，智能体需要在环境中解决一组复杂的交互任务。它们存储并组织已完成的轨迹，并为新任务召回类似的轨迹。在召回的轨迹中，成功案例将与失败案例进行比较，以识别成功的模式。

讨论. 根据跨试验信息的累积记忆，智能体能够积累经验，这对它们的演化非常重要。基于过去的经验，智能体可以根据整个过程的整体反馈调整它们的动作。与作为短期记忆的试验内观察相比，试验经验可以被视为长期记忆。它利用不同试验的反馈来支持更广泛的智能体试验，为智能体提供更持久的经验支持。然而，其局限性在于，无论是试验内信息还是跨试验信息，都要求智能体亲自参与智能体-环境交互，外部经验和知识未被包括在内。

5.1.3 外源知识

一个重要的特性是，基于 LLM 的智能体可以直接用自然语言进行交流和控制。因此，基于 LLM 的智能体可以轻松整合文本形式的外部知识（如 Wikipedia）。[3]) 以促进他们的决策。

代表性研究. 在 ReAct [104] 中，智能体需要通过多个推理步骤回答关于常识性问题。如果在这些步骤中缺乏信息，它们可以利用 Wikipedia API 获取外部知识。GITM [93] 旨在设计 Minecraft 中的智能体，这些智能体可以在复杂且稀疏奖励的环境中进行探索。智能体从在线 Minecraft Wiki 和配方制作中获取无限的知识来源，以辅助导航。CodeAgent [114] 专注于仓库级代码生成任务，该任务通常需要复杂的依赖关系和广泛的文档。它设计了一种网络搜索策略来获取相关的外部知识。ChatDoctor [115] 将基于 LLM 的智能体适应到医疗领域。它微调了一个获取过程，以从 Wikipedia 和医学数据库中检索外部知识。

讨论. 外部知识可以从私人和公共来源获取。它为基于 LLM 的智能体提供了超越其内部环境的大量知识，这些知识可能对智能体通过与环境交互来获取非常困难甚至不可能。此外，大多数外部知识可以根据任务需求实时动态访问各种工具的 API 来获得，从而缓解了过时知识的问题。将外部知识集成到基于 LLM 的智能体的记忆中显著扩展了它们的知识边界，为其决策提供了无限、最新且有根据的知识。

5.2 记忆形成

一般而言，有两种形式可以表示记忆内容：文本形式和参数形式。在文本形式中，信息通过自然语言显式地保留和回忆。在参数形式中，记忆信息被编码为参数，并隐式地影响智能体的动作。我们在表 2 中总结了先前关于记忆形式及其实现的工作。

5.2.1 文本形式的记忆

目前，文本形式是表示记忆内容的主流方法，其特点在于更好的可解释性、更易实现以及更快的读写效率。具体而言，文本形式可以是非结构化表示（如原始自然语言）和结构化信息（如元组、数据库等）。总体上，先前的研究使用文本记忆存储四种类型的信息：（1）完整的智能体-环境交互，（2）近期的智能体-环境交互，（3）检索到的智能体-环境交互，以及（4）外部知识。在前三种方法中，记忆利用自然语言描述智能体-环境交互环中的信息。在前三种类型中，它们记录了智能体-环境交互环内的信息，而最后一种类型则利用自然语言来存储环外的信息。

完整交互。该方法基于长上下文策略 [116] 存储智能体-环境交互历史的所有信息。对于**第 3.1节**中的示例，在任务（A）中步骤 2 之后智能体的记忆可以通过拼接步骤 2 之前的所有信息来实现，最终的文本形式记忆为："你的记忆是 [步骤 1]（智能体）...（在线票务办公室）...[步骤 2]... 请根据你的记忆进行推理"。

在之前的工作中，不同的模型使用了不同的策略来存储记忆信息。例如，在 LongChat [116] 中，智能体专注于理解长上下文场景中的自然语言。它微调基础模型以更好地适应记住完整的交互。Memory Sandbox [117] 旨在减轻无关记忆对对话的影响。它设计了一种透明且交互的方法来管理智能体的记忆，在将它们拼接成提示之前删除无关记忆。此外，还有一些努力致力于增强 LLMs 处理更长上下文的能力 [118, 119]。

虽然存储所有 agent-环境交互可以保持全面的信息，但在计算成本、推理时间和推理鲁棒性方面存在明显的限制。首先，由于注意力计算的时间复杂度随序列长度的二次增长，在实践中快速扩展的长上下文内存会导致 LLM 推理时的高计算成本。因此，它需要更多的计算资

[3] https://www.wikipedia.org

表 2: 记忆形式的总结。我们使用✓ 和 × 来标记相应的记忆形式是否被采用在模型中。

Models	Textual Form				Parametric Form	
	Complete	Recent	Retrieved	External	Fine-tuning	Editing
MemoryBank [6]	×	×	✓	×	×	×
RET-LLM [7]	×	×	✓	×	×	×
ChatDB [96]	×	×	✓	×	×	×
TiM [97]	×	×	✓	×	×	×
SCM [98]	×	✓	✓	×	×	×
Voyager [99]	×	×	✓	×	×	×
MemGPT [100]	×	✓	✓	×	×	×
MemoChat [94]	×	×	✓	×	×	×
MPC [101]	×	×	✓	×	×	×
Generative Agents [83]	×	×	✓	×	×	×
RecMind [102]	✓	×	×	×	×	×
Retroformer [103]	✓	×	×	✓	✓	×
ExpeL [82]	✓	×	✓	✓	×	×
Synapse [91]	×	×	✓	×	×	×
GITM [93]	✓	×	✓	✓	×	×
ReAct [104]	✓	×	×	✓	×	×
Reflexion [5]	✓	×	×	✓	×	×
RecAgent [95]	×	✓	✓	×	×	×
Character-LLM [105]	×	✓	×	×	✓	×
MAC [106]	×	×	×	×	×	✓
Huatuo [107]	✓	×	×	×	✓	×
ChatDev [1]	✓	×	×	×	×	×
InteRecAgent [108]	×	✓	✓	✓	×	×
MetaAgents [109]	×	×	✓	×	×	×
TPTU [110, 111]	✓	×	×	✓	×	×
MetaGPT [112]	✓	×	×	×	×	×
S^3 [2]	×	×	✓	×	×	×
InvestLM [113]	✓	×	×	×	✓	×

源并显著增加推理延迟，这阻碍了其实际部署。更重要的是，随着其快速增长，内存长度在 LLM 预训练期间很容易超过序列长度的上限，这使得记忆截断成为必要。因此，它可能导致由于 agent 记忆不完整而导致的信息丢失。最后但同样重要的是，它可能导致 LLM 推理中的偏差和不鲁棒性。具体来说，一项先前的研究 [120] 表明，长上下文中文本段的位置可以极大地影响它们的利用率，因此不能将长上下文提示中的内存同等对待且稳定。所有这些缺点表明，有必要为基于 LLM 的 agent 设计额外的记忆模块，而不是简单地将所有信息直接连接到提示中。

近期交互. 该方法使用自然语言存储和维护最近获取的记忆，从而根据局部性原理 [121] 提高记忆信息的利用率。在**第**3.1**节**示例的任务 (B) 中，我们只需记住爱丽丝近三年的偏好，并截断遥远的部分，其中近三年可视为记忆窗口的大小。

在先前的研究中，有各种策略来存储最近的文本记忆。例如，SCM [98] 提出了一种基于缓存机制的闪存，它保留了最近 $t-1$ 时间步的观察结果，旨在增强信息的新鲜度。MemGPT [100] 将智能体视为操作系统，可以通过自然界面与用户动态交互。它设计了工作上下文以保存最近的历史记录，作为虚拟上下文管理的一部分。在 RecAgent [95] 中，智能体被设计为模拟电影推荐中的用户行为。它将一些时间信息存储在短期记忆中作为一个中间缓存，可以模拟人脑的记忆机制 [122, 123]。这些代表性方法可以根据最近的交互动态更新记忆，并更加关注当前阶段重要的近期上下文。

根据最近性缓存记忆是一种提高内存效率的有效方法，它使智能体能够更多地关注近期信息。然而，在长期任务中，这种方法无法访问来自遥远记忆的关键信息。这可能导致潜在的重要信息丢失，这些信息不在即时缓存窗口内。换句话说，强调近期性会内在地忽略早期的关键信息，从而在需要全面理解过去事件的情景中构成挑战。

检索交互. 与上述根据时间截断记忆的方法不同，该方法通常基于相关性、重要性和主题选择记忆内容。它确保在决策过程中包含遥远但关键的记忆，从而解决了仅记忆最近信息的局限性。在**第** 3.1**节**示例任务（A）中，Alice 的偏好在该任务之前已存储在记忆中。在 [步骤 2]，代理将根据查询关键字“旅行”从记忆中检索与 Alice 偏好最相关的方面，获取 Alice 对古代建筑风景名胜的偏好。一般来说，检索方法在写入记忆时会为记忆条目生成嵌入作为索引，并记录辅助信息以协助检索。在读取记忆时，计算每个记忆条目的匹配分数，前 K 个条目将用于代理的决策过程。

在现有研究中，大多数智能体利用检索方法来处理记忆信息。例如，Park et al. [83] 首先通过余弦相似度计算当前上下文与记忆条目之间的相关性，并根据辅助信息获得重要性和新颖性。MemoryBank [6] 使用双塔稠密检索模型从过去的对话中找到相关信息。每个记忆条目被编码为嵌入，并使用 FAISS [124] 进行索引以提高检索效率。在读取记忆时，当前上下文将被编码为表示形式以获取最相关的记忆。此外，RET-LLM [7] 计划设计一个通用的写-读记忆模块。它利用局部敏感哈希（LSH）检索数据库中的相对条目以提供更多信息。另外，ChatDB [96] 设计了利用符号记忆的方法，并提出生成 SQL 声明从数据库检索以获取存储的信息。

检索方法很大程度上依赖于获取预期信息的准确性和效率。不准确的检索策略可能会获取与智能体推理无关的信息，而繁重的检索系统会导致较高的计算成本和较长的时间延迟，特别是在处理大量信息时。此外，检索方法通常在环境中存储同质信息，所有信息都以一致的形式存在。对于环境外的异质信息，很难直接应用相同的方法进行存储记忆。

外部知识. 为了获取更多信息，一些智能体会通过调用工具来获取外部知识，目的是将额外的相关知识转化为它们自己的记忆以辅助决策。例如，通过应用程序编程接口（API）访问外部知识是一种常见做法 [104, 5]。如今，像维基百科和 OpenWeatherMap 这样的大量公共

信息非常丰富。[4], 均可在线获取（免费或付费），并且可以通过 API 调用方便地访问。例如，在**第**3.1**节**示例任务 (A) 的 [步骤 2] 中，使用工具方法从数字杂志中获取外部知识。

在现有的模型中，Toolformer [125] 提出教导大型语言模型（LLM）使用工具，这可以获取外部知识以更好地解决问题。此外，ToolLLM [126] 赋予了 Llama [127] 使用 RapidAPI 中更多 API 的能力。[5] 并且启用多工具使用，提供一个通用接口以扩展智能体的能力。在 TPTU [110] 中，智能体被整合到任务规划和工具使用中，以便解决复杂问题。后续工作 [111] 进一步广泛提高其能力，例如检索。在 ToRA [128] 中，要求智能体解决数学问题。它们利用模仿学习来提高使用基于程序工具的能力。

上述方法通过允许智能体从多样化的来源访问最新的现实世界信息，显著提升了智能体的能力。然而，由于潜在的不准确性和偏见，这些信息的可靠性可能存在问题 [18]。此外，将工具集成到智能体中需要全面理解如何在各种上下文中解释检索到的信息，这可能导致更高的计算成本和在使外部数据与内部决策过程对齐时的复杂性增加。另外，使用外部 API 带来了关于隐私、数据安全以及遵守使用政策方面的担忧，需要严格的管理和监督 [18]。

5.2.2 参数形式的记忆

另一种方法是用参数形式表示记忆。它们不会占用提示词中额外的上下文长度，因此不受限于 LLM 上下文的长度限制。然而，参数化记忆形式仍在研究之中，我们将之前的工作分为两类：微调方法和记忆编辑方法。

微调方法。将外部知识融入智能体的记忆中，有助于在其一般知识之上丰富特定领域的知识。为了将领域知识注入到大语言模型（LLMs）中，监督微调是一种常见方法，它赋予智能体领域专家的记忆能力。这显著提高了智能体完成特定领域任务的能力。在**第** 3.1**节**示例的任务 (A) 中，任务前可以从杂志中微调关于景点的外部知识到 LLMs 的参数中。

在先前的工作中，Character-LLM [105] 专注于角色扮演环境。它利用与角色相关的数据（例如，经验）进行监督微调策略，以赋予智能体特定的角色特质和特征。Huatuo [107] 致力于为智能体赋能生物医学领域的专业能力。它尝试在中文医学知识库上对 Llama [127] 进行微调。此外，为了创建人工智能医生，DoctorGLM [129] 使用 LoRA [131] 对 ChatGLM [130] 进行微调；Radiology-GPT [132] 通过在标注的放射学数据集上进行监督微调来提升放射学分析领域的知识。而且，InvestLM [113] 收集投资数据并对其进行微调，以提高其在金融投资领域的特定能力。

微调方法可以有效地弥合通用智能体与专用智能体之间的差距。它提高了智能体在需要高精度和可靠性领域信息的任务上的能力。然而，针对特定领域的微调大型语言模型（LLMs）可能会导致过拟合，并且还引发了关于灾难性遗忘的担忧，即由于更新参数，LLMs 可能会忘记原始知识。微调的另一个局限性在于计算成本和时间消耗，以及对大量数据的需求。因此，大多数微调方法应用于离线场景，很少能处理在线场景，例如使用智能体观察和试验经验进行微调。由于频繁的智能体-环境交互，在线和动态交互的每一步都进行反向传播微调是不可负担的。

记忆编辑方法。除了微调方法外，另一种将记忆注入模型参数的方法是知识编辑 [133, 134]。与从特定数据集中提取模式的微调方法不同，知识编辑方法专门针对并调整需要改变的事实，确保无关知识不受影响。知识编辑方法更适合小规模的记忆调整。通常，它们的计算成本较低，因此更适合在线场景。在任务 (B) 的示例中，Alice 总是在晚上 9 点从智能体的记

[4] `https://openweathermap.org`

[5] `https://rapidapi.com/hub`

忆中看电影，但如果她最近改变了工作安排并且晚上 9 点不再空闲，则应编辑相关记忆（如晚上 9 点的习惯）。这可以通过知识编辑方法实现。

在先前的研究中，MAC [106] 旨在为在线场景设计一个有效且高效的内存适应框架。它利用元学习来替代最优化步骤。PersonalityEdit [135] 专注于编辑 LLMs 和智能体的个性，其中根据大五人格理论等理论改变它们的特征。MEND [134] 利用元学习的思想训练一个轻量级模型，该模型能够为预训练的语言模型的模型参数生成修改。APP [136] 研究添加新事实是否会导致现有事实的灾难性遗忘。它关注邻域扰动对内存添加的影响。此外，KnowledgeEditor [133] 通过基于学习更新问题公式化的方法训练一个超网络，以预测注入内存时模型参数的修改。Wang et al. [137]提出了一种新的最优化目标，以改变 LLM 的中毒知识，并同时保持总体性能。对于基于 LLM 的智能体，智能体可以通过知识编辑来改变不良记忆，这可以被视为一种遗忘机制。

知识编辑方法为更新大型语言模型 (LLMs) 参数中存储的信息提供了一种创新方式。通过专门针对并调整事实，这些方法可以在更新过程中确保非目标知识不受影响，从而减轻灾难性遗忘问题。此外，目标调整机制允许更高效且资源消耗更低的更新，使知识编辑成为高精度和实时修改的有吸引力的选择。然而，尽管有这些令人鼓舞的发展，元训练的计算成本以及无关记忆的保存仍然是重要的挑战。

5.2.3 文本记忆和参数记忆的优势与劣势

文本记忆和参数记忆各有优劣，使其适用于不同的记忆内容和应用场景。在本节中，我们将从各个方面讨论这两种记忆形式的优缺点。

有效性。文本记忆存储了关于智能体-环境交互的原始信息，这更加全面和详细。然而，它受到 LLM 提示的词元限制的约束，使得智能体难以存储大量信息。相比之下，参数记忆不受提示长度的限制，但在将文本转换为参数时可能会遭受信息丢失，并且复杂的记忆训练会带来额外的挑战。

效率。对于文本记忆，每次 LLM 推理都需要将记忆整合到上下文提示中，这会导致更高的成本和更长的处理时间。相比之下，对于参数化记忆，信息可以被整合到 LLM 的参数中，消除了这些上下文的额外成本。然而，参数化记忆在写入过程中会带来额外的成本，但文本记忆更容易编写，尤其是在小数据量的情况下。总而言之，文本记忆在写入时更高效，而参数化记忆在读取时更高效。

可解释性。文本记忆通常比参数化记忆更具可解释性，因为自然语言是人类理解和表达信息最自然和直接的策略，而参数化记忆通常以潜在空间表示。然而，这种可解释性是以信息密度为代价获得的。这是因为文本记忆中的词序列表示在离散空间中，不如参数化记忆中连续空间那样密集。

总之，这两类记忆之间的权衡使它们适用于不同的应用场景。例如，对于需要回忆最近交互的任务，如对话和上下文特定任务，文本记忆似乎更有效。对于需要大量记忆或已确立知识的任务，参数化记忆可能是一个更好的选择。

5.3 记忆操作

我们将整个记忆过程划分为三个操作：内存写入、内存管理和内存读取。这三个操作通常协同工作以实现内存功能，为 LLM 推理提供信息。我们在**表** 3中总结了之前关于内存操作的工作。

表 3: 总结内存操作。如果一个模型在内存操作上没有特殊设计，我们用 ∘ 标记它，否则用 ✓ 表示。× 表示论文中未讨论内存操作。

Models	Writing	Management			Reading
		Merging	Reflection	Forgetting	
MemoryBank [6]	✓	✓	✓	✓	✓
RET-LLM [7]	✓	×	×	×	✓
ChatDB [96]	✓	×	✓	×	✓
TiM [97]	✓	✓	×	✓	✓
SCM [98]	✓	✓	×	×	✓
Voyager [99]	✓	×	✓	×	✓
MemGPT [100]	✓	×	✓	×	✓
MemoChat [94]	✓	×	×	×	✓
MPC [101]	✓	×	×	×	✓
Generative Agents [83]	✓	×	✓	✓	✓
RecMind [102]	∘	×	×	×	✓
Retroformer [103]	✓	✓	✓	×	∘
ExpeL [82]	✓	✓	✓	×	∘
Synapse [91]	✓	×	×	×	✓
GITM [93]	∘	✓	✓	×	✓
ReAct [104]	∘	×	×	×	∘
Reflexion [5]	✓	✓	✓	×	∘
RecAgent [95]	✓	✓	✓	✓	✓
Character-LLM [105]	✓	×	×	×	∘
MAC [106]	✓	✓	✓	×	✓
Huatuo [107]	✓	×	×	×	∘
ChatDev [1]	✓	×	✓	×	✓
InteRecAgent [108]	✓	✓	✓	×	✓
MetaAgents [109]	✓	×	✓	×	✓
TPTU [110, 111]	∘	×	✓	×	✓
MetaGPT [112]	✓	×	✓	×	✓
S^3 [2]	✓	×	✓	✓	✓
InvestLM [113]	✓	×	×	×	∘

5.3.1 记忆书写

智能体感知信息后，会通过记忆写入操作将其中的一部分信息存储起来以供后续使用，关键是要识别出哪些信息是需要存储的。许多研究选择存储原始信息，而另一些研究还会将原始信息的摘要放入记忆模块中。

代表性研究。在 TiM [97] 中，原始信息将被提取为两个实体之间的关系，并存储在一个结构化数据库中。在写入数据库时，相似的内容会被存储在同一组中。在 SCM [98] 中，它设计了一个内存控制器来决定何时执行操作。该控制器作为整个内存模块的引导。在 MemGPT [100] 中，记忆写入完全是自主进行的。代理可以根据上下文自主更新记忆。在 MemoChat [94] 中，代理通过抽象主要讨论的主题并将其存储为索引记忆片段的关键字来总结每次对话段落。

讨论。先前的研究表明，在记忆写入操作期间设计信息提取策略至关重要 [94]。这是因为在原始信息通常冗长且嘈杂。此外，不同的环境可能提供各种形式的反馈，如何提取和表示信息以作为记忆对于记忆写入同样重要。

5.3.2 内存管理

对于人类来说，记忆信息在大脑中不断被处理和抽象化。智能体的记忆也可以通过反思来管理，以生成更高级别的记忆、合并冗余的记忆条目，并遗忘不重要的早期记忆。

代表性研究。在 MemoryBank [6] 中，智能体处理并提炼对话为日常事件的高级摘要，类似于人类回忆经验的关键方面。通过长期交互，它们不断评估和优化自己的知识，生成关于人格特征的每日洞察。在 Voyager [99] 中，智能体能够根据环境反馈来完善记忆。在 Generative Agents [83] 中，智能体可以进行反思以获取更高级的信息，这些抽象思维由智能体产生。当积累的事件足够多时，反思过程会被激活。对于 GITM [93]，在内存模块中进一步总结了多个计划中的关键动作，以便为各种情况建立共同参考计划。

讨论。大多数内存管理操作受人类大脑工作机理的启发。凭借大型语言模型（LLMs）模拟人类思维的强大能力，这些操作可以帮助智能体更好地生成高级信息并与环境进行交互。

5.3.3 记忆阅读

当智能体需要信息进行推理和决策时，记忆读取操作将从记忆中提取相关信息以供使用。因此，如何获取与当前状态相关的有用信息是重要的。由于记忆实体的数量庞大，并非所有实体都与当前状态相关，因此需要精心设计，以便根据相关性及其他面向任务的因子提取有用信息。

代表性研究。在 ChatDB [96] 中，内存读取操作由 SQL 语句执行。这些语句将由智能体提前作为一系列记忆链生成。在 MPC [101] 中，智能体可以从内存池中检索相关的内存。该方法还提出了提供思维链示例以忽略某些内存的方法。ExpeL [82] 利用 Faiss [124] 向量存储作为内存池，并获取与当前任务具有最高相似度分数的前 K 个成功轨迹。

讨论。在某种程度上，内存的读写操作是协作的，内存写入的形式极大地影响了内存读取的方法。对于文本内存的形式，大多数先前的工作使用文本相似度和其他辅助信息进行读取。对于参数内存的形式，现有的模型可能仅利用更新后的参数进行推理，这可以被视为一种隐式的读取过程。

6 如何评估基于 LLM 的智能体的记忆能力

如何有效评估记忆模块仍然是一个开放问题，在先前的工作中，根据不同的应用提出了多种评估策略。为清晰展示不同评估方法的共同思想，在本节中，我们总结了一个通用框架，该

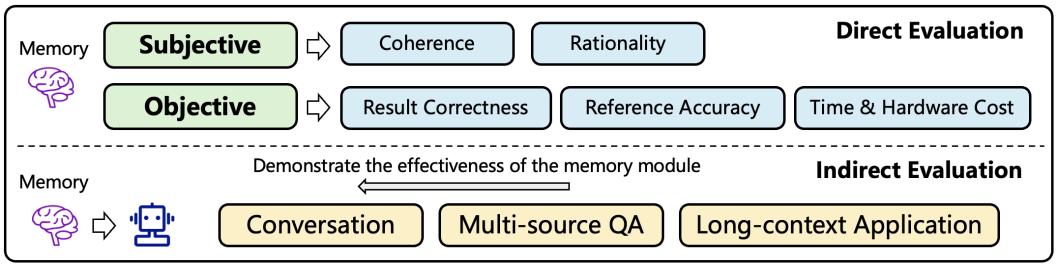

图 5: 内存模块的评估方法概述。

框架包括两种广泛的评估策略（详见**图** 5），即：（1）直接评估，它独立地衡量记忆模块的能力；（2）间接评估，通过端到端智能体任务来评估记忆模块。如果任务能够被有效地完成，则证明记忆模块是有用的。

6.1 直接评估

这类方法将智能体的记忆视为一个独立的组件，并独立评估其有效性。先前的研究可以分为两类：主观评估和客观评估。主观评估旨在根据人类的判断来衡量记忆的有效性，这在缺乏客观真实值的情景中可以广泛应用。客观评估则基于数值指标来评估记忆的有效性，这使得比较不同的记忆模块变得容易。

6.1.1 主观评价

在主观评估中，有两个关键问题，即（1）应评估哪些方面和（2）如何进行评估过程。首先，以下两个方面是最常见的用于评估内存模块的视角。

连贯性。这个方面是指回忆起的记忆是否自然且适合当前上下文。例如，如果智能体正在为 Alice 制定旅行计划，记忆应与她对旅行的偏好相关，而不是与工作相关。在先前的工作中，Modarressi et al. [7] 研究记忆模块是否能够在不断变化的知识中提供适当的引用。Liang et al. [98] 提供一些示例来展示当前查询与历史记忆之间的关系。Zhong et al. [6] 和 Liu et al. [97] 通过评分标签评估整合上下文和检索到的记忆的响应的连贯性。Lee et al. [101] 关注回忆起的记忆与上下文之间的矛盾。

合理性. 该方面旨在评估检索出的记忆是否合理。例如，如果智能体被问到“颐和园在哪里”，检索出的记忆应为“颐和园在北京”而不是“颐和园在月球上”。在之前的工作中，Lee et al. [101] 让众包工作者直接对检索出的记忆的合理性进行打分。Zhong et al. [6] 和 Liu et al. [97] 招募人工评估者来检查记忆是否包含当前问题的合理答案。

至于如何进行评估过程，有两个重要问题。第一个问题是如何选择人类评估者。一般来说，评估者应该熟悉评估任务，这确保了标注结果令人信服且可靠。此外，评估者的背景应多样化，以消除特定人群的主观偏见。第二个问题是如何为记忆模块的输出打分。通常，可以直接对结果评分 [6] 或在两个候选者之间进行比较 [95]。前者可以获得绝对且定量的评估结果，而后者可以在独立为每个候选者评分时消除标注噪声。此外，评分的粒度也应仔细设计。过于粗略的评分可能无法有效区分不同记忆模块的能力，而过于精细的评分可能会给工作人员带来更多的判断努力。

通常来说，主观评价可以在广泛的场景中使用，只需要定义好评价的方面，然后让招募的工人进行判断即可。由于工作人员可以提供判断的理由，这种方法通常更加可解释。然而，由于需要雇佣人类评估者，主观评价成本较高。此外，不同的评估者群体可能存在各种偏见，这使得结果难以再现和比较。

6.1.2 目标评估

在目标评估中，先前的工作通常定义数值指标来评估内存模块的有效性和效率。

结果正确性。该指标衡量智能体是否可以根据记忆模块直接成功回答预定义的问题。例如，问题可以是“爱丽丝今天去了哪里?”，选项为“A：颐和园”和“B：长城”。然后，智能体应根据问题和其记忆选择正确的答案。将智能体生成的答案与真实值进行比较。正式地说，准确率可以计算为

$$\text{Correctness} = \frac{1}{N}\sum_{i=1}^{N}\mathbb{I}\left[a_i = \hat{a}_i\right],$$

其中 N 是问题的数量，a_i 表示第 i 个问题的真实值，$\hat{a}_i$ 表示智能体给出的答案，$\mathbb{I}\left[a_i = \hat{a}_i\right]$ 是通常表示为的匹配函数

$$\mathbb{I}\left[a_i = \hat{a}_i\right] = \begin{cases} 1 & \text{if } a_i = \hat{a}_i, \\ 0 & \text{if } a_i \neq \hat{a}_i. \end{cases}$$

在先前的工作中，Hu et al. [96] 从带有标注真实值的历史记录中构建问题，并计算回忆的记忆是否能与正确答案匹配的准确率。同样地，Packer et al. [100] 生成只能从过去的会话中推导出的问题和答案，并将智能体的响应与真实值进行比较以计算准确率。

参考准确率。该指标评估智能体是否能够发现相关的记忆内容来回答问题。与上述关注最终结果的指标不同，参考准确率更关心支持智能体最终决策的中间信息。具体来说，它将检索到的记忆与预先准备的真实值进行比较。对于上述问题“爱丽丝今天去了哪里?”如果记忆内容包括（A）“爱丽丝今天和朋友在王府井吃午饭。”和（B）“爱丽丝今天午餐吃了烤鸭”，那么一个好的记忆模块应该选择（A）作为参考来回答问题。通常，研究者使用 F1 得分来评估参考准确率，其计算方式为

$$\text{F1} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}},$$

其中准确率和召回率的计算公式为 $\text{Precision} = \frac{\text{TP}}{\text{TP}+\text{FP}}$ 和 $\text{Recall} = \frac{\text{TP}}{\text{TP}+\text{FN}}$ 。其中，TP 表示真正例记忆内容的数量，FP 表示假正例记忆内容的数量，FN 表示假负例记忆内容的数量。在之前的工作中，Lu et al. [94] 使用 F1 得分来评估记忆检索过程，而 Zhong et al. [6] 关注于评估是否可以成功检索到相关记忆。

结果正确性和参考准确性都被用来评估内存模块的有效性。除了有效性之外，效率也是一个重要的方面，特别是在现实世界的应用中。因此，我们以下描述效率的评估方法。

时间和硬件成本。总时间成本包括用于内存适配和推理的时间。适配时间指的是内存写入和内存管理所花费的时间，而推理时间表示内存读取的时间延迟。具体来说，可以将内存操作的结束时间与开始时间之差视为时间消耗。形式上，每种操作的平均时间消耗可以表示为

$$\Delta\text{time} = \frac{1}{M}\sum_{i=1}^{M} t_i^{\text{end}} - t_i^{\text{start}},$$

其中 M 表示这些操作的数量，t_i^{end} 表示第 i 个操作的结束时间，而 t_i^{start} 表示该操作的开始时间。至于计算开销，可以通过峰值 GPU 内存分配来评估。在之前的工作中，Tack et al. [106] 利用峰值内存分配和适应时间来评估内存操作的效率。

目标评估为比较不同的记忆方法提供了数值策略，这对于设定该领域的基准和促进未来发展非常重要。

6.2 间接评估

除了上述直接评估记忆模块的方法之外，通过任务完成来评估也是一种流行的评估策略。这类方法背后的直觉是，如果智能体能够成功完成一个高度依赖记忆的任务，这就表明所设计的记忆模块是有效的。在接下来的部分中，我们将介绍几种代表性任务，这些任务以间接方式用于评估记忆模块。

6.2.1 对话

与人类进行对话是智能体最重要的应用之一，在这一过程中记忆起到了至关重要的作用。通过在记忆中存储上下文信息，智能体使用户能够体验个性化的对话，从而提高用户的满意度。因此，在确定智能体的其他部分后，对话任务的表现可以反映不同记忆模块的有效性。

在对话环境中，一致性与参与度是评估智能体记忆效果的两种常用方法。一致性指智能体的回答与上下文的一致性，因为对话过程中应尽量避免剧烈变化。例如，Lu et al. [94] 使用 GPT-4 对智能体在交互式对话中的一致性进行评分。参与度指用户被引导继续对话的程度。它反映了智能体回答的质量和吸引力，以及智能体塑造当前对话角色的能力。例如，Lee et al. [101] 通过 SCE-p 分数评估回答的参与度，Packer et al. [100] 利用 CSIM 分数评估记忆效果对提升用户参与度的影响。

6.2.2 多源问答

多源问答能够全面评估来自多个来源的记忆信息，包括试验内信息、跨试验信息和外部知识，侧重于对来自各种内容和来源的记忆利用的整合。

在先前的工作中，Yao et al. [104] 评估了从任务试验和维基百科的外部知识中整合信息的记忆。然后，Shinn et al. [5] 和 Yao et al. [103] 进一步包含了相同任务的跨试验信息，其中记忆被允许从前一次失败的试验中获得更多的经验。此外，Packer et al. [100] 允许智能体利用来自多文档信息的记忆进行问答。

通过评估多源问答任务，可以检验智能体在整合来自不同来源内容方面的能力，并揭示由于多个信息源而导致的记忆矛盾问题以及更新知识的问题，这些问题可能会影响记忆模块的性能。

6.2.3 长上下文应用

除了上述一般应用之外，在许多场景中，基于 LLM 的智能体必须根据极其冗长的提示做出决策。在这些场景中，冗长的提示通常被视为记忆内容，对驱动智能体行为起着重要作用。

在先前的工作中，Huang et al. [19] 组织了关于长上下文大语言模型的综合调查，提供了长上下文场景下评估指标的总结。此外，Shaham et al. [138] 提出了一个 zero-shot 基准，用于评估智能体对长上下文自然语言的理解能力。至于具体的长上下文任务，长上下文段落检索是评估智能体长上下文能力的重要任务之一。它要求智能体在长上下文中找到与给定问题或描述相对应的正确段落 [139]。长上下文摘要则是另一个代表性任务。它要求智能体对整个上下文形成全局理解，并根据描述进行总结，可以使用 ROUGE 等匹配分数上的某些指标来将结果与真实值进行比较。

长上下文应用的评估提供了更广泛的方法来评估智能体中记忆的功能，重点关注实际的下游场景。全面的基准 [138, 140] 还为长上下文理解能力提供了客观评估。

6.2.4 其他任务

除了上述三种主要的间接评估任务类型外，在一般任务中还有一些其他指标可以揭示记忆模块的有效性。

成功率指智能体能够成功解决的任务的比例。对于 Yao et al. [104], Shinn et al. [5]和 Zhao et al. [82]，它们评估通过推理和记忆在 AlfWorld [141] 中正确完成空间任务的数量。在 Zhu et al. [93]中，它们评估在 Minecraft 中生成不同物品的成功率以展示记忆的效果。此外，Shinn et al. [5]测量通过生成代码解决的问题的成功率，Zheng et al. [91]计算计算机控制的成功率和元素选择的准确性以展示轨迹作为示例记忆的功能。探索程度通常出现在探索性游戏中，反映智能体探索环境的程度。例如，Wang et al. [99]比较在 Minecraft 中探索的不同物品的数量以反映记忆中的技能学习。

事实上，几乎所有配备内存的智能体都可以通过消融研究来评估内存的效果，比较带/不带内存模块的性能。在特定场景下的评估可以更好地反映内存对实际下游应用的意义。

6.3 讨论

与直接评估相比，通过特定任务进行间接评估可能更容易开展，因为已经有许多公开的基准。然而，任务表现可以归因于各种因素，而记忆只是其中之一，这可能导致评估结果有偏。通过直接评估，可以独立评估内存模块的有效性，从而提高评估结果的可靠性。然而，据我们所知，针对基于 LLM 的智能体中的内存模块，没有开源的基准。

7 增强记忆的智能体应用

最近，基于 LLM 的智能体已在各种场景中得到研究，促进了社会进步。一般来说，大多数基于 LLM 的智能体都配备了内存模块。然而，这些内存组件的具体作用、存储的具体信息以及使用的实现方法在不同的应用中各不相同。为了为基于 LLM 的智能体的内存功能设计提供见解，在本节中，我们回顾并总结了内存机制在各种应用场景中的表现方式。具体来说，我们将它们分类为几个类别：角色扮演与社会仿真、个人助手、开放世界游戏、代码生成、推荐、特定领域的专家系统和其他应用。总结见**表** 4。

7.1 角色扮演和社会仿真

角色扮演代表了基于 LLM 的智能体的经典应用，其中记忆在智能体内部起着至关重要的作用。它赋予角色不同的特征，从而将它们彼此区分开来。许多先前的研究已经探索了构建角色记忆的方法 [105, 143, 145–147]. Shao et al. [105] 通过经验上传构建角色记忆，利用 SFT 将记忆注入模型参数中。Li et al. [143] 通过改进的提示和从剧本中提取的角色记忆增强用于角色扮演的大语言模型，其中用户查询和聊天机器人的响应被连结成一个序列作为记忆。Wang et al. [145] 将角色特定知识和回合记忆注入到基于 LLM 的智能体中，其中上下文问答对被连结成回合记忆。Zhao et al. [146] 旨在生成类似人类的响应，这些响应由从叙事中提取的人格特质指导，可以按相关性和重要性存储和检索。Zhou et al. [147] 为不同角色生成基于角色的对话，并通过 SFT 为基于 LLM 的智能体赋予相应的风格。

社交模拟基本上是角色扮演的扩展，更侧重于多智能体建模。记忆模块是此类应用的重要组成部分，有助于准确模拟人类动态行为。在先前的研究中，Kaiya et al. [148] 提出了一种用于社交场景中更好自我监控的 Summarize-and-Forget 记忆机制。Gao et al. [2] 关注社交网络仿真系统。系统中的每个智能体都有一个记忆池，该记忆池由来自在线平台的多样化用户消息组成，以识别用户。Li et al. [163] 维护对话上下文，包括前几个月的经济环境和智能体决策，以便模拟宏观经济趋势对智能体决策的影响，并使智能体掌握市场动态。Li et al.

表 4: 记忆增强型智能体应用的总结。

Applications	Models	Applications	Models
Role-playing	Character-LLM [105] ChatHaruhi [143] RoleLLM [145] NarrativePlay [146] CharacterGLM [147]	Code Generation	RTLFixer [142] GameGPT [144] ChatDev [1] MetaGPT [109] CodeAgent [114]
Social Simulation	Generative Agents [83] Lyfe Agents [148] S^3 [2] MetaAgents [109] WarAgent [150]	Recommendation	RecAgent [95] InteRecAgent [108] RecMind [102] AgentCF [149]
Personal Assistant	MemoryBank [6] RET-LLM [7] MemoChat [94] MemGPT [100] MPC [101] AutoGen [153] ChatDB [96] TiM [97] SCM [98]	Medicine	Huatuo [107] DoctorGLM [129] Radiology-GPT [132] Wang et al. [151] EHRAgent [152] ChatDoctor [115]
Game	Voyager [99] GITM [93] JARVIS [159] LARP [161]	Finance	InvestLM [113] TradingGPT [154] QuantAgent [155] FinMem [156] Koa et al. [157]
		Science	Chemist-X [158] ChemDFM [160] MatChat [162]

[109] 模拟人类社会中的求职场景，智能体的记忆最初包括个人资料和目标，并进一步丰富其他信息，如对话和个人反思。Hua et al. [150] 模拟参与战争的各国的决策及其后果，其中智能体的对话被持续保存到记忆中。

在为角色扮演和社交仿真设计智能体的记忆时，有几个见解。首先，记忆应与角色的特征保持一致，这可以用于识别每个角色并将其与其他角色区分开来。这对于提高角色扮演的真实性和社交仿真的多样性至关重要。其次，记忆应适当影响智能体随后的动作，以确保其行为的一致性和合理性。此外，对于类人智能体，其记忆机制应与人类记忆的特征相一致，例如遗忘以及长短期记忆，这些应参考认知心理学的理论。

7.2 个人助手

基于大语言模型的智能体非常适合创建个人助手，例如能够与用户进行长期对话的智能体 [94, 101, 153]，以及负责自动获取信息的智能体 [164]。这些智能体通常需要记住之前

的对话以保持一致性，并记住关键风格和事件，以便生成更个性化和相关的响应。Lu et al. [94] 通过保存对话内容和信息来保持对话上下文的一致性，这有助于通过检索找到适当的相关信息。Lee et al. [101] 概括对话以提取重要信息，存储它，并在将来推理时检索它。Pan et al. [164] 关注信息获取任务，设计记忆模块来存储用户上下文信息，并通过工具使用赋予外部知识能力。Wu et al. [153] 保留重要的上下文作为记忆以保持对话一致性。

总之，大多数个人助手的记忆实现方法都采用了文本形式的检索方法，因为它们在从对话片段中查找相关信息方面表现更好。对于记忆存储，智能体应记住用户-代理交互中的事实信息，以及用户的个人风格，以便生成针对用户情况定制的回复。此外，在回忆记忆时，智能体应识别并检索与当前查询和上下文相关的记忆。这一原则可以帮助智能体正确理解用户的需求，并在对话中保持一致性。

7.3 开放世界游戏

对于游戏和开放世界探索，基于 LLM 的智能体始终将试验后的观察结果作为任务上下文，并将经验存储在先前成功的试验中。通过利用过去的经验，智能体可以避免反复犯同样的错误，并对环境有更高级的理解，从而更有效地进行探索。其中一些智能体可以获取外部数据库或 API 以获得通用知识 [99, 93, 159, 161]。Wang et al. [99] 通过记忆保存在 Minecraft 中获得的技能，以便进一步使用。Zhu et al. [93] 存储并检索成功轨迹作为类似任务的示例，并通过 API 调用利用外部 Minecraft Wiki。Wang et al. [159] 构建多模态记忆作为知识库，并通过检索交互式经验为提示提供示例。Yan et al. [161] 维持工作记忆以辅助决策，保存并检索相关的过去经验，并实施外部数据集以获取通用知识。

总之，无论是 intra-trial 还是 inter-trial 的信息，记忆的关键方面在于反思过去的交互，并提炼出可以应用于后续探索的经验。除了通过自我参与的试验积累经验外，将吸收外部知识作为智能体记忆的一部分，也是增强智能体探索能力的重要途径。

7.4 代码生成

在代码生成的场景中，基于 LLM 的智能体可以从内存中搜索相关信息，从而获得更多的开发知识。它们可以为未来的问题保存先前的经验，并在会话式的开发界面中保持上下文 [142, 144, 1, 109]。Tsai et al. [142] 构建了一个外部非参数记忆数据库，存储了编译器错误和人类专家指令以实现自动语法错误修复。在 [144] 中，个人信息将被存储在内存中，并有助于保留上下文和知识以供决策。Qian et al. [1] 采用多智能体进行软件开发，每个角色都维护一个内存来存储与其他角色的过往对话。Li et al. [109] 同样关注软件开发，当发生错误时，代理可以从内存中检索其历史记录。Zhang et al. [114] 在遇到代码生成问题时可以搜索相关的信息。

通过利用外部资源，智能体可以学习与代码相关的知识并将其存储到记忆中，从而增强代码生成的能力。此外，记忆还可以提高代码生成的连续性和一致性。通过整合上下文记忆，智能体可以更好地理解软件开发的需求，从而提高生成代码的连贯性。此外，记忆对于代码的迭代最优化也至关重要，因为它可以根据历史记录识别开发者的 Target。

7.5 推荐

在推荐领域，一些先前的工作集中在模拟推荐系统中的用户 [95, 108]，其中内存可以表示现实世界中用户的个人资料和历史记录。另一些工作则试图提高推荐的性能，或提供其他形式的推荐界面 [149, 102]。Wang et al. [95] 在推荐场景中模拟用户行为，为推荐系统生成数据，这些代理将过去的观察结果和见解存储到分层内存中。在 Huang et al. [108]中，基于 LLM 的代理内存可以长期存档用户对话历史，并捕捉与当前提示相关的最近对话，以模拟交互式

推荐系统。它还使用演员-评论员反思来提高代理的鲁棒性。在 [149] 中，项目代理和用户代理配备了不同的内存，其中项目代理配备了动态内存模块，旨在捕获并保存与其内在属性及其采用者倾向相关的信息。对于用户代理，自适应内存更新机制在其操作与用户行为和偏好保持一致方面起着关键作用。Wang et al. [102] 记忆个性化的用户信息，如对项目的评论或评分，并通过网络搜索工具获取特定领域的知识和实时信息。

对于模拟推荐系统中的用户并捕捉其偏好，通过记忆保留个性化信息是至关重要的。一个关键的挑战在于如何将个性化信息和反馈与大型语言模型（LLMs）对齐，并将其存储到智能体的记忆中。这也是弥合传统推荐模型与大型语言模型之间差距的一项重要任务。

7.6 特定领域的专家系统

医学领域。在医学领域，之前的大多数工作都在基于大语言模型的智能体的记忆中赋予其外部知识 [107, 129, 132, 151, 115]。Wang et al. [107]以问答形式用医学知识图谱 CMeKG [165] 对 LLaMA [127] 进行微调，以增强其医学领域知识。Xiong et al. [129]采用 LoRA [131] 在医疗基础模型上进行高效微调。Wang et al. [151]使基于大语言模型的智能体能够获取基于文本的外部知识作为推理参考。此外，Shi et al. [152]基于过去经验中最相关的成功案例构建记忆，并使用相似度度量在医学领域中检索相关问题。

金融领域。一些先前的工作也将基于 LLM 的智能体应用于金融领域，其记忆可以存储金融知识 [113]、市场信息 [154, 156] 和成功经验 [157, 155]。Yang et al. [113] 构建金融投资数据集以微调 LLaMA [127]，从而赋予投资知识。Li et al. [154] 设计了一种分层记忆结构来存储不同类型营销信息。Wang et al. [155] 记录正在进行的交互（如交易和信息）以确保一致的响应，并记录先前输出作为经验，用于检索相关示例，为智能体提供多样化的学习上下文。Koa et al. [157] 存储过去的市场价格变动和解释，并对之前的试验进行反思。Yu et al. [156] 采用分层记忆机制以提供丰富的推理信息。

科学。在科学领域，一些现有工作设计了基于大型语言模型（LLM）的智能体，这些智能体在内存中存储了大量知识以解决问题 [158, 160, 162]。Chen et al. [158] 包括将分子数据库和在线文献作为外部知识纳入基于 LLM 的智能体的记忆，并在需要相关信息时检索它们。Zhao et al. [160] 和 Chen et al. [162] 分别通过在化学和结构材料领域的微调赋予领域知识能力。

要在特定的垂直领域构建基于智能体的专家系统，必须在它们的记忆中保留领域特定的知识。然而，存在几个挑战。首先，领域知识是专门化的，需要更高的准确率，这给构建记忆存储带来了困难。其次，领域知识通常是时间敏感的，可能会在未来过时。因此，当部分知识过时时，需要对记忆进行部分更新。此外，大量的领域知识使得根据当前查询从记忆中检索变得困难。

7.7 其他应用

有一些其他基于 LLM 的智能体中记忆的应用。Wang et al. [166] 专注于云根因分析任务，使用记忆存储框架规则、任务需求、工具文档、few-shot 示例和智能体观察结果。Qiang et al. [167] 解决本体匹配问题。智能体保存会话对话并构建一个理性数据库以检索外部知识。Wen et al. [168] 研究自动驾驶，其记忆模块由向量数据库构建，并包含过去驾驶场景的经验。Wang et al. [169] 提出改进用户验收测试，该测试采用自我反思机制。在每次试验后，操作智能体总结对话并更新记忆池，直到完成当前步骤的目标。

对于不同的应用，记忆的重点各不相同，因为它本质上服务于下游任务。因此，设计时也应考虑任务的需求。

8 局限性 & 未来方向

8.1 参数记忆的更多进展

目前，基于 LLM 的智能体的记忆主要以文本形式存在，特别是在观察记录、试验经验以及文本知识数据库等上下文知识方面。尽管文本记忆具有可解释性强、易于扩展和编辑的优点，但与参数化记忆相比，在效率上有所牺牲。本质上，参数化记忆具有更高的信息密度，在潜在空间中通过连续实数向量表达语义，而文本记忆则通过离散空间中的词元组合来表达语义。因此，参数化记忆提供了更丰富的表达空间，并且其软编码比词元序列的硬编码形式更加鲁棒。此外，参数化记忆在存储效率上更高，它不需要像文本记忆那样显式地存储大量文本，类似于一种知识压缩过程。至于记忆管理，如合并和反射等操作，参数化记忆不一定需要像文本记忆那样设计手动规则，而是可以采用最优化方法隐式地学习这些过程。而且，可插拔的参数化记忆类似于一张数字生命卡，能够赋予智能体所需的特性。例如，Huatuo [107] 旨在通过在中国医学知识库上微调 Llama [127] 模型，增强智能体在生物医学领域的专业知识。MAC [106] 旨在为在线情景设计一个参数化记忆适配框架，使用元学习技术取代传统的最优化阶段。

尽管参数化记忆前景广阔，但目前也面临着诸多挑战。其中首要的问题是效率：如何有效地将文本信息转化为参数或参数的修改是一个关键问题。目前，研究人员可以通过 SFT 将大量领域知识转移到 LLM 的参数中。然而，这种方法耗时且需要大量的文本语料库，因此不适合情境知识。一个可行的方法是采用元学习让模型学会记忆。例如，MEND [134] 利用元学习方法训练了一个紧凑型模型，该模型能够为预训练语言模型的参数生成调整。此外，与参数化记忆相关的缺乏可解释性可能成为一个障碍，特别是在需要高度信任的领域（如医学）中。因此，增强参数化记忆的可信度和可解释性是一个亟待解决的问题。

8.2 基于 LLM 的多智能体应用中的记忆

探索 LLMs 中记忆机制的研究已蓬勃发展为多智能体系统（MAS）的动态领域，标志着在同步、通信和信息不对称管理方面取得了重大进展。在协作场景中出现的一个关键方面是智能体之间的记忆同步。这一过程对于建立统一的知识库、确保不同智能体决策一致性至关重要。例如，Chen et al. [170] 强调了将同步记忆模块集成到多机器人协作中的重要性。另一个重要的方面是智能体间的通信，这严重依赖于记忆来保持上下文并解释消息。例如，Mandi et al. [171] 展示了记忆驱动的通信框架，促进了智能体之间的共同理解。除了协作场景，一些研究还关注竞争场景，信息不对称成为一个关键问题 [172]。

展望未来，基于大型语言模型（LLM）的多智能体系统（MAS）在记忆方面的进步正处于技术创新与战略应用的交汇点。这呼唤着对新型记忆模块的探索，这些模块能够进一步提升代理同步性、实现更有效的沟通，并在信息丰富的环境中提供战略优势。开发这样的记忆模型不仅需要解决当前的记忆整合和管理挑战，还需要挖掘记忆在促进更强大、智能和适应性强的 MAS 方面尚未被充分利用的潜力。正如开创性研究所示，基于 LLM 的 MAS 的演变格局为未来在记忆利用和管理方面的创新提供了充满希望的舞台。这种探索有望揭示记忆整合的新维度，突破目前的局限，并在 MAS 领域设定新的基准。

8.3 基于记忆的终身学习

终身学习是人工智能的一个高级主题，扩展了智能体在其一生中不断学习的能力 [173]。智能体可以持续与环境交互，持久地观察环境，并获取外部知识，从而实现一种类似于人类的增强模式。智能体的记忆对于实现终身学习至关重要，因为它需要学会存储和应用过去的观测结果。基于 LLM 的智能体的终身学习具有重要的实际价值，例如在长期社会仿真和个人

辅助方面。然而，它也面临一些挑战。首先，终身学习是时序性的，要求智能体的记忆能够捕捉时序性。这种时序性可能导致记忆之间的相互作用，如记忆重叠。此外，由于终身学习的时间跨度较长，它需要存储大量的记忆并在需要时检索它们，可能还需要某种遗忘机制。

8.4 人形智能体的记忆

一个类人智能体指的是被设计为表现出与人类一致行为的智能体，从而促进其在社会仿真、人类行为研究以及角色扮演中的应用。与任务导向型智能体不同，通常更倾向于更高的能力，类人智能体的能力应该尽可能接近人类。因此，类人智能体的记忆应与人类的认知过程相匹配，并遵循诸如记忆扭曲和遗忘等心理学原理。此外，类人智能体应具备知识边界，这意味着它们的知识应与其所模仿的实体相符。例如，在角色扮演场景中，一个代表儿童的智能体不应具备超出该年龄段典型水平的高级数学概念或其他复杂知识 [174].

9 结论

在这篇综述中，我们系统地回顾了基于 LLM 的智能体的记忆机制，重点介绍了三个关键问题，包括“是什么”、“为什么需要”以及“如何设计和评估”基于 LLM 的智能体中的记忆模块。为了展示智能体记忆的重要性，我们还展示了许多典型应用，在这些应用中，记忆模块发挥了重要作用。我们相信这篇综述可以为该领域的新人提供有价值的参考，并希望它能激发更多先进的记忆机制来增强基于 LLM 的智能体。

致谢

我们感谢王磊为本综述进行校对并提出宝贵建议。

参考文献

[1] Chen Qian, Xin Cong, Cheng Yang, Weize Chen, Yusheng Su, Juyuan Xu, Zhiyuan Liu, and Maosong Sun. Communicative agents for software development. arXiv preprint arXiv:2307.07924, 2023.

[2] Chen Gao, Xiaochong Lan, Zhihong Lu, Jinzhu Mao, Jinghua Piao, Huandong Wang, Depeng Jin, and Yong Li. S^3: Social-network simulation system with large language model-empowered agents. arXiv preprint arXiv:2307.14984, 2023.

[3] Lei Wang, Chen Ma, Xueyang Feng, Zeyu Zhang, Hao Yang, Jingsen Zhang, Zhiyuan Chen, Jiakai Tang, Xu Chen, Yankai Lin, et al. A survey on large language model based autonomous agents. arXiv preprint arXiv:2308.11432, 2023.

[4] Zhiheng Xi, Wenxiang Chen, Xin Guo, Wei He, Yiwen Ding, Boyang Hong, Ming Zhang, Junzhe Wang, Senjie Jin, Enyu Zhou, et al. The rise and potential of large language model based agents: A survey. arXiv preprint arXiv:2309.07864, 2023.

[5] Noah Shinn, Federico Cassano, Ashwin Gopinath, Karthik R Narasimhan, and Shunyu Yao. Reflexion: Language agents with verbal reinforcement learning. In Thirty-seventh Conference on Neural Information Processing Systems, 2023.

[6] Wanjun Zhong, Lianghong Guo, Qiqi Gao, and Yanlin Wang. Memorybank: Enhancing large language models with long-term memory. arXiv preprint arXiv:2305.10250, 2023.

[7] Ali Modarressi, Ayyoob Imani, Mohsen Fayyaz, and Hinrich Schütze. Ret-llm: Towards a general read-write memory for large language models. arXiv preprint arXiv:2305.14322, 2023.

[8] Shengyu Zhang, Linfeng Dong, Xiaoya Li, Sen Zhang, Xiaofei Sun, Shuhe Wang, Jiwei Li, Runyi Hu, Tianwei Zhang, Fei Wu, et al. Instruction tuning for large language models: A survey. arXiv preprint arXiv:2308.10792, 2023.

[9] Tianhao Shen, Renren Jin, Yufei Huang, Chuang Liu, Weilong Dong, Zishan Guo, Xinwei Wu, Yan Liu, and Deyi Xiong. Large language model alignment: A survey. arXiv preprint arXiv:2309.15025, 2023.

[10] Yufei Wang, Wanjun Zhong, Liangyou Li, Fei Mi, Xingshan Zeng, Wenyong Huang, Lifeng Shang, Xin Jiang, and Qun Liu. Aligning large language models with human: A survey. arXiv preprint arXiv:2307.12966, 2023.

[11] Yang Liu, Yuanshun Yao, Jean-Francois Ton, Xiaoying Zhang, Ruocheng Guo Hao Cheng, Yegor Klochkov, Muhammad Faaiz Taufiq, and Hang Li. Trustworthy llms: a survey and guideline for evaluating large language models' alignment. arXiv preprint arXiv:2308.05374, 2023.

[12] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. arXiv preprint arXiv:2312.10997, 2023.

[13] Song Wang, Yaochen Zhu, Haochen Liu, Zaiyi Zheng, Chen Chen, et al. Knowledge editing for large language models: A survey. arXiv preprint arXiv:2310.16218, 2023.

[14] Yunzhi Yao, Peng Wang, Bozhong Tian, Siyuan Cheng, Zhoubo Li, Shumin Deng, Huajun Chen, and Ningyu Zhang. Editing large language models: Problems, methods, and opportunities. arXiv preprint arXiv:2305.13172, 2023.

[15] Peng Wang, Ningyu Zhang, Xin Xie, Yunzhi Yao, Bozhong Tian, Mengru Wang, Zekun Xi, Siyuan Cheng, Kangwei Liu, Guozhou Zheng, et al. Easyedit: An easy-to-use knowledge editing framework for large language models. arXiv preprint arXiv:2308.07269, 2023.

[16] Zhangyin Feng, Weitao Ma, Weijiang Yu, Lei Huang, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, et al. Trends in integration of knowledge and large language models: A survey and taxonomy of methods, benchmarks, and applications. arXiv preprint arXiv:2311.05876, 2023.

[17] Ningyu Zhang, Yunzhi Yao, Bozhong Tian, Peng Wang, Shumin Deng, Mengru Wang, Zekun Xi, Shengyu Mao, Jintian Zhang, Yuansheng Ni, et al. A comprehensive study of knowledge editing for large language models. arXiv preprint arXiv:2401.01286, 2024.

[18] Yujia Qin, Shengding Hu, Yankai Lin, Weize Chen, Ning Ding, Ganqu Cui, Zheni Zeng, Yufei Huang, Chaojun Xiao, Chi Han, et al. Tool learning with foundation models. arXiv preprint arXiv:2304.08354, 2023.

[19] Yunpeng Huang, Jingwei Xu, Zixu Jiang, Junyu Lai, Zenan Li, Yuan Yao, Taolue Chen, Lijuan Yang, Zhou Xin, and Xiaoxing Ma. Advancing transformer architecture in long-context large language models: A comprehensive survey. arXiv preprint arXiv:2311.12351, 2023.

[20] Xindi Wang, Mahsa Salmani, Parsa Omidi, Xiangyu Ren, Mehdi Rezagholizadeh, and Armaghan Eshaghi. Beyond the limits: A survey of techniques to extend the context length in large language models. arXiv preprint arXiv:2402.02244, 2024.

[21] Saurav Pawar, SM Tonmoy, SM Zaman, Vinija Jain, Aman Chadha, and Amitava Das. The what, why, and how of context length extension techniques in large language models–a detailed survey. arXiv preprint arXiv:2401.07872, 2024.

[22] Jiayang Wu, Wensheng Gan, Zefeng Chen, Shicheng Wan, and S Yu Philip. Multimodal large language models: A survey. In 2023 IEEE International Conference on Big Data (BigData), pages 2247–2256. IEEE, 2023.

[23] Shezheng Song, Xiaopeng Li, and Shasha Li. How to bridge the gap between modalities: A comprehensive survey on multimodal large language model. arXiv preprint arXiv:2311.07594, 2023.

[24] Davide Caffagni, Federico Cocchi, Luca Barsellotti, Nicholas Moratelli, Sara Sarto, Lorenzo Baraldi, Marcella Cornia, and Rita Cucchiara. The (r) evolution of multimodal large language models: A survey. arXiv preprint arXiv:2402.12451, 2024.

[25] Shukang Yin, Chaoyou Fu, Sirui Zhao, Ke Li, Xing Sun, Tong Xu, and Enhong Chen. A survey on multimodal large language models. arXiv preprint arXiv:2306.13549, 2023.

[26] Guangji Bai, Zheng Chai, Chen Ling, Shiyu Wang, Jiaying Lu, Nan Zhang, Tingwei Shi, Ziyang Yu, Mengdan Zhu, Yifei Zhang, et al. Beyond efficiency: A systematic survey of resource-efficient large language models. arXiv preprint arXiv:2401.00625, 2024.

[27] Zhongwei Wan, Xin Wang, Che Liu, Samiul Alam, Yu Zheng, Zhongnan Qu, Shen Yan, Yi Zhu, Quanlu Zhang, Mosharaf Chowdhury, et al. Efficient large language models: A survey. arXiv preprint arXiv:2312.03863, 1, 2023.

[28] Xupeng Miao, Gabriele Oliaro, Zhihao Zhang, Xinhao Cheng, Hongyi Jin, Tianqi Chen, and Zhihao Jia. Towards efficient generative large language model serving: A survey from algorithms to systems. arXiv preprint arXiv:2312.15234, 2023.

[29] Lingling Xu, Haoran Xie, Si-Zhao Joe Qin, Xiaohui Tao, and Fu Lee Wang. Parameter-efficient fine-tuning methods for pretrained language models: A critical review and assessment. arXiv preprint arXiv:2312.12148, 2023.

[30] Xunyu Zhu, Jian Li, Yong Liu, Can Ma, and Weiping Wang. A survey on model compression for large language models. arXiv preprint arXiv:2308.07633, 2023.

[31] Canwen Xu and Julian McAuley. A survey on model compression and acceleration for pretrained language models. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 37, pages 10566–10575, 2023.

[32] Wenxiao Wang, Wei Chen, Yicong Luo, Yongliu Long, Zhengkai Lin, Liye Zhang, Binbin Lin, Deng Cai, and Xiaofei He. Model compression and efficient inference for large language models: A survey. arXiv preprint arXiv:2402.09748, 2024.

[33] Seungcheol Park, Jaehyeon Choi, Sojin Lee, and U Kang. A comprehensive survey of compression algorithms for language models. arXiv preprint arXiv:2401.15347, 2024.

[34] Yupeng Chang, Xu Wang, Jindong Wang, Yuan Wu, Linyi Yang, Kaijie Zhu, Hao Chen, Xiaoyuan Yi, Cunxiang Wang, Yidong Wang, et al. A survey on evaluation of large language models. ACM Transactions on Intelligent Systems and Technology, 2023.

[35] Zishan Guo, Renren Jin, Chuang Liu, Yufei Huang, Dan Shi, Linhao Yu, Yan Liu, Jiaxuan Li, Bojian Xiong, Deyi Xiong, et al. Evaluating large language models: A comprehensive survey. arXiv preprint arXiv:2310.19736, 2023.

[36] Jingfeng Yang, Hongye Jin, Ruixiang Tang, Xiaotian Han, Qizhang Feng, Haoming Jiang, Bing Yin, and Xia Hu. Harnessing the power of llms in practice: A survey on chatgpt and beyond. arXiv preprint arXiv:2304.13712, 2023.

[37] Yutao Zhu, Huaying Yuan, Shuting Wang, Jiongnan Liu, Wenhan Liu, Chenlong Deng, Zhicheng Dou, and Ji-Rong Wen. Large language models for information retrieval: A survey. arXiv preprint arXiv:2308.07107, 2023.

[38] Derong Xu, Wei Chen, Wenjun Peng, Chao Zhang, Tong Xu, Xiangyu Zhao, Xian Wu, Yefeng Zheng, and Enhong Chen. Large language models for generative information extraction: A survey. arXiv preprint arXiv:2312.17617, 2023.

[39] Angela Fan, Beliz Gokkaya, Mark Harman, Mitya Lyubarskiy, Shubho Sengupta, Shin Yoo, and Jie M Zhang. Large language models for software engineering: Survey and open problems. arXiv preprint arXiv:2310.03533, 2023.

[40] Junjie Wang, Yuchao Huang, Chunyang Chen, Zhe Liu, Song Wang, and Qing Wang. Software testing with large language models: Survey, landscape, and vision. IEEE Transactions on Software Engineering, 2024.

[41] Zibin Zheng, Kaiwen Ning, Yanlin Wang, Jingwen Zhang, Dewu Zheng, Mingxi Ye, and Jiachi Chen. A survey of large language models for code: Evolution, benchmarking, and future trends. arXiv preprint arXiv:2311.10372, 2023.

[42] Fanlong Zeng, Wensheng Gan, Yongheng Wang, Ning Liu, and Philip S Yu. Large language models for robotics: A survey. arXiv preprint arXiv:2311.07226, 2023.

[43] Can Cui, Yunsheng Ma, Xu Cao, Wenqian Ye, Yang Zhou, Kaizhao Liang, Jintai Chen, Juanwu Lu, Zichong Yang, Kuei-Da Liao, et al. A survey on multimodal large language models for autonomous driving. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, pages 958–979, 2024.

[44] Zhenjie Yang, Xiaosong Jia, Hongyang Li, and Junchi Yan. A survey of large language models for autonomous driving. arXiv preprint arXiv:2311.01043, 2023.

[45] Kai He, Rui Mao, Qika Lin, Yucheng Ruan, Xiang Lan, Mengling Feng, and Erik Cambria. A survey of large language models for healthcare: from data, technology, and applications to accountability and ethics. arXiv preprint arXiv:2310.05694, 2023.

[46] Hongjian Zhou, Boyang Gu, Xinyu Zou, Yiru Li, Sam S Chen, Peilin Zhou, Junling Liu, Yining Hua, Chengfeng Mao, Xian Wu, et al. A survey of large language models in medicine: Progress, application, and challenge. arXiv preprint arXiv:2311.05112, 2023.

[47] Benyou Wang, Qianqian Xie, Jiahuan Pei, Zhihong Chen, Prayag Tiwari, Zhao Li, and Jie Fu. Pre-trained language models in biomedical domain: A systematic survey. ACM Computing Surveys, 56(3):1–52, 2023.

[48] Yinheng Li, Shaofei Wang, Han Ding, and Hang Chen. Large language models in finance: A survey. In Proceedings of the Fourth ACM International Conference on AI in Finance, pages 374–382, 2023.

[49] Tianyu He, Guanghui Fu, Yijing Yu, Fan Wang, Jianqiang Li, Qing Zhao, Changwei Song, Hongzhi Qi, Dan Luo, Huijing Zou, et al. Towards a psychological generalist ai: A survey of current applications of large language models and future prospects. arXiv preprint arXiv:2312.04578, 2023.

[50] Lei Li, Yongfeng Zhang, Dugang Liu, and Li Chen. Large language models for generative recommendation: A survey and visionary discussions. arXiv preprint arXiv:2309.01157, 2023.

[51] Jianghao Lin, Xinyi Dai, Yunjia Xi, Weiwen Liu, Bo Chen, Xiangyang Li, Chenxu Zhu, Huifeng Guo, Yong Yu, Ruiming Tang, et al. How can recommender systems benefit from large language models: A survey. arXiv preprint arXiv:2306.05817, 2023.

[52] Wenjie Wang, Xinyu Lin, Fuli Feng, Xiangnan He, and Tat-Seng Chua. Generative recommendation: Towards next-generation recommender paradigm. arXiv preprint arXiv:2304.03516, 2023.

[53] Yue Zhang, Yafu Li, Leyang Cui, Deng Cai, Lemao Liu, Tingchen Fu, Xinting Huang, Enbo Zhao, Yu Zhang, Yulong Chen, et al. Siren's song in the ai ocean: a survey on hallucination in large language models. arXiv preprint arXiv:2309.01219, 2023.

[54] Lei Huang, Weijiang Yu, Weitao Ma, Weihong Zhong, Zhangyin Feng, Haotian Wang, Qianglong Chen, Weihua Peng, Xiaocheng Feng, Bing Qin, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions. arXiv preprint arXiv:2311.05232, 2023.

[55] Vipula Rawte, Amit Sheth, and Amitava Das. A survey of hallucination in large foundation models. arXiv preprint arXiv:2309.05922, 2023.

[56] Hongbin Ye, Tong Liu, Aijia Zhang, Wei Hua, and Weiqiang Jia. Cognitive mirage: A review of hallucinations in large language models. arXiv preprint arXiv:2309.06794, 2023.

[57] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12):1–38, 2023.

[58] SM Tonmoy, SM Zaman, Vinija Jain, Anku Rani, Vipula Rawte, Aman Chadha, and Amitava Das. A comprehensive survey of hallucination mitigation techniques in large language models. arXiv preprint arXiv:2401.01313, 2024.

[59] Xuhui Jiang, Yuxing Tian, Fengrui Hua, Chengjin Xu, Yuanzhuo Wang, and Jian Guo. A survey on large language model hallucination via a creativity perspective. arXiv preprint arXiv:2402.06647, 2024.

[60] Isabel O Gallegos, Ryan A Rossi, Joe Barrow, Md Mehrab Tanjim, Sungchul Kim, Franck Dernoncourt, Tong Yu, Ruiyi Zhang, and Nesreen K Ahmed. Bias and fairness in large language models: A survey. arXiv preprint arXiv:2309.00770, 2023.

[61] Hadas Kotek, Rikker Dockum, and David Sun. Gender bias and stereotypes in large language models. In Proceedings of The ACM Collective Intelligence Conference, pages 12–24, 2023.

[62] Yingji Li, Mengnan Du, Rui Song, Xin Wang, and Ying Wang. A survey on fairness in large language models. arXiv preprint arXiv:2308.10149, 2023.

[63] Haiyan Zhao, Hanjie Chen, Fan Yang, Ninghao Liu, Huiqi Deng, Hengyi Cai, Shuaiqiang Wang, Dawei Yin, and Mengnan Du. Explainability for large language models: A survey. ACM Transactions on Intelligent Systems and Technology, 2023.

[64] Yifan Yao, Jinhao Duan, Kaidi Xu, Yuanfang Cai, Eric Sun, and Yue Zhang. A survey on large language model (llm) security and privacy: The good, the bad, and the ugly. arXiv preprint arXiv:2312.02003, 1, 2023.

[65] Erfan Shayegani, Md Abdullah Al Mamun, Yu Fu, Pedram Zaree, Yue Dong, and Nael Abu-Ghazaleh. Survey of vulnerabilities in large language models revealed by adversarial attacks. arXiv preprint arXiv:2310.10844, 2023.

[66] Seth Neel and Peter Chang. Privacy issues in large language models: A survey. arXiv preprint arXiv:2312.06717, 2023.

[67] Victoria Smith, Ali Shahin Shamsabadi, Carolyn Ashurst, and Adrian Weller. Identifying and mitigating privacy risks stemming from language models: A survey. arXiv preprint arXiv:2310.01424, 2023.

[68] Zhichen Dong, Zhanhui Zhou, Chao Yang, Jing Shao, and Yu Qiao. Attacks, defenses and evaluations for llm conversation safety: A survey. arXiv preprint arXiv:2402.09283, 2024.

[69] Badhan Chandra Das, M Hadi Amini, and Yanzhao Wu. Security and privacy challenges of large language models: A survey. arXiv preprint arXiv:2402.00888, 2024.

[70] Wayne Xin Zhao, Kun Zhou, Junyi Li, Tianyi Tang, Xiaolei Wang, Yupeng Hou, Yingqian Min, Beichen Zhang, Junjie Zhang, Zican Dong, et al. A survey of large language models. arXiv preprint arXiv:2303.18223, 2023.

[71] Muhammad Usman Hadi, Rizwan Qureshi, Abbas Shah, Muhammad Irfan, Anas Zafar, Muhammad Bilal Shaikh, Naveed Akhtar, Jia Wu, Seyedali Mirjalili, et al. A survey on large language models: Applications, challenges, limitations, and practical usage. Authorea Preprints, 2023.

[72] Bonan Min, Hayley Ross, Elior Sulem, Amir Pouran Ben Veyseh, Thien Huu Nguyen, Oscar Sainz, Eneko Agirre, Ilana Heintz, and Dan Roth. Recent advances in natural language processing via large pre-trained language models: A survey. ACM Computing Surveys, 56(2):1–40, 2023.

[73] Grégoire Mialon, Roberto Dessì, Maria Lomeli, Christoforos Nalmpantis, Ram Pasunuru, Roberta Raileanu, Baptiste Rozière, Timo Schick, Jane Dwivedi-Yu, Asli Celikyilmaz, et al. Augmented language models: a survey. arXiv preprint arXiv:2302.07842, 2023.

[74] Xu Huang, Weiwen Liu, Xiaolong Chen, Xingmei Wang, Hao Wang, Defu Lian, Yasheng Wang, Ruiming Tang, and Enhong Chen. Understanding the planning of llm agents: A survey. arXiv preprint arXiv:2402.02716, 2024.

[75] Taicheng Guo, Xiuying Chen, Yaqi Wang, Ruidi Chang, Shichao Pei, Nitesh V Chawla, Olaf Wiest, and Xiangliang Zhang. Large language model based multi-agents: A survey of progress and challenges. arXiv preprint arXiv:2402.01680, 2024.

[76] Yuanchun Li, Hao Wen, Weijun Wang, Xiangyu Li, Yizhen Yuan, Guohong Liu, Jiacheng Liu, Wenxing Xu, Xiang Wang, Yi Sun, et al. Personal llm agents: Insights and survey about the capability, efficiency and security. arXiv preprint arXiv:2401.05459, 2024.

[77] Pengyu Zhao, Zijian Jin, and Ning Cheng. An in-depth survey of large language model-based artificial intelligence agents. arXiv preprint arXiv:2309.14365, 2023.

[78] Yuheng Cheng, Ceyao Zhang, Zhengwen Zhang, Xiangrui Meng, Sirui Hong, Wenhao Li, Zihao Wang, Zekai Wang, Feng Yin, Junhua Zhao, et al. Exploring large language model based intelligent agents: Definitions, methods, and prospects. arXiv preprint arXiv:2401.03428, 2024.

[79] Zane Durante, Qiuyuan Huang, Naoki Wake, Ran Gong, Jae Sung Park, Bidipta Sarkar, Rohan Taori, Yusuke Noda, Demetri Terzopoulos, Yejin Choi, et al. Agent ai: Surveying the horizons of multimodal interaction. arXiv preprint arXiv:2401.03568, 2024.

[80] Yingqiang Ge, Yujie Ren, Wenyue Hua, Shuyuan Xu, Juntao Tan, and Yongfeng Zhang. Llm as os (llmao), agents as apps: Envisioning aios, agents and the aios-agent ecosystem. arXiv preprint arXiv:2312.03815, 2023.

[81] Ning Ding, Yujia Qin, Guang Yang, Fuchao Wei, Zonghan Yang, Yusheng Su, Shengding Hu, Yulin Chen, Chi-Min Chan, Weize Chen, et al. Delta tuning: A comprehensive study of parameter efficient methods for pre-trained language models. arXiv preprint arXiv:2203.06904, 2022.

[82] Andrew Zhao, Daniel Huang, Quentin Xu, Matthieu Lin, Yong-Jin Liu, and Gao Huang. Expel: Llm agents are experiential learners. arXiv preprint arXiv:2308.10144, 2023.

[83] Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S Bernstein. Generative agents: Interactive simulacra of human behavior. In Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology, pages 1–22, 2023.

[84] Robert L Solso and Jerome Kagan. Cognitive psychology. Houghton Mifflin Harcourt P, 1979.

[85] Fergus IM Craik and Robert S Lockhart. Levels of processing: A framework for memory research. Journal of verbal learning and verbal behavior, 11(6):671–684, 1972.

[86] Selma Leydesdorff. Memory cultures: Memory, subjectivity and recognition. Routledge, 2017.

[87] Philip Nicholas Johnson-Laird. Mental models: Towards a cognitive science of language, inference, and consciousness. Number 6. Harvard University Press, 1983.

[88] John E Laird. The Soar cognitive architecture. MIT press, 2019.

[89] Ron Sun. Duality of the mind: A bottom-up approach toward cognition. Psychology Press, 2001.

[90] Richard S Sutton and Andrew G Barto. Reinforcement learning: An introduction. MIT press, 2018.

[91] Longtao Zheng, Rundong Wang, Xinrun Wang, and Bo An. Synapse: Trajectory-as-exemplar prompting with memory for computer control. In NeurIPS 2023 Foundation Models for Decision Making Workshop, 2023.

[92] Ali Montazeralghaem, Hamed Zamani, and James Allan. A reinforcement learning framework for relevance feedback. In Proceedings of the 43rd international acm sigir conference on research and development in information retrieval, pages 59–68, 2020.

[93] Xizhou Zhu, Yuntao Chen, Hao Tian, Chenxin Tao, Weijie Su, Chenyu Yang, Gao Huang, Bin Li, Lewei Lu, Xiaogang Wang, et al. Ghost in the minecraft: Generally capable agents for open-world enviroments via large language models with text-based knowledge and memory. arXiv preprint arXiv:2305.17144, 2023.

[94] Junru Lu, Siyu An, Mingbao Lin, Gabriele Pergola, Yulan He, Di Yin, Xing Sun, and Yunsheng Wu. Memochat: Tuning llms to use memos for consistent long-range open-domain conversation. arXiv preprint arXiv:2308.08239, 2023.

[95] Lei Wang, Jingsen Zhang, Hao Yang, Zhiyuan Chen, Jiakai Tang, Zeyu Zhang, Xu Chen, Yankai Lin, Ruihua Song, Wayne Xin Zhao, Jun Xu, Zhicheng Dou, Jun Wang, and Ji-Rong Wen. When large language model based agent meets user behavior analysis: A novel user simulation paradigm, 2023.

[96] Chenxu Hu, Jie Fu, Chenzhuang Du, Simian Luo, Junbo Zhao, and Hang Zhao. Chatdb: Augmenting llms with databases as their symbolic memory. arXiv preprint arXiv:2306.03901, 2023.

[97] Lei Liu, Xiaoyan Yang, Yue Shen, Binbin Hu, Zhiqiang Zhang, Jinjie Gu, and Guannan Zhang. Think-in-memory: Recalling and post-thinking enable llms with long-term memory. arXiv preprint arXiv:2311.08719, 2023.

[98] Xinnian Liang, Bing Wang, Hui Huang, Shuangzhi Wu, Peihao Wu, Lu Lu, Zejun Ma, and Zhoujun Li. Unleashing infinite-length input capacity for large-scale language models with self-controlled memory system. arXiv preprint arXiv:2304.13343, 2023.

[99] Guanzhi Wang, Yuqi Xie, Yunfan Jiang, Ajay Mandlekar, Chaowei Xiao, Yuke Zhu, Linxi Fan, and Anima Anandkumar. Voyager: An open-ended embodied agent with large language models. arXiv preprint arXiv:2305.16291, 2023.

[100] Charles Packer, Vivian Fang, Shishir G Patil, Kevin Lin, Sarah Wooders, and Joseph E Gonzalez. Memgpt: Towards llms as operating systems. arXiv preprint arXiv:2310.08560, 2023.

[101] Gibbeum Lee, Volker Hartmann, Jongho Park, Dimitris Papailiopoulos, and Kangwook Lee. Prompted llms as chatbot modules for long open-domain conversation. arXiv preprint arXiv:2305.04533, 2023.

[102] Yancheng Wang, Ziyan Jiang, Zheng Chen, Fan Yang, Yingxue Zhou, Eunah Cho, Xing Fan, Xiaojiang Huang, Yanbin Lu, and Yingzhen Yang. Recmind: Large language model powered agent for recommendation. arXiv preprint arXiv:2308.14296, 2023.

[103] Weiran Yao, Shelby Heinecke, Juan Carlos Niebles, Zhiwei Liu, Yihao Feng, Le Xue, Rithesh Murthy, Zeyuan Chen, Jianguo Zhang, Devansh Arpit, et al. Retroformer: Retrospective large language agents with policy gradient optimization. arXiv preprint arXiv:2308.02151, 2023.

[104] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. arXiv preprint arXiv:2210.03629, 2022.

[105] Yunfan Shao, Linyang Li, Junqi Dai, and Xipeng Qiu. Character-llm: A trainable agent for role-playing. arXiv preprint arXiv:2310.10158, 2023.

[106] Jihoon Tack, Jaehyung Kim, Eric Mitchell, Jinwoo Shin, Yee Whye Teh, and Jonathan Richard Schwarz. Online adaptation of language models with a memory of amortized contexts. arXiv preprint arXiv:2403.04317, 2024.

[107] Haochun Wang, Chi Liu, Nuwa Xi, Zewen Qiang, Sendong Zhao, Bing Qin, and Ting Liu. Huatuo: Tuning llama model with chinese medical knowledge. arXiv preprint arXiv:2304.06975, 2023.

[108] Xu Huang, Jianxun Lian, Yuxuan Lei, Jing Yao, Defu Lian, and Xing Xie. Recommender ai agent: Integrating large language models for interactive recommendations. arXiv preprint arXiv:2308.16505, 2023.

[109] Yuan Li, Yixuan Zhang, and Lichao Sun. Metaagents: Simulating interactions of human behaviors for llm-based task-oriented coordination via collaborative generative agents. arXiv preprint arXiv:2310.06500, 2023.

[110] Jingqing Ruan, Yihong Chen, Bin Zhang, Zhiwei Xu, Tianpeng Bao, Guoqing Du, Shiwei Shi, Hangyu Mao, Xingyu Zeng, and Rui Zhao. Tptu: Task planning and tool usage of large language model-based ai agents. arXiv preprint arXiv:2308.03427, 2023.

[111] Yilun Kong, Jingqing Ruan, Yihong Chen, Bin Zhang, Tianpeng Bao, Shiwei Shi, Guoqing Du, Xiaoru Hu, Hangyu Mao, Ziyue Li, et al. Tptu-v2: Boosting task planning and tool usage of large language model-based agents in real-world systems. arXiv preprint arXiv:2311.11315, 2023.

[112] Sirui Hong, Xiawu Zheng, Jonathan Chen, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, et al. Metagpt: Meta programming for multi-agent collaborative framework. arXiv preprint arXiv:2308.00352, 2023.

[113] Yi Yang, Yixuan Tang, and Kar Yan Tam. Investlm: A large language model for investment using financial domain instruction tuning. arXiv preprint arXiv:2309.13064, 2023.

[114] Kechi Zhang, Jia Li, Ge Li, Xianjie Shi, and Zhi Jin. Codeagent: Enhancing code generation with tool-integrated agent systems for real-world repo-level coding challenges. arXiv preprint arXiv:2401.07339, 2024.

[115] Li Yunxiang, Li Zihan, Zhang Kai, Dan Ruilong, and Zhang You. Chatdoctor: A medical chat model fine-tuned on llama model using medical domain knowledge. arXiv preprint arXiv:2303.14070, 2023.

[116] Dacheng Li, Rulin Shao, Anze Xie, Ying Sheng, Lianmin Zheng, Joseph Gonzalez, Ion Stoica, Xuezhe Ma, and Hao Zhang. How long can context length of open-source llms truly promise? In NeurIPS 2023 Workshop on Instruction Tuning and Instruction Following, 2023.

[117] Ziheng Huang, Sebastian Gutierrez, Hemanth Kamana, and Stephen MacNeil. Memory sandbox: Transparent and interactive memory management for conversational agents. In Adjunct Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology, pages 1–3, 2023.

[118] Arka Pal, Deep Karkhanis, Manley Roberts, Samuel Dooley, Arvind Sundararajan, and Siddartha Naidu. Giraffe: Adventures in expanding context lengths in llms. arXiv preprint arXiv:2308.10882, 2023.

[119] Szymon Tworkowski, Konrad Staniszewski, Mikołaj Pacek, Yuhuai Wu, Henryk Michalewski, and Piotr Miłoś. Focused transformer: Contrastive training for context scaling, 2023.

[120] Nelson F Liu, Kevin Lin, John Hewitt, Ashwin Paranjape, Michele Bevilacqua, Fabio Petroni, and Percy Liang. Lost in the middle: How language models use long contexts. arXiv preprint arXiv:2307.03172, 2023.

[121] Peter J Denning. The locality principle. Communications of the ACM, 48(7):19–24, 2005.

[122] Hermann Ebbinghaus. Memory: A contribution to experimental psychology, trans. HA Ruger & CE Bussenius. Teachers College.[rWvH], 1885.

[123] Jaap MJ Murre and Joeri Dros. Replication and analysis of ebbinghaus' forgetting curve. PloS one, 10(7):e0120644, 2015.

[124] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with gpus. IEEE Transactions on Big Data, 7(3):535–547, 2019.

[125] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools. arXiv preprint arXiv:2302.04761, 2023.

[126] Yujia Qin, Shihao Liang, Yining Ye, Kunlun Zhu, Lan Yan, Yaxi Lu, Yankai Lin, Xin Cong, Xiangru Tang, Bill Qian, et al. Toolllm: Facilitating large language models to master 16000+ real-world apis. arXiv preprint arXiv:2307.16789, 2023.

[127] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, et al. Llama: Open and efficient foundation language models. arXiv preprint arXiv:2302.13971, 2023.

[128] Zhibin Gou, Zhihong Shao, Yeyun Gong, Yujiu Yang, Minlie Huang, Nan Duan, Weizhu Chen, et al. Tora: A tool-integrated reasoning agent for mathematical problem solving. arXiv preprint arXiv:2309.17452, 2023.

[129] Honglin Xiong, Sheng Wang, Yitao Zhu, Zihao Zhao, Yuxiao Liu, Qian Wang, and Dinggang Shen. Doctorglm: Fine-tuning your chinese doctor is not a herculean task. arXiv preprint arXiv:2304.01097, 2023.

[130] Aohan Zeng, Xiao Liu, Zhengxiao Du, Zihan Wang, Hanyu Lai, Ming Ding, Zhuoyi Yang, Yifan Xu, Wendi Zheng, Xiao Xia, et al. Glm-130b: An open bilingual pre-trained model. arXiv preprint arXiv:2210.02414, 2022.

[131] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. Lora: Low-rank adaptation of large language models. arXiv preprint arXiv:2106.09685, 2021.

[132] Zhengliang Liu, Aoxiao Zhong, Yiwei Li, Longtao Yang, Chao Ju, Zihao Wu, Chong Ma, Peng Shu, Cheng Chen, Sekeun Kim, et al. Radiology-gpt: A large language model for radiology. arXiv preprint arXiv:2306.08666, 2023.

[133] Nicola De Cao, Wilker Aziz, and Ivan Titov. Editing factual knowledge in language models. arXiv preprint arXiv:2104.08164, 2021.

[134] Eric Mitchell, Charles Lin, Antoine Bosselut, Chelsea Finn, and Christopher D Manning. Fast model editing at scale. arXiv preprint arXiv:2110.11309, 2021.

[135] Shengyu Mao, Ningyu Zhang, Xiaohan Wang, Mengru Wang, Yunzhi Yao, Yong Jiang, Pengjun Xie, Fei Huang, and Huajun Chen. Editing personality for large language models. 2023.

[136] Jun-Yu Ma, Jia-Chen Gu, Ningyu Zhang, and Zhen-Hua Ling. Neighboring perturbations of knowledge editing on large language models. arXiv preprint arXiv:2401.17623, 2024.

[137] Mengru Wang, Ningyu Zhang, Ziwen Xu, Zekun Xi, Shumin Deng, Yunzhi Yao, Qishen Zhang, Linyi Yang, Jindong Wang, and Huajun Chen. Detoxifying large language models via knowledge editing. arXiv preprint arXiv:2403.14472, 2024.

[138] Uri Shaham, Maor Ivgi, Avia Efrat, Jonathan Berant, and Omer Levy. Zeroscrolls: A zero-shot benchmark for long text understanding. arXiv preprint arXiv:2305.14196, 2023.

[139] Yushi Bai, Xin Lv, Jiajie Zhang, Hongchang Lyu, Jiankai Tang, Zhidian Huang, Zhengxiao Du, Xiao Liu, Aohan Zeng, Lei Hou, et al. Longbench: A bilingual, multitask benchmark for long context understanding. arXiv preprint arXiv:2308.14508, 2023.

[140] Dacheng Li, Rulin Shao, Anze Xie, Ying Sheng, Lianmin Zheng, Joseph Gonzalez, Ion Stoica, Xuezhe Ma, and Hao Zhang. How long can context length of open-source llms truly promise? In NeurIPS 2023 Workshop on Instruction Tuning and Instruction Following, 2023.

[141] Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. Alfworld: Aligning text and embodied environments for interactive learning. arXiv preprint arXiv:2010.03768, 2020.

[142] YunDa Tsai, Mingjie Liu, and Haoxing Ren. Rtlfixer: Automatically fixing rtl syntax errors with large language models. arXiv preprint arXiv:2311.16543, 2023.

[143] Cheng Li, Ziang Leng, Chenxi Yan, Junyi Shen, Hao Wang, Weishi Mi, Yaying Fei, Xiaoyang Feng, Song Yan, HaoSheng Wang, et al. Chatharuhi: Reviving anime character in reality via large language model. arXiv preprint arXiv:2308.09597, 2023.

[144] Dake Chen, Hanbin Wang, Yunhao Huo, Yuzhao Li, and Haoyang Zhang. Gamegpt: Multi-agent collaborative framework for game development. arXiv preprint arXiv:2310.08067, 2023.

[145] Zekun Moore Wang, Zhongyuan Peng, Haoran Que, Jiaheng Liu, Wangchunshu Zhou, Yuhan Wu, Hongcheng Guo, Ruitong Gan, Zehao Ni, Man Zhang, et al. Rolellm: Benchmarking, eliciting, and enhancing role-playing abilities of large language models. arXiv preprint arXiv:2310.00746, 2023.

[146] Runcong Zhao, Wenjia Zhang, Jiazheng Li, Lixing Zhu, Yanran Li, Yulan He, and Lin Gui. Narrativeplay: Interactive narrative understanding. arXiv preprint arXiv:2310.01459, 2023.

[147] Jinfeng Zhou, Zhuang Chen, Dazhen Wan, Bosi Wen, Yi Song, Jifan Yu, Yongkang Huang, Libiao Peng, Jiaming Yang, Xiyao Xiao, et al. Characterglm: Customizing chinese conversational ai characters with large language models. arXiv preprint arXiv:2311.16832, 2023.

[148] Zhao Kaiya, Michelangelo Naim, Jovana Kondic, Manuel Cortes, Jiaxin Ge, Shuying Luo, Guangyu Robert Yang, and Andrew Ahn. Lyfe agents: Generative agents for low-cost real-time social interactions. arXiv preprint arXiv:2310.02172, 2023.

[149] Junjie Zhang, Yupeng Hou, Ruobing Xie, Wenqi Sun, Julian McAuley, Wayne Xin Zhao, Leyu Lin, and Ji-Rong Wen. Agentcf: Collaborative learning with autonomous language agents for recommender systems. arXiv preprint arXiv:2310.09233, 2023.

[150] Wenyue Hua, Lizhou Fan, Lingyao Li, Kai Mei, Jianchao Ji, Yingqiang Ge, Libby Hemphill, and Yongfeng Zhang. War and peace (waragent): Large language model-based multi-agent simulation of world wars. arXiv preprint arXiv:2311.17227, 2023.

[151] Haochun Wang, Sendong Zhao, Zewen Qiang, Zijian Li, Nuwa Xi, Yanrui Du, MuZhen Cai, Haoqiang Guo, Yuhan Chen, Haoming Xu, et al. Knowledge-tuning large language models with structured medical knowledge bases for reliable response generation in chinese. arXiv preprint arXiv:2309.04175, 2023.

[152] Wenqi Shi, Ran Xu, Yuchen Zhuang, Yue Yu, Jieyu Zhang, Hang Wu, Yuanda Zhu, Joyce Ho, Carl Yang, and May D Wang. Ehragent: Code empowers large language models for complex tabular reasoning on electronic health records. arXiv preprint arXiv:2401.07128, 2024.

[153] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Shaokun Zhang, Erkang Zhu, Beibin Li, Li Jiang, Xiaoyun Zhang, and Chi Wang. Autogen: Enabling next-gen llm applications via multi-agent conversation framework. arXiv preprint arXiv:2308.08155, 2023.

[154] Yang Li, Yangyang Yu, Haohang Li, Zhi Chen, and Khaldoun Khashanah. Tradinggpt: Multi-agent system with layered memory and distinct characters for enhanced financial trading performance. arXiv preprint arXiv:2309.03736, 2023.

[155] Saizhuo Wang, Hang Yuan, Lionel M Ni, and Jian Guo. Quantagent: Seeking holy grail in trading by self-improving large language model. arXiv preprint arXiv:2402.03755, 2024.

[156] Yangyang Yu, Haohang Li, Zhi Chen, Yuechen Jiang, Yang Li, Denghui Zhang, Rong Liu, Jordan W Suchow, and Khaldoun Khashanah. Finmem: A performance-enhanced llm trading agent with layered memory and character design. arXiv e-prints, pages arXiv–2311, 2023.

[157] Kelvin JL Koa, Yunshan Ma, Ritchie Ng, and Tat-Seng Chua. Learning to generate explainable stock predictions using self-reflective large language models. arXiv preprint arXiv:2402.03659, 2024.

[158] Kexin Chen, Junyou Li, Kunyi Wang, Yuyang Du, Jiahui Yu, Jiamin Lu, Lanqing Li, Jiezhong Qiu, Jianzhang Pan, Yi Huang, Qun Fang, Pheng Ann Heng, and Guangyong

Chen. Chemist-x: Large language model-empowered agent for reaction condition recommendation in chemical synthesis, 2024.

[159] Zihao Wang, Shaofei Cai, Anji Liu, Yonggang Jin, Jinbing Hou, Bowei Zhang, Haowei Lin, Zhaofeng He, Zilong Zheng, Yaodong Yang, et al. Jarvis-1: Open-world multi-task agents with memory-augmented multimodal language models. arXiv preprint arXiv:2311.05997, 2023.

[160] Zihan Zhao, Da Ma, Lu Chen, Liangtai Sun, Zihao Li, Hongshen Xu, Zichen Zhu, Su Zhu, Shuai Fan, Guodong Shen, et al. Chemdfm: Dialogue foundation model for chemistry. arXiv preprint arXiv:2401.14818, 2024.

[161] Ming Yan, Ruihao Li, Hao Zhang, Hao Wang, Zhilan Yang, and Ji Yan. Larp: Language-agent role play for open-world games. arXiv preprint arXiv:2312.17653, 2023.

[162] Zi-Yi Chen, Fan-Kai Xie, Meng Wan, Yang Yuan, Miao Liu, Zong-Guo Wang, Sheng Meng, and Yan-Gang Wang. Matchat: A large language model and application service platform for materials science. Chinese Physics B, 32(11):118104, 2023.

[163] Nian Li, Chen Gao, Yong Li, and Qingmin Liao. Large language model-empowered agents for simulating macroeconomic activities. arXiv preprint arXiv:2310.10436, 2023.

[164] Haojie Pan, Zepeng Zhai, Hao Yuan, Yaojia Lv, Ruiji Fu, Ming Liu, Zhongyuan Wang, and Bing Qin. Kwaiagents: Generalized information-seeking agent system with large language models. arXiv preprint arXiv:2312.04889, 2023.

[165] Odma Byambasuren, Yunfei Yang, Zhifang Sui, Damai Dai, Baobao Chang, Sujian Li, and Hongying Zan. Preliminary study on the construction of chinese medical knowledge graph. Journal of Chinese Information Processing, 33(10):1–9, 2019.

[166] Zefan Wang, Zichuan Liu, Yingying Zhang, Aoxiao Zhong, Lunting Fan, Lingfei Wu, and Qingsong Wen. Rcagent: Cloud root cause analysis by autonomous agents with tool-augmented large language models. arXiv preprint arXiv:2310.16340, 2023.

[167] Zhangcheng Qiang, Weiqing Wang, and Kerry Taylor. Agent-om: Leveraging large language models for ontology matching. arXiv preprint arXiv:2312.00326, 2023.

[168] Licheng Wen, Daocheng Fu, Xin Li, Xinyu Cai, Tao Ma, Pinlong Cai, Min Dou, Botian Shi, Liang He, and Yu Qiao. Dilu: A knowledge-driven approach to autonomous driving with large language models. arXiv preprint arXiv:2309.16292, 2023.

[169] Zhitao Wang, Wei Wang, Zirao Li, Long Wang, Can Yi, Xinjie Xu, Luyang Cao, Hanjing Su, Shouzhi Chen, and Jun Zhou. Xuat-copilot: Multi-agent collaborative system for automated user acceptance testing with large language model. arXiv preprint arXiv:2401.02705, 2024.

[170] Yongchao Chen, Jacob Arkin, Yang Zhang, Nicholas Roy, and Chuchu Fan. Scalable multi-robot collaboration with large language models: Centralized or decentralized systems? arXiv preprint arXiv:2309.15943, 2023.

[171] Zhao Mandi, Shreeya Jain, and Shuran Song. Roco: Dialectic multi-robot collaboration with large language models. arXiv preprint arXiv:2307.04738, 2023.

[172] Jonathan Light, Min Cai, Sheng Shen, and Ziniu Hu. From text to tactic: Evaluating llms playing the game of avalon. arXiv preprint arXiv:2310.05036, 2023.

[173] Bing Liu. Lifelong machine learning: a paradigm for continuous learning. Frontiers of Computer Science, 11:359–361, 2017.

[174] Gati V Aher, Rosa I Arriaga, and Adam Tauman Kalai. Using large language models to simulate multiple humans and replicate human subject studies. In International Conference on Machine Learning, pages 337–371. PMLR, 2023.